Artificial Intelligence:
Advances in Unsupervised Learning



Modèles à base d'énergie (EBMs)

FST of Settat
March 16-17, 2022

Pr. BEN LAHMAR EL HABIB
HASSAN II University, Casablanca
Faculty of Sciences Ben M'Sik

Agenda

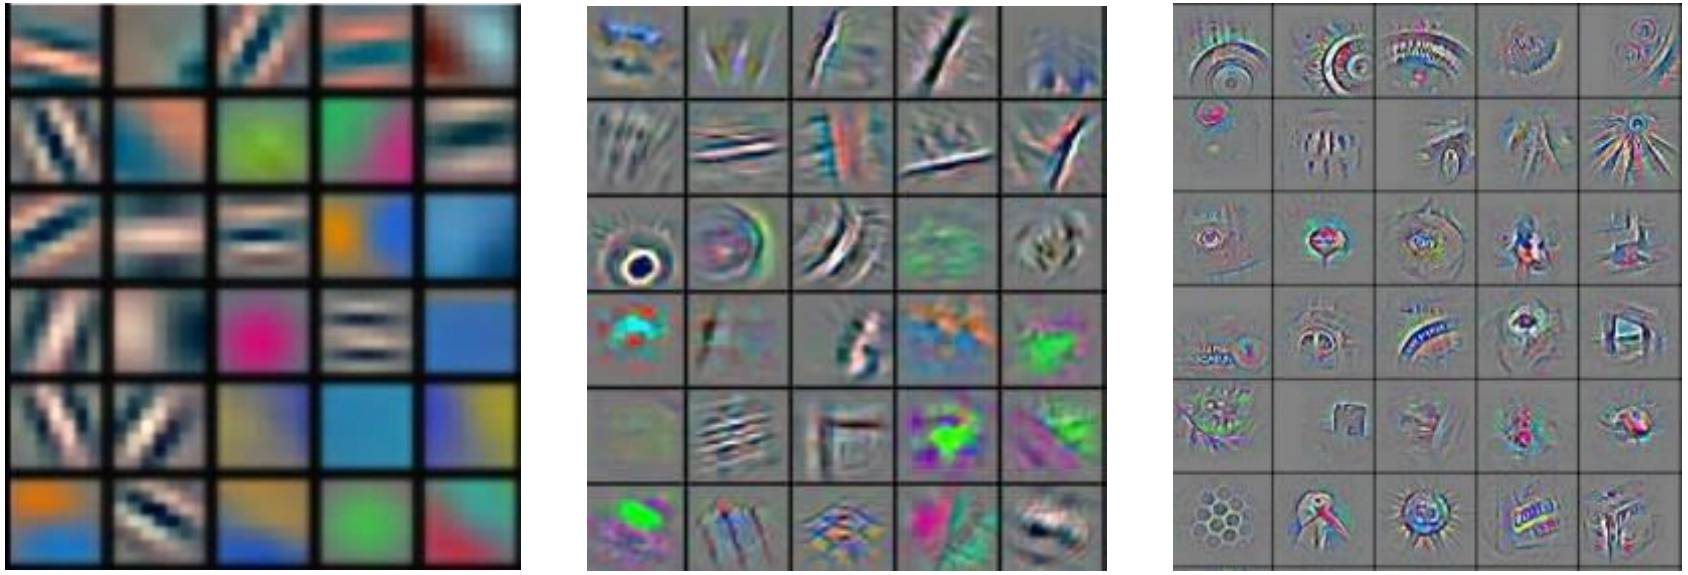
- Deep Learning
- Pourquoi un autre modèle d'apprentissage ?
- Modèle génératif Modèle discriminant
- Problème d'incertitude
- Modèle basé sur l'énergie
- Exemples et tâches
- Illustration
- Conclusion

DEEP LEARNING

It's deep if it has more than one stage of non-linear feature transformation

- Deep learning = learning hierarchical representations





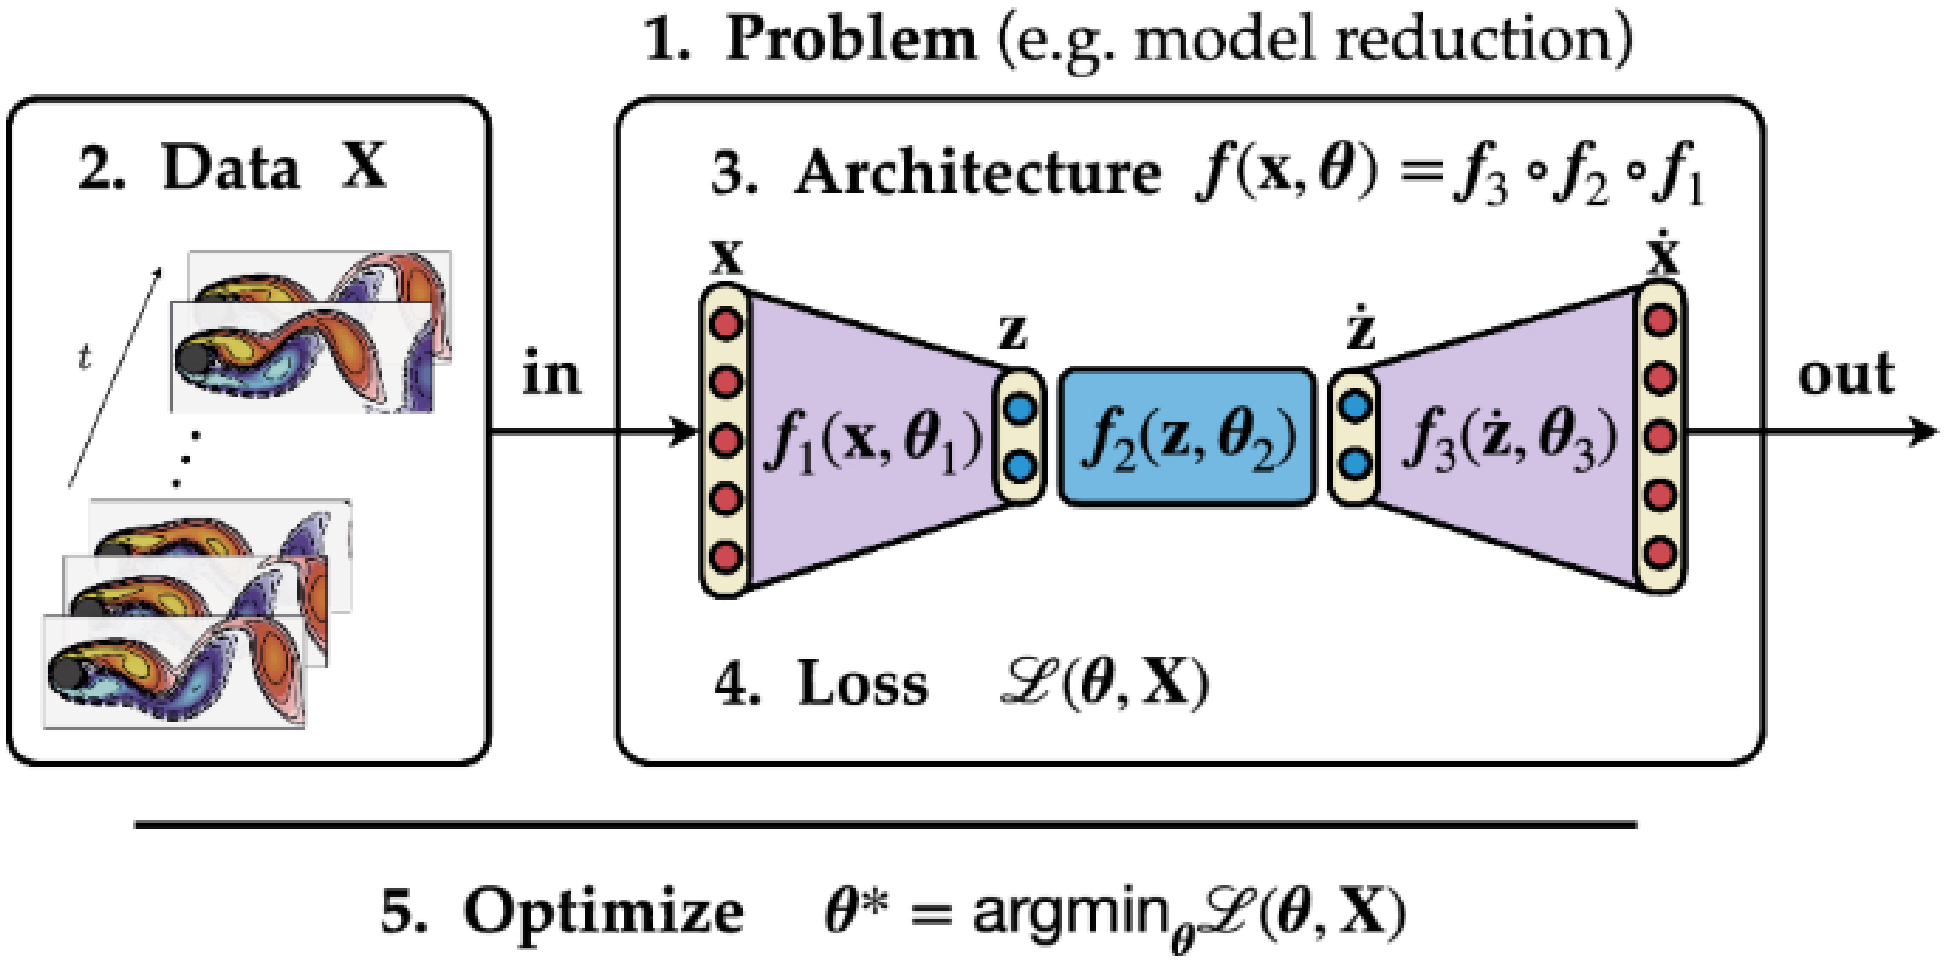
Feature visualization of convolutional net trained on ImageNet from [Zeiler & Fergus 2013]

Deep learning: Trois questions

- Quelle architecture $F(W,X)$.
- Quelle de perte $L(W, y^i, X^i)$.
- Quelle méthode d'optimisation

- Model???
- Architecture + algo d'inférence + loss function = model

Deep learning: Trois questions





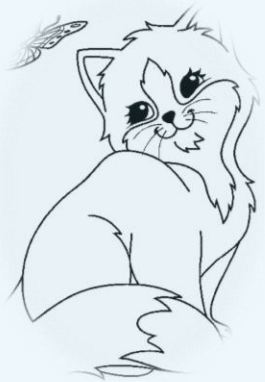
Modèle Génératif



Chien ou Chat ?

Dessiner

En se basant sur ce qu'in a appris





Comparer

En se basant sur la **correspondance la plus proche** entre l'image et l'animal

Comparer

En se basant sur les différences, en fonction des **différentes propriétés apprises**

Réponse : Chien

Modèle Discriminant

Les deux trouvent le type d'animal, mais **la manière d'apprendre** et **la manière de trouver** la réponse sont entièrement différentes.

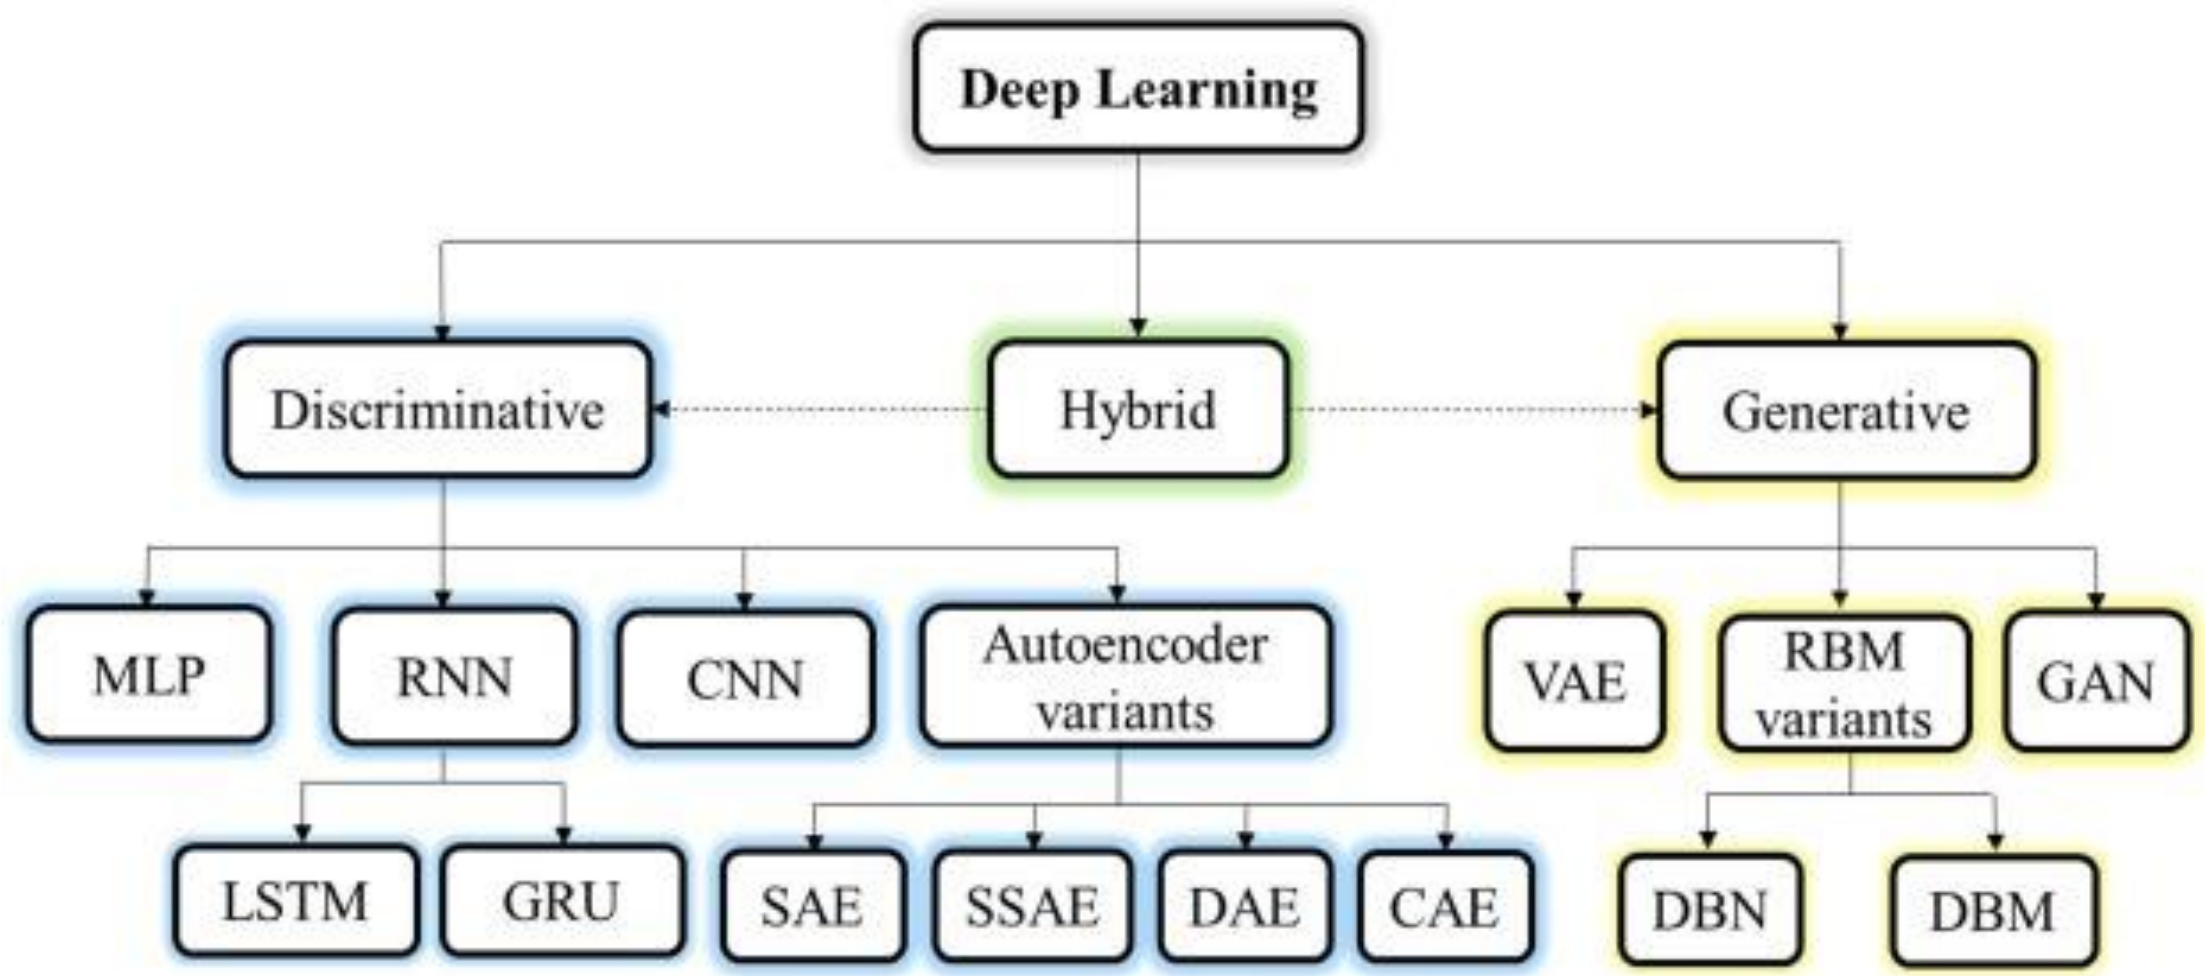
Modèle génératif Modèle discriminant.

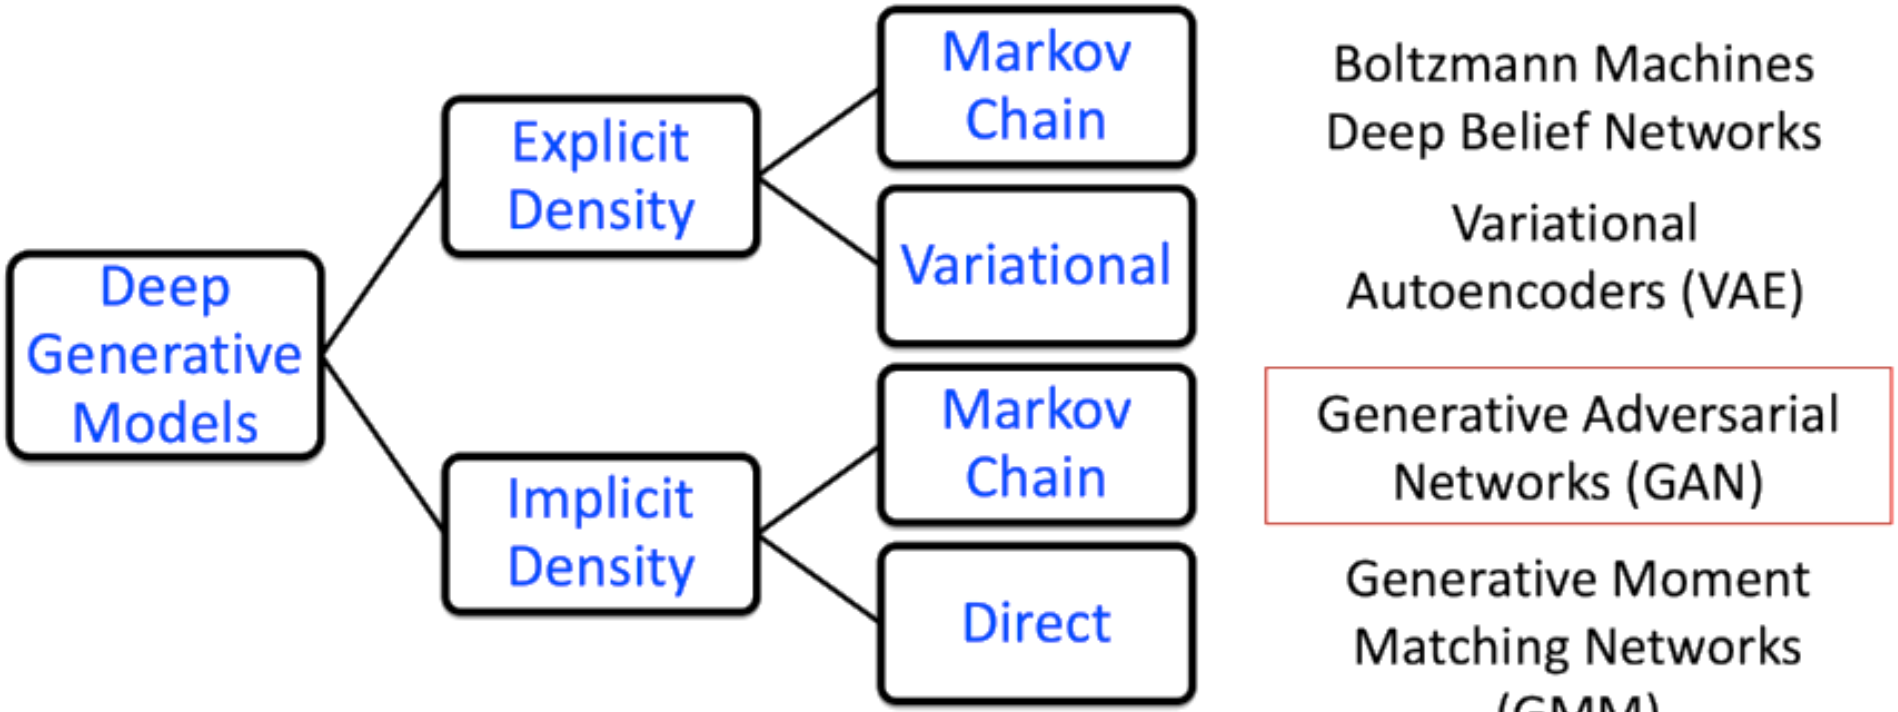
- Un modèle discriminant modélise la **frontière de décision entre les classes** .
- Un modèle génératif modélise explicitement la **distribution réelle de chaque classe** .
- Les deux prédisent la probabilité conditionnelle P (Animal | Caractéristiques). Mais les deux modèles apprennent des probabilités de manières différentes.

Modèle génératif Modèle discriminant.

- Un modèle génératif apprend la **distribution de probabilité conjointe p(x,y).** Il prédit la probabilité conditionnelle à l'aide du théorème de **Bayes** .
- Un modèle discriminant apprend la **distribution de probabilité conditionnelle p(y|x)** .

Deep Learning




Deep Generative Models
Explicit Density
Implicit Density
Markov Chain
Variational
Markov Chain
Direct
Boltzmann Machines
Deep Belief Networks
Variational Autoencoders (VAE)
Generative Adversarial Networks (GAN)
Generative Moment Matching Networks (GMM)

Pourquoi un autre modèle d'apprentissage ?
Les Problèmes

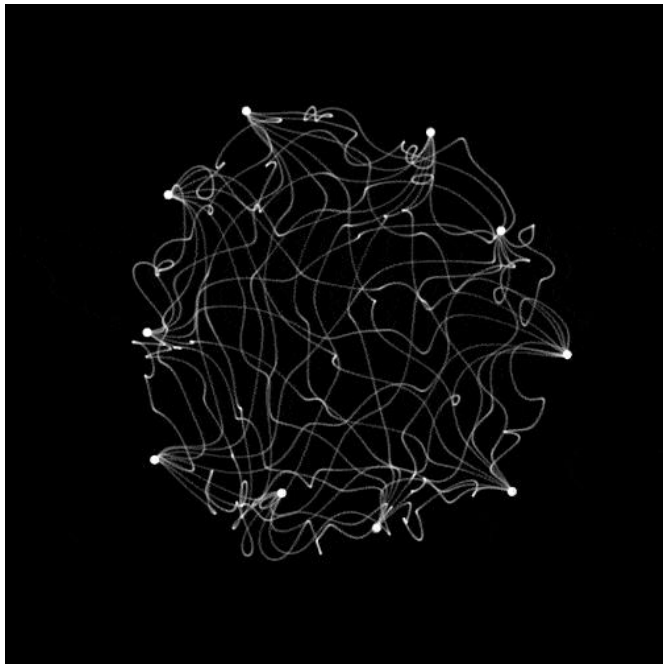
- Les réseaux *feed-forward* posent deux problèmes majeurs :
  1. Que faire si la procédure d'inférence est un calcul plus complexe que des couches empilées de sommes pondérées ?
  2. Que faire s'il y a plusieurs résultats possibles pour une seule entrée comme par exemple la prédiction des images futures dans une vidéo ?

Problèmes

- Dans un réseau de classification, nous entraînons ce réseau à émettre un score pour chaque classe.
- Cela n'est pas possible dans un domaine continu à **haute dimension** comme les images : nous ne pouvons pas avoir de softmax sur les images !

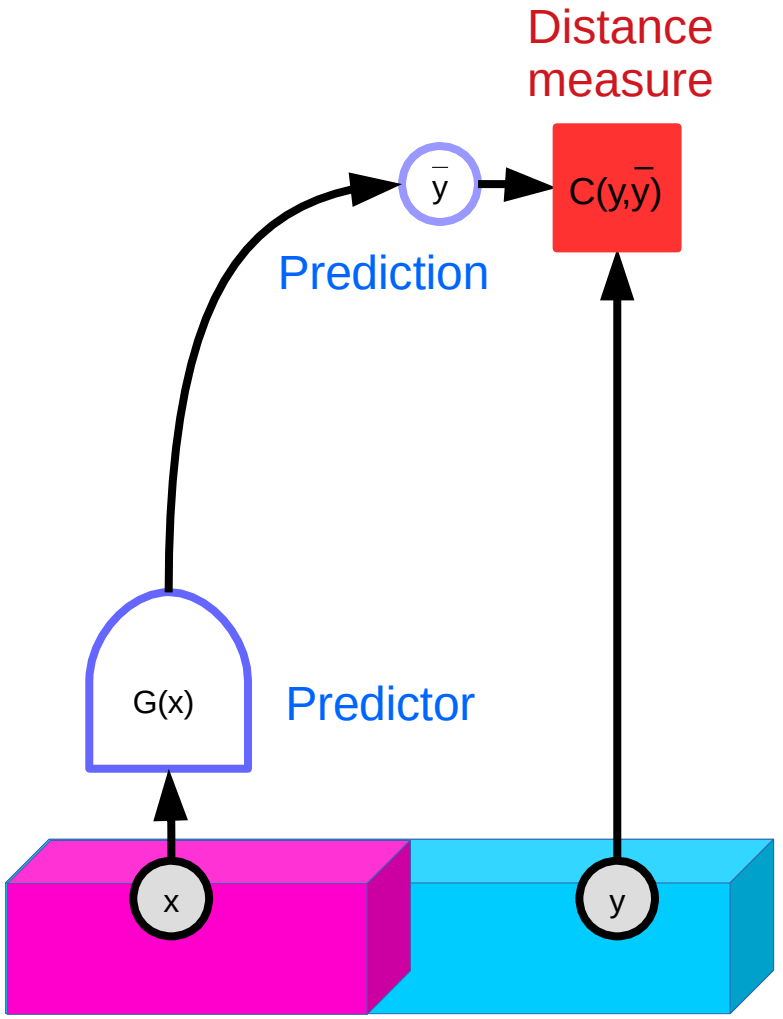
Problème : Incertitude!

- Il existe de nombreux mots plausibles pour compléter un texte.
- Il existe une infinité d'images plausibles pour compléter une vidéo.
- Les prédicteurs déterministes ne fonctionnent pas !
- Comment gérer l'incertitude dans la prédiction ?



Problème : Incertitude!

$$E(x, y) = C(y, G(x))$$



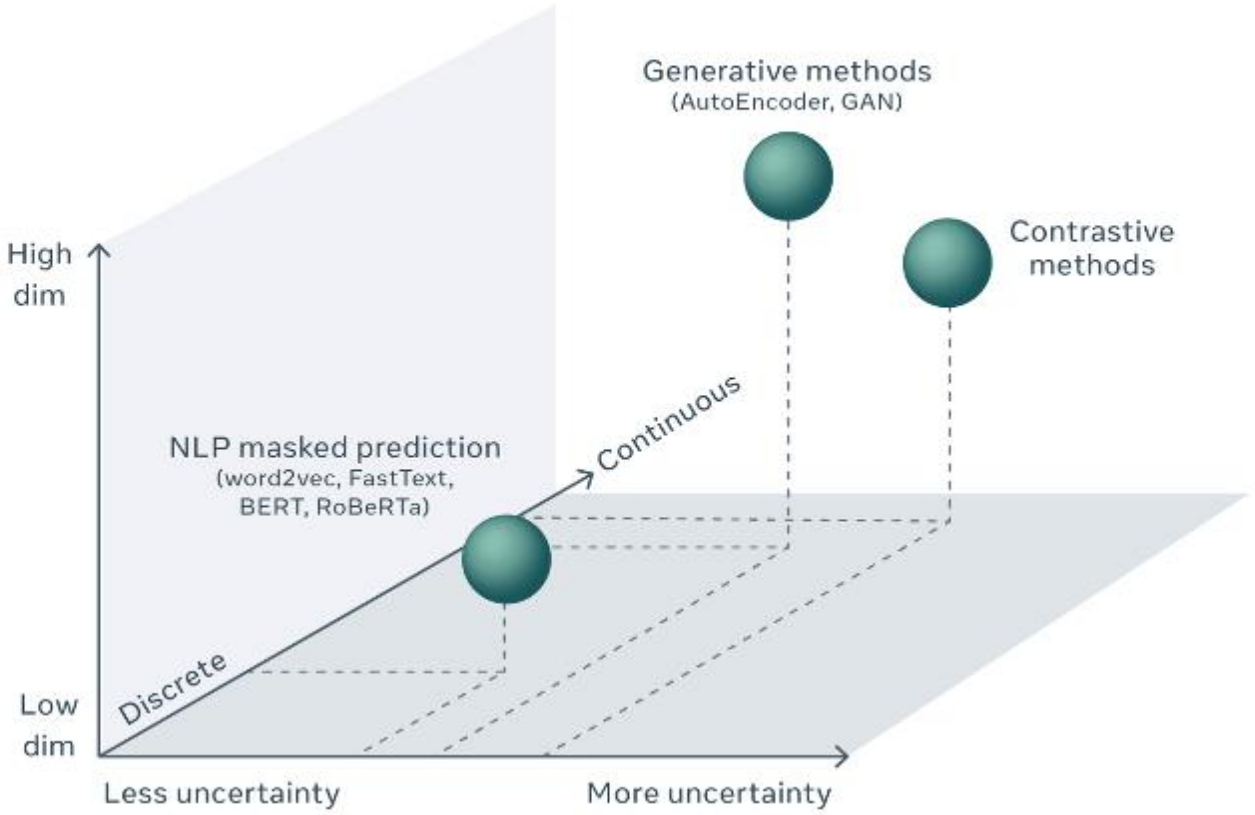
Modélisation de l'incertitude de la prédiction

- En NLP, la prédiction des mots manquants implique le calcul d'un score de prédiction pour chaque mot possible du vocabulaire.
- Même que la prédiction d'un mot manquant implique une certaine incertitude, il est possible de produire une liste de tous les mots possibles du vocabulaire avec une estimation de probabilité de l'apparition des mots à cet endroit.
- le problème de prédiction devient un problème de classification
  - Calcule des scores pour chaque résultat à l'aide du **softmax**, qui transforme les scores bruts en une distribution de probabilité sur les mots.

Modélisation de l'incertitude de la prédiction

- En CV, la tâche analogue de prédire les images «manquantes» dans une vidéo, ou le segment manquant dans un signal vocal implique une prédiction d'objets continus de haute dimension plutôt que des résultats discrets.
- Il existe **un nombre infini d'images** vidéo possibles qui peuvent suivre de manière plausible un clip vidéo donné.
- Il n'est pas possible de représenter explicitement toutes les images vidéo possibles et de leur associer un score de prédiction.
- Pas de techniques pour représenter des distributions de probabilités appropriées sur des espaces continus de grande dimension, tels que l'ensemble de toutes les images vidéo possibles.

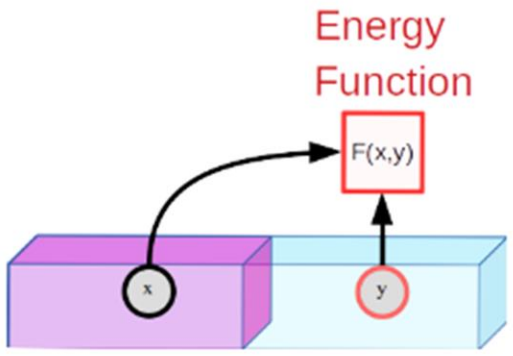
Modélisation de l'incertitude de la prédiction



Comment ?

Apprendre à gérer l'incertitude tout en évitant les probabilités

Une vision unifiée des méthodes autocontrôlées



Objectif

- Les modèles basées sur les réseaux feed-forward avaient pour objectif la classification ou la régression, les modèles basés sur l'énergie sont motivés par une perspective différente : **l'estimation de la densité**.
- Étant donné un ensemble de données avec beaucoup d'éléments, nous voulons estimer la distribution de probabilité sur l'ensemble de l'espace de données

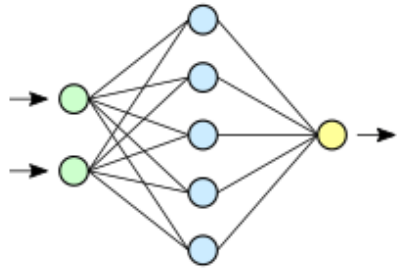
Paramétrer les distributions de probabilité

1. La distribution de probabilité doit attribuer toute valeur possible de x une valeur non négative :$p(x) \geq 0$.
2. La densité de probabilité doit être intégrer à 1 sur **toutes** les entrées possibles : $\int_{\mathbf{x}} p(\mathbf{x}) d\mathbf{x} = 1.$

Objectif

- L'idée fondamentale des modèles basés sur l'énergie est que vous pouvez transformer n'importe quelle fonction qui prédit des valeurs supérieures à zéro en une distribution de probabilité en divisant par son volume.

Exemple



- Imaginez que nous ayons un réseau de neurones, qui a comme sortie un seul neurone, comme dans la régression.
- Nous pouvons appeler ce réseau $E\theta(x)$, où θ sont nos paramètres du réseau, et x les données d'entrée (par exemple une image).
- La sortie de $E\theta$ est une valeur scalaire entre $-\infty$ et ∞. Maintenant, nous pouvons utiliser la théorie des probabilités de base pour normaliser les scores de toutes les entrées possibles :

$$q_\theta(\mathbf{x}) = \frac{\exp\left(-E_\theta(\mathbf{x})\right)}{Z_\theta} \quad \text{where} \quad Z_\theta = \begin{cases} \int_{\mathbf{x}} \exp\left(-E_\theta(\mathbf{x})\right) d\mathbf{x} & \text{if } x \text{ is continuous} \\ \sum_{\mathbf{x}} \exp\left(-E_\theta(\mathbf{x})\right) & \text{if } x \text{ is discrete} \end{cases}$$

On utilise un signe négatif devant E parce que nous $E\theta$ doit être la fonction énergétique : les points de données à forte probabilité ont une faible énergie, tandis que les points de données à faible probabilité ont une énergie élevée

Pb: comment calcule-t-on Zθ?

$$q_\theta(\mathbf{x}) = \frac{\exp\left(-E_\theta(\mathbf{x})\right)}{Z_\theta} \quad \text{where} \quad Z_\theta = \begin{cases} \int_{\mathbf{x}} \exp\left(-E_\theta(\mathbf{x})\right) d\mathbf{x} & \text{if } x \text{ is continuous} \\ \sum_{\mathbf{x}} \exp\left(-E_\theta(\mathbf{x})\right) & \text{if } x \text{ is discrete} \end{cases}$$

Zθ : la constante de normalisation inconnue

$$\int_{\mathbf{x}} q_\theta(\mathbf{x}) d\mathbf{x} = \int_{\mathbf{x}} \frac{\exp\left(-E_\theta(\mathbf{x})\right)}{\int_{\tilde{\mathbf{x}}} \exp\left(-E_\theta(\tilde{\mathbf{x}})\right) d\tilde{\mathbf{x}}} d\mathbf{x} = \frac{\int_{\mathbf{x}} \exp\left(-E_\theta(\mathbf{x})\right) d\mathbf{x}}{\int_{\tilde{\mathbf{x}}} \exp\left(-E_\theta(\tilde{\mathbf{x}})\right) d\tilde{\mathbf{x}}} = 1$$

Paramétrer les distributions de probabilité

Problem: $g_\theta(\mathbf{x}) \geq 0$ is easy, but $g_\theta(\mathbf{x})$ might not be normalized
Solution:

$$p_\theta(\mathbf{x}) = \frac{1}{Volume(g_\theta)} g_\theta(\mathbf{x}) = \frac{1}{\int g_\theta(\mathbf{x}) \mathrm{d}\mathbf{x}} g_\theta(\mathbf{x})$$

Then by definition, $\int p_\theta(\mathbf{x}) \mathrm{d}\mathbf{x} = 1$.
Example: choose $g_\theta(\mathbf{x})$ so that we know the volume *analytically* as a function of θ.

1. $g_{(\mu,\sigma)}(x) = e^{-\frac{(x-\mu)^2}{2\sigma^2}}$. **Volume** is: $\int e^{-\frac{x-\mu}{2\sigma^2}} dx = \sqrt{2\pi\sigma^2}$. $\rightarrow$ **Gaussian**
2. $g_\lambda(x) = e^{-\lambda x}$. **Volume** is: $\int_0^{+\infty} e^{-\lambda x} dx = \frac{1}{\lambda}$. $\rightarrow$ **Exponential**
3. $g_\theta(x) = h(x) \exp\{\theta \cdot T(x)\}$. **Volume** is $\exp\{A(\theta)\}$, where $A(\theta) = \log \int h(x) \exp\{\theta \cdot T(x)\} \mathrm{d}\mathbf{x}$. $\rightarrow$ **Exponential family**
   - Normal, Poisson, exponential, Bernoulli
   - beta, gamma, Dirichlet, Wishart, etc.

- Les formes de fonction gθ(x) doivent permettre une intégration analytique. Bien qu'elles soient restrictives, elles sont très utiles comme blocs de construction pour des distributions plus complexes.

Que faire

- Et pour les modèles où le "volume"/la constante de normalisation de $g_\theta(x)$ n'est pas facile à calculer analytiquement ?

Astuce

$$p_\theta(\mathbf{x}) = \frac{1}{\int \exp(f_\theta(\mathbf{x}))d\mathbf{x}} \exp(f_\theta(\mathbf{x})) = \frac{1}{Z(\theta)} \exp(f_\theta(\mathbf{x}))$$

Étant donné x, x'

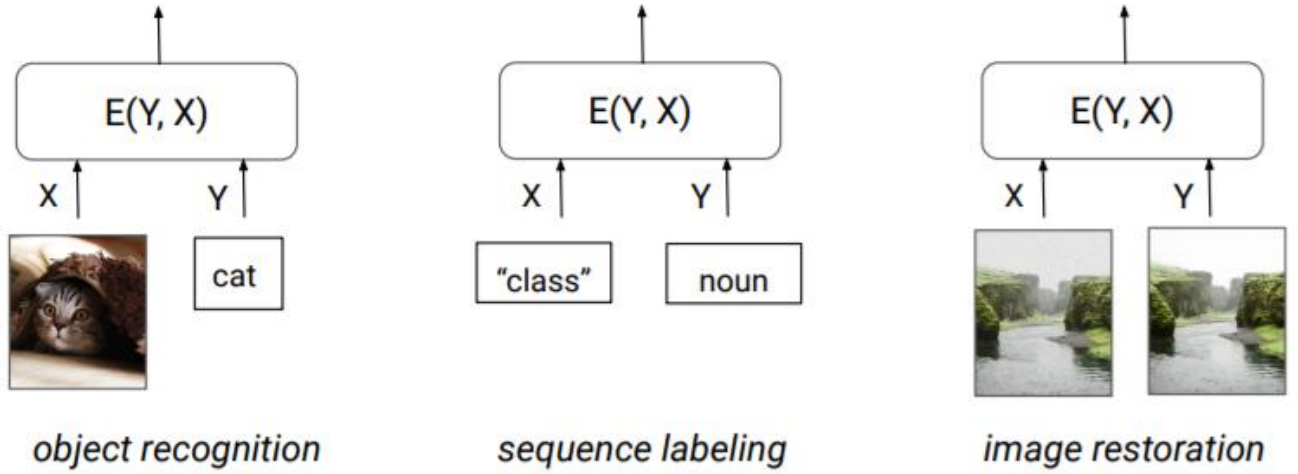
Évaluer $P\theta(x)$ ou $P\theta(x')$ nécessite $Z(\theta)$.
Cependant, leur rapport

$$\frac{p_\theta(\mathbf{x})}{p_\theta(\mathbf{x}')} = \exp(f_\theta(\mathbf{x}) - f_\theta(\mathbf{x}'))$$ ne fait pas intervenir $Z(\theta)$.

Cela signifie que nous pouvons facilement vérifier lequel est le plus probable.

Applications

- Étant donné un modèle entraîné, de nombreuses applications nécessitent des comparaisons relatives.
- Par conséquent, Z(θ) n'est pas nécessaire.



Modèles basé sur l'énergie (EBMs)

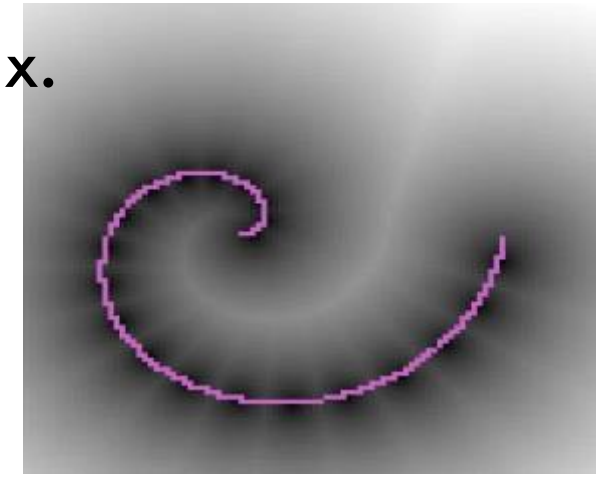
- Un EBM est un système entraînable
- étant donné deux entrées, x et y, le système indique à quel point elles sont incompatibles l'une avec l'autre.
- Par exemple, x peut être un court clip vidéo et y un autre clip vidéo proposé. La machine nous dirait dans quelle mesure y est une bonne continuation pour x.
- Pour indiquer l'incompatibilité entre x et y, la machine produit un seul nombre, appelé énergie.
  - Si l'énergie est faible, x et y sont réputés compatibles; s'il est élevé, ils sont jugés incompatibles.

$$\arg\min f \overset{\text{déf}}{=} \{x \in X \mid \forall x' \in X, f(x') \geq f(x)\}.$$

Modèle basé sur l'énergie (EBM)

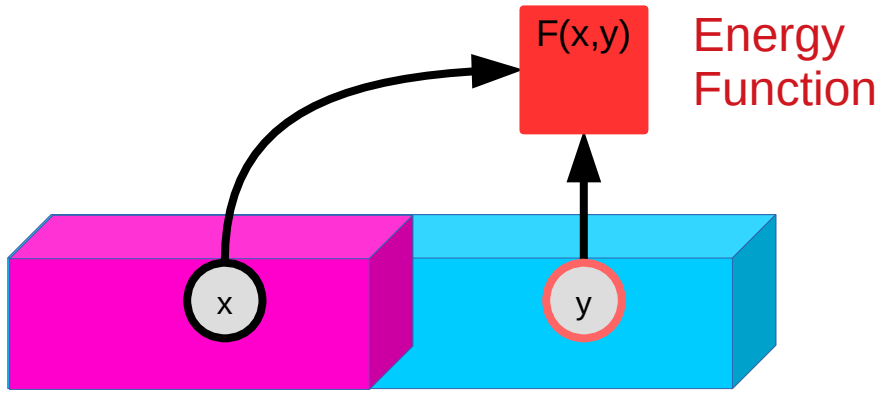
- Fonction d'énergie à valeur scalaire : F(x,y)
- Mesure la compatibilité entre x et y.
- Faible énergie : y est une bonne prédiction à partir de x.
- Energie élevée : y est une mauvaise prédiction de x

Dark = low energy (good)
Bright = high energy (bad)
Purple = data manifold



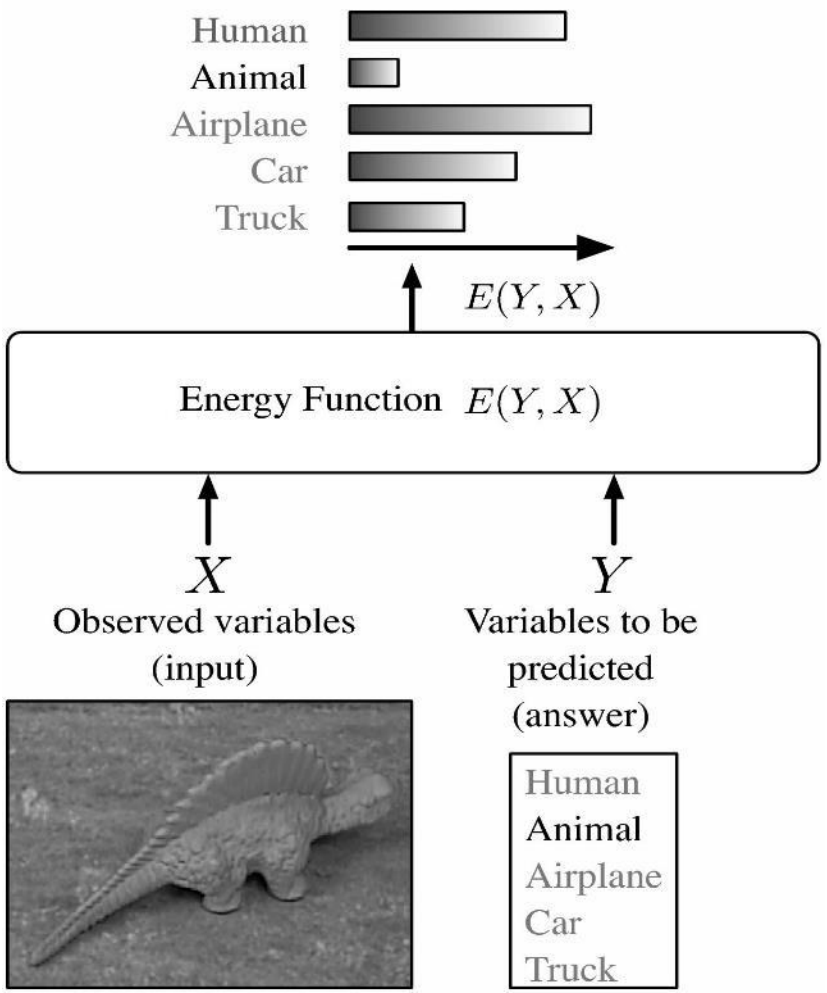
[Figure from M-A Ranzato's PhD thesis]

- Inference: $\check{y} = \operatorname{argmin}_y F(x, y)$



A noter que cette énergie est utilisée en inférence et non **pas** pour l'apprentissage.

Modèle énergétique pour la prise de décision



- Modèle : Mesure la compatibilité entre une variable observée X et une variable à prédire Y à travers une fonction d'énergie E(Y,X).

$$Y^* = \text{argmin}_{Y \in \mathcal{Y}} E(Y, X).$$

- Inférence : Recherche du Y qui minimise l'énergie au sein d'un ensemble.
- Si l'ensemble a une faible cardinalité, on peut utiliser la recherche exhaustive.

À quelles questions un modèle peut-il répondre ?

- Classification et prise de décision : "Quelle valeur de Y est la plus compatible avec X ?"
  - Applications : navigation de robots, ...
  - Entraînement : donner la plus faible énergie à la bonne réponse
- Classement : "Y1 ou Y2 est-il plus compatible avec X ?"
  - Applications : exploration de données....
  - Entraînement : produire des énergies qui classent les réponses correctement
- Détection : "Cette valeur de Y est-elle compatible avec X" ?
  - Application : détection de visage....
  - Entraînement : énergies qui augmentent à mesure que l'image ressemble moins à un visage.
  - Estimation de la densité conditionnelle :
- "Quelle est la distribution conditionnelle $P(Y|X)$?"
  - Application : alimentation d'un système de décision
  - Entraînement : les différences d'énergies doivent être justes.

N.B

- Les énergies ne sont pas calibrées
  - Les énergies de deux systèmes formés séparément ne peuvent pas être combinées.
  - Les énergies ne sont pas calibrées (mesurées en untis arbitraires).
- Comment calibrer les énergies ?
  - Nous les transformons en probabilités (nombres positifs dont la somme est égale à 1).
  - Méthode la plus simple : Distribution de Gibbs
  - Les autres méthodes peuvent être réduites à Gibbs par une redéfinition appropriée de l'énergie

Transformer les énergies en probabilités (si nécessaire)

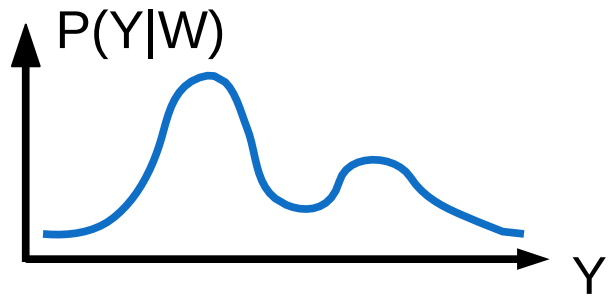
- L'énergie peut être interprétée comme une densité logarithmique négative non normalisée.
- Distribution de Gibbs : Probabilité proportionnelle à exp(-énergie)
  - Le paramètre bêta s'apparente à une température inverse.
- Ne calculez pas les probabilités sauf si vous devez absolument le faire.
  - Parce que le dénominateur est souvent difficile à résoudre

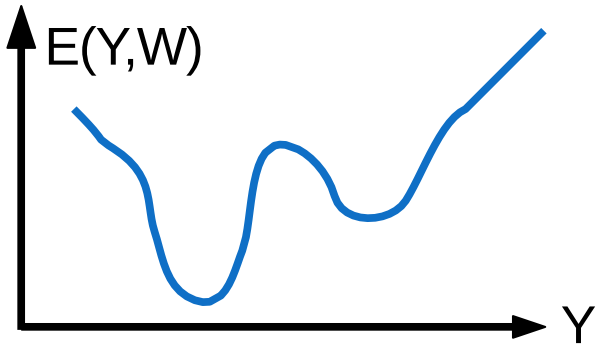
$$P(Y|W) = \frac{e^{-\beta E(Y,W)}}{\int_y e^{-\beta E(y,W)}}$$

Partition function

Inverse temperature

$$E(Y,W) \propto -\log P(Y|W)$$





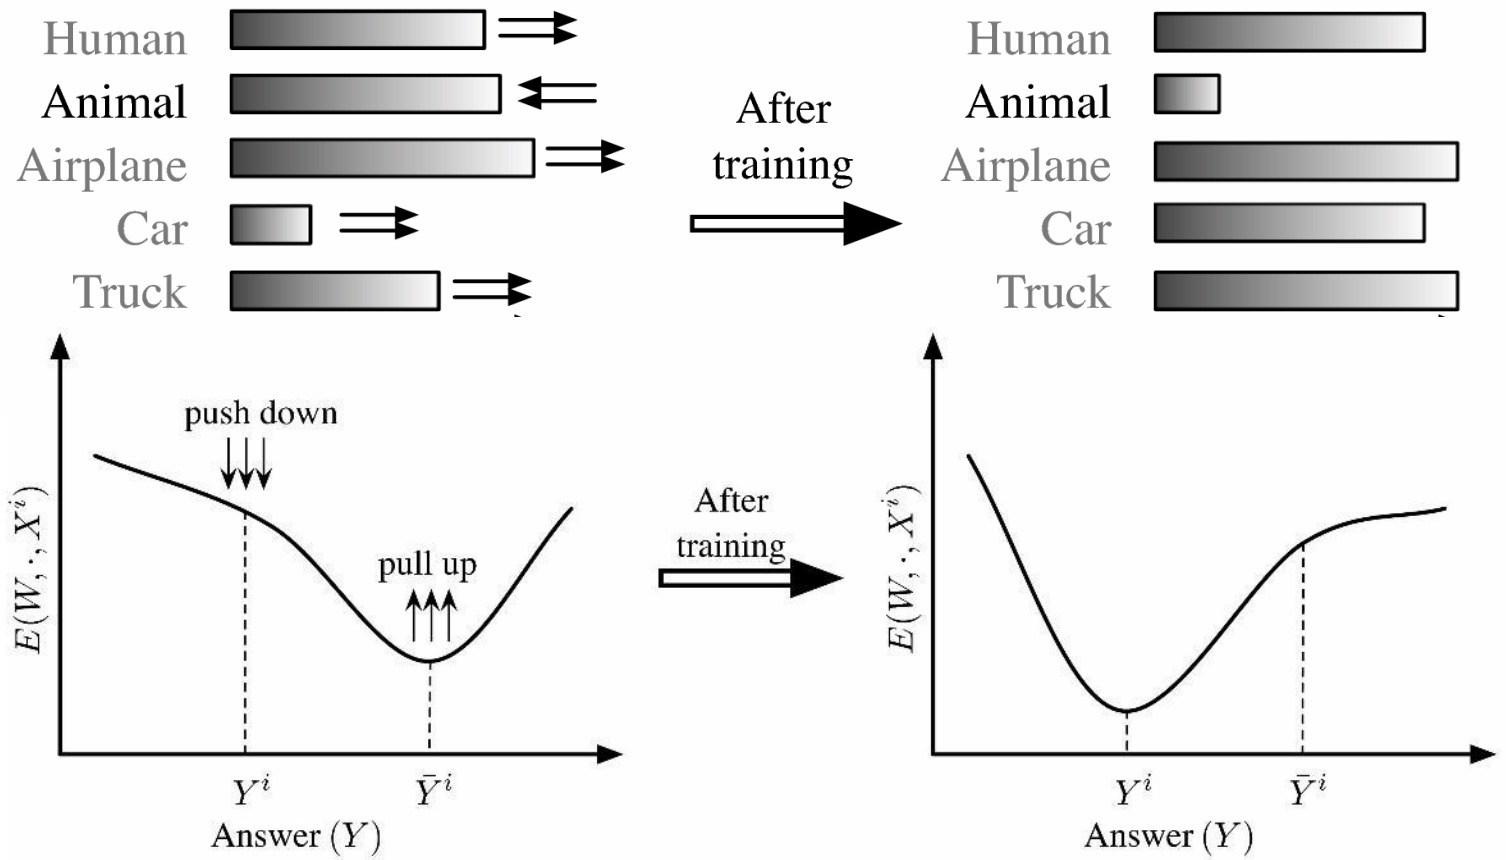
Apprendre la fonction d'énergie

- Fonction d'énergie paramétrée E(Y,W)
- Rendre l'énergie faible sur les échantillons
- Rendre l'énergie plus élevée partout ailleurs
- Rendre l'énergie faible sur les échantillons est facile
- Mais comment faire pour qu'elle soit plus élevée partout ailleurs ?

Sept stratégies pour façonner la fonction énergétique

1. Construire la machine de façon à ce que le volume des produits à faible énergie soit constant.
   - PCA, K-means, GMM, ICA carré
2. Diminution de l'énergie des points de données, augmentation de l'énergie partout ailleurs.
   - Maxi-vraisemblance (nécessite une fonction de partition traçable)
3. Diminution de l'énergie des points de données, augmentation de l'énergie à certains endroits.
   - Divergence contrastive, Ratio Matching, Estimation Contrastive du Bruit, Flux de Probabilité Minimum.
4. Minimisez le gradient et maximisez la courbure autour des points de données.
   - correspondance de score
5. Entraînement d'un système dynamique pour que la dynamique aille vers le collecteur.
   - débruitage auto-encodeur
6. Utilisez un régularisateur qui limite le volume de l'espace à faible énergie.
   - Codage clairsemé, auto-encodeur clairsemé, PSD
7. Si E(Y) = ||Y - G(Y)||^2, rendre G(Y) aussi "constant" que possible.
   - Auto-codeur contractuel, auto-codeur saturant

Designing a loss functional



– Push down on the energy of the correct answer
– Pull up on the energies of the incorrect answers, particularly if they are smaller than the correct one

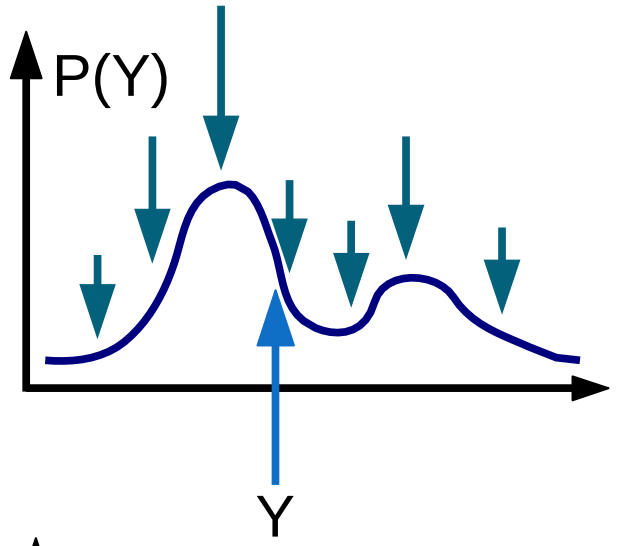
Diminution de l'énergie des points de données, augmentation de l'énergie partout ailleurs.

- Max likelihood (requires a tractable partition function)
- Maximizing P(Y|W) on training samples

make this big

$$P(Y|W) = \frac{e^{-\beta E(Y,W)}}{\int_y e^{-\beta E(y,W)}}$$

make this small

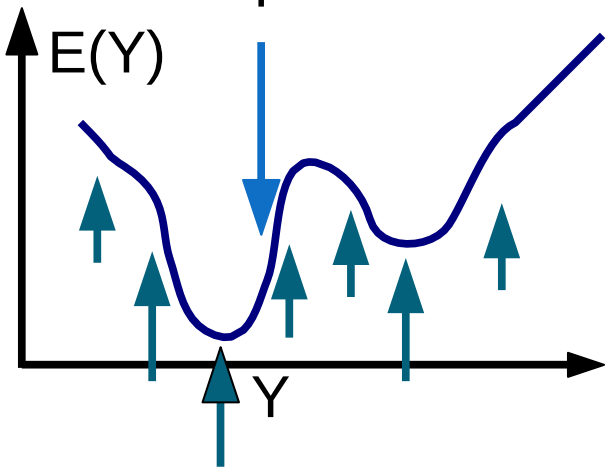


- Minimizing -log P(Y,W) on training samples

$$L(Y,W) = E(Y,W) + \frac{1}{\beta}\log\int_y e^{-\beta E(y,W)}$$

make this small

make this big



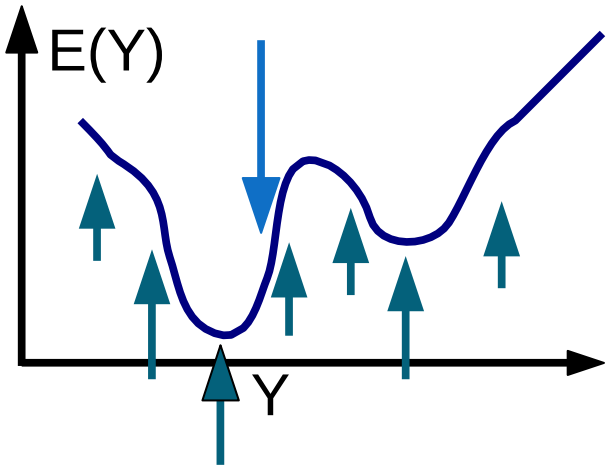
Diminuer l'énergie des points de données, augmenter l'énergie partout ailleurs.

– Gradient of the negative log-likelihood loss for one sample Y:

$$\frac{\partial L(Y,W)}{\partial W} = \frac{\partial E(Y,W)}{\partial W} - \int_y P(y|W) \frac{\partial E(y,W)}{\partial W}$$

– Gradient descent:

$$W \leftarrow W - \eta \frac{\partial L(Y,W)}{\partial W}$$



Pushes down on the energy of the samples

Pulls up on the energy of low-energy Y's

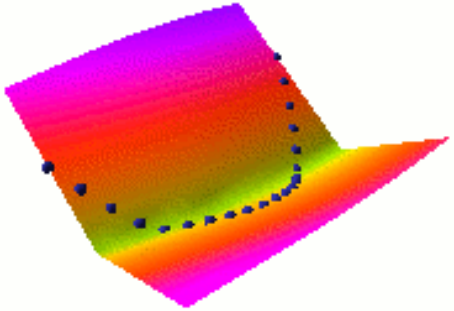
$$W \leftarrow W - \eta \frac{\partial E(Y,W)}{\partial W} + \eta \int_y P(y|W) \frac{\partial E(y,W)}{\partial W}$$

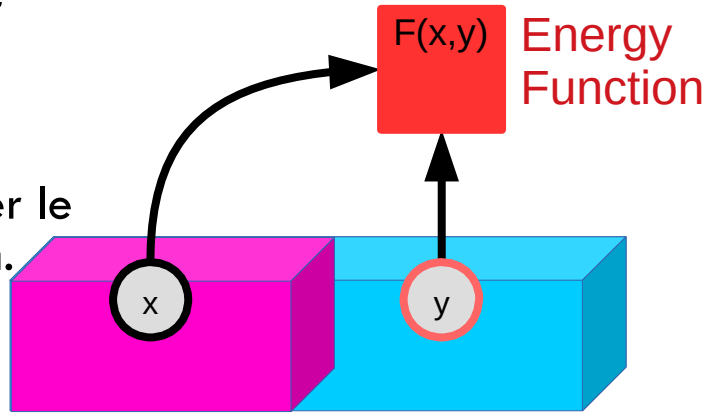
Entraînement d'un EBM

- L'entraînement d'un EBM se compose de deux parties:
  1. Lui montrer des exemples de x et y qui sont compatibles et l'entraîner à produire une faible énergie
  2. Trouver **un moyen** de s'assurer que pour un x particulier, les valeurs y qui sont incompatibles avec x produisent une énergie plus élevée que les valeurs y compatibles avec x.
- La première partie est simple, mais la deuxième est …

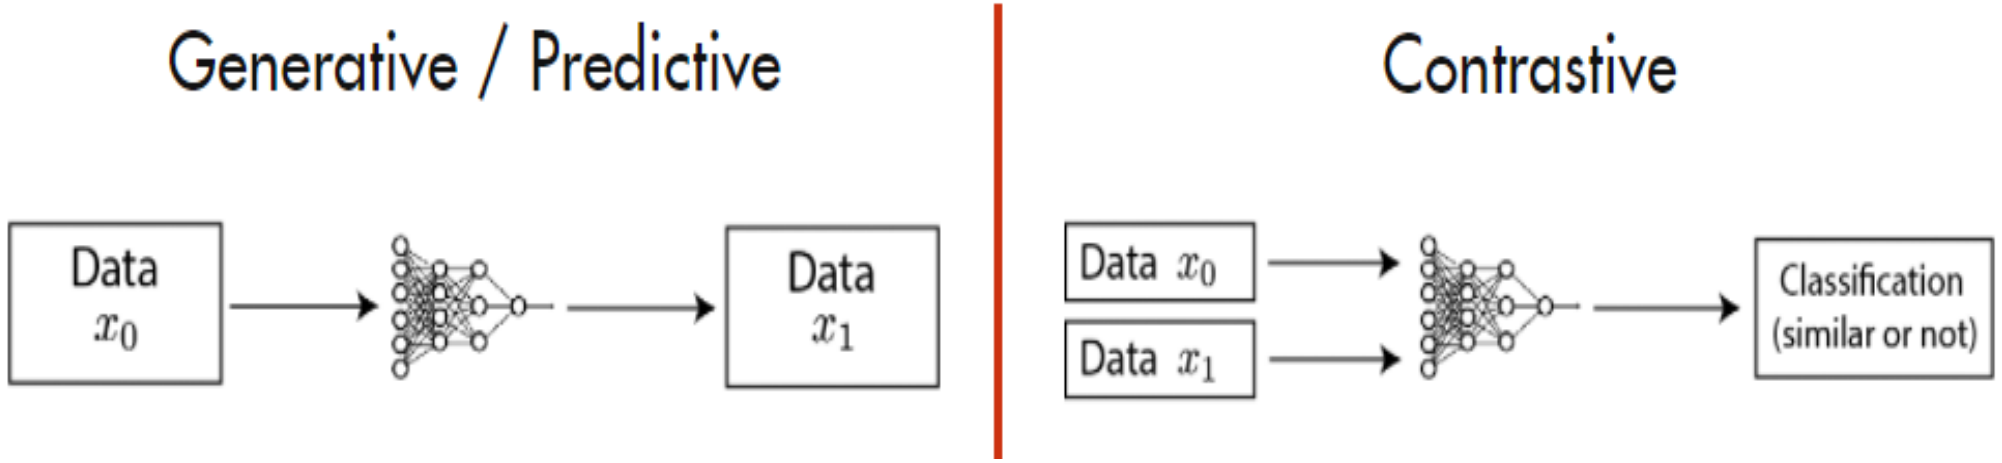
Entraînement d'un EBM

- Paramétrer F(x,y)
- Obtenir des données d'apprentissage (x[i], y[i])
- Paramétrer F(x,y) de sorte que :
  - F(x[i], y[i]) est strictement plus petit que F(x[i], y) pour tous les y différents de y[i]
- F est lisse (les méthodes probabilistes cassent cela !)
- **Deux classes de méthodes d'apprentissage** :
- Méthodes contrastives :
  - Pousser vers le bas l'énergie des points des données d'entraînement sur F(x[i], y[i]), pousser vers le haut l'énergie sur d'autres points F(x[i], y').
- Méthodes architecturales :
  - Construire une fonction énergie F(x,y) de manière à limiter ou minimiser le volume des régions à faible énergie en appliquant une régularisation.





Méthodes génératives vs contrastives



Perte mesurée dans l'espace de sortie
Exemples: colorisation, auto-encodeurs

Perte mesurée dans l'espace de représentation
Exemples: TCN, CPC, Deep-InfoMax

Comment fonctionnent les méthodes contrastives?

- Plus formellement, pour tout point de données X, les méthodes contrastives visent à apprendre un encodeur F tel que:

$$\text{score}(f(x), f(x^+)) >> \text{score}(f(x), f(x^-))$$

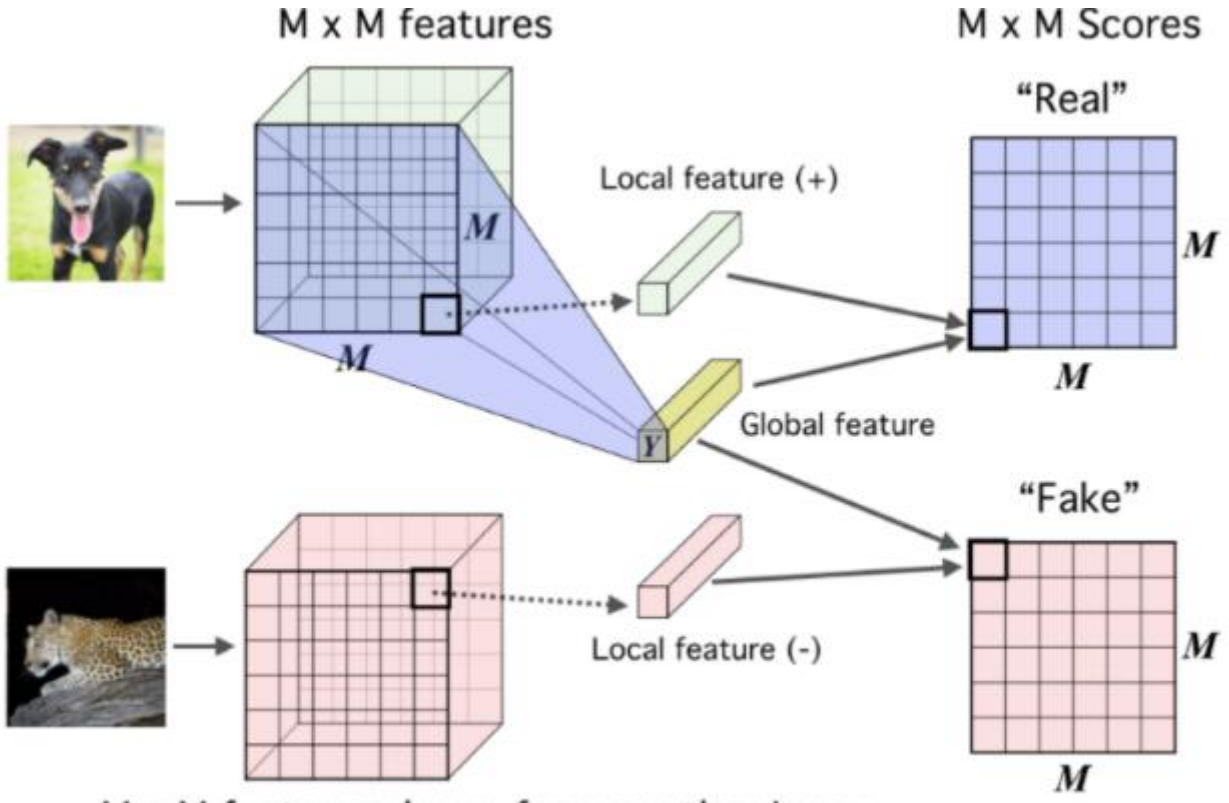
données est-il similaire a X

échantillons positifs

échantillon *négatif*

Exemple : InfoMax profond

- Deep InfoMax apprend les représentations d'images en exploitant la structure locale présente dans une image.
- La tâche contrastive derrière DIM est de classer si une paire de caractéristiques globales et de caractéristiques locales proviennent de la même image ou non.

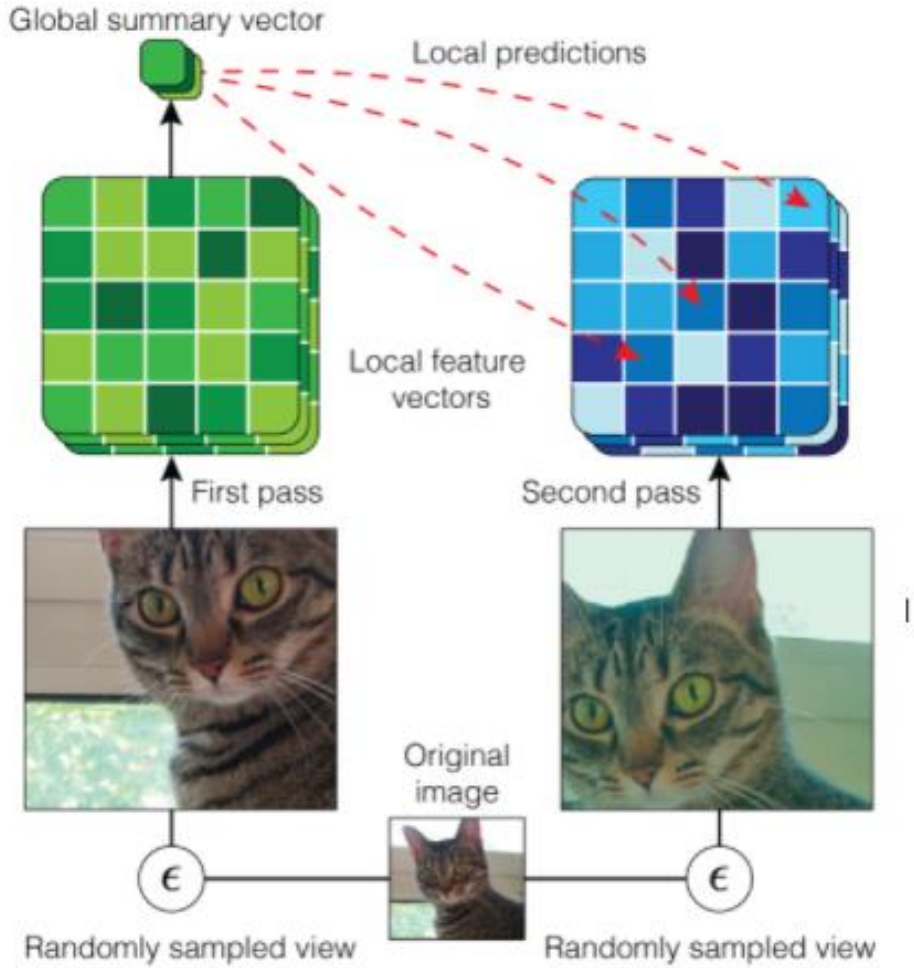


Source : https://arxiv.org/abs/1808.06670

les features globales sont la sortie finale d'un encodeur convolutif (un vecteur plat, Y) et les features locales sont la sortie d'une couche intermédiaire dans l'encodeur (un feature map M x M).

Apprentissage des invariances avec apprentissage contrasté

- *AMDIM apprend des représentations qui sont invariantes à travers les augmentations de données telles que le recadrage aléatoire.*

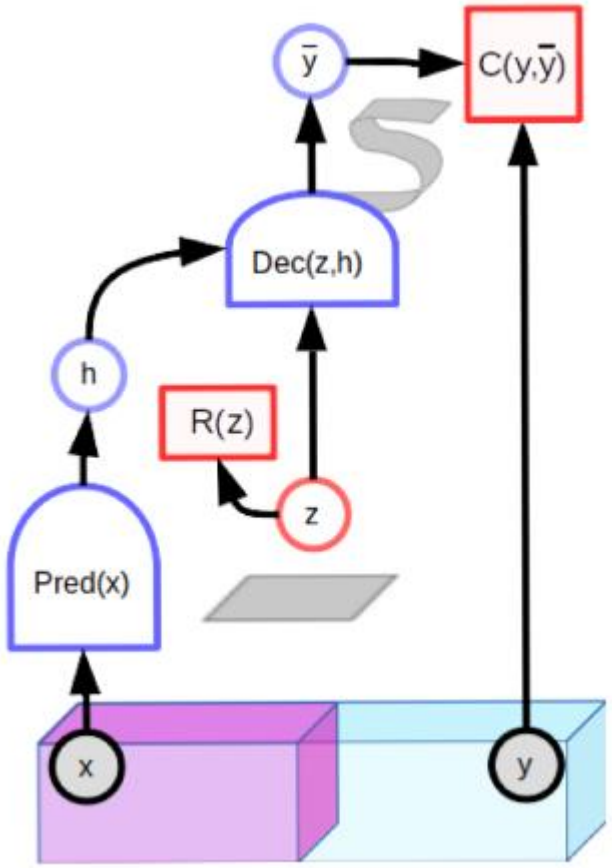


Augmented Multiscale DIM (AMDIM, Bachman et al., 2019) utilise des techniques d'augmentation de données standard comme l'ensemble de transformations auquel une représentation doit être invariante.

Exemple : Latent-Variable EBM

- Les modèles prédictifs à variable latente contiennent une variable d'entrée supplémentaire (z). Il est appelé latent car sa valeur n'est jamais observée.
- Permettre des prédictions multiples par le biais d'une variable latente
- Permettre l'inférence par minimisation
- Prédiction structurée
- Comme z varie sur un ensemble, y varie sur la multitude de prédictions possibles.

$$F(x, y) = min_z E(x, y, z)$$



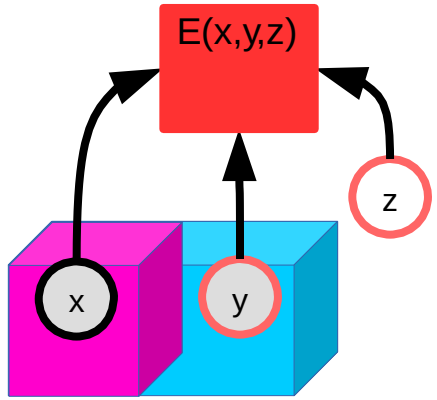
Latent-Variable EBM

- **Allowing multiple predictions through a latent variable**

- **Conditional:**

$$F(x,y)=min_z E(x,y,z)$$

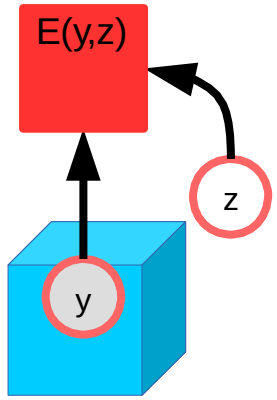
$$F(x,y)=-\frac{1}{\beta}\log\left[\int_z \exp(-\beta E(x,y,z))\right]$$



- **Unconditional**

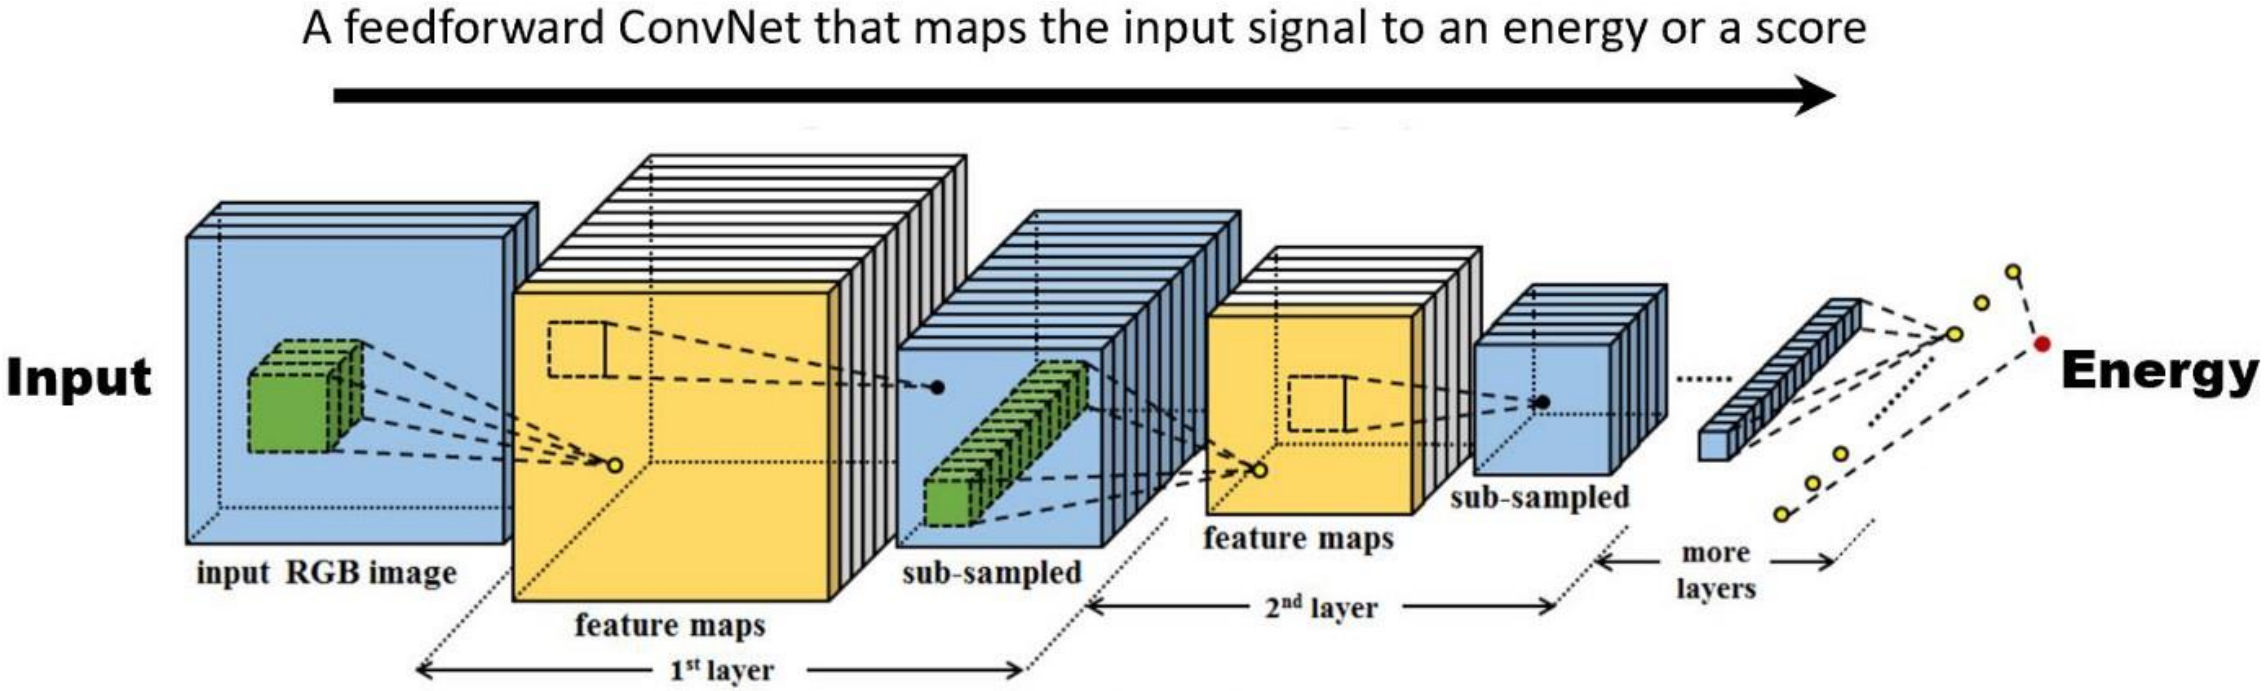
$$F(y)=min_z E(y,z)$$

$$F(y)=-\frac{1}{\beta}\log\left[\int_z \exp(-\beta E(y,z))\right]$$



Utilisation d'un réseau de neurones comme fonction énergétique

« A Theory of Generative ConvNet (ICML 2016)»



Le ConvNet prend une image en entrée et la mappe à un **scalaire** en tant qu'énergie par calcul par anticipation, où tous les paramètres de ce ConvNet seront formés par estimation de vraisemblance maximale (MLE) sans s'appuyer sur des étiquettes de classe

$$p(\mathrm{I}; w) = \frac{1}{Z(w)} \exp\left[-U(\mathrm{I}; w)\right]$$

(Step 1) Sampling gradient **(Langevin dynamics)**

$$\tilde{\mathrm{I}}_{\tau+1} = \tilde{\mathrm{I}}_{\tau} - \delta \frac{\partial}{\partial \tilde{\mathrm{I}}} U(\tilde{\mathrm{I}}_{\tau}; w) + \sqrt{2\delta}\epsilon_{\tau}$$

Langevin to synthesiz

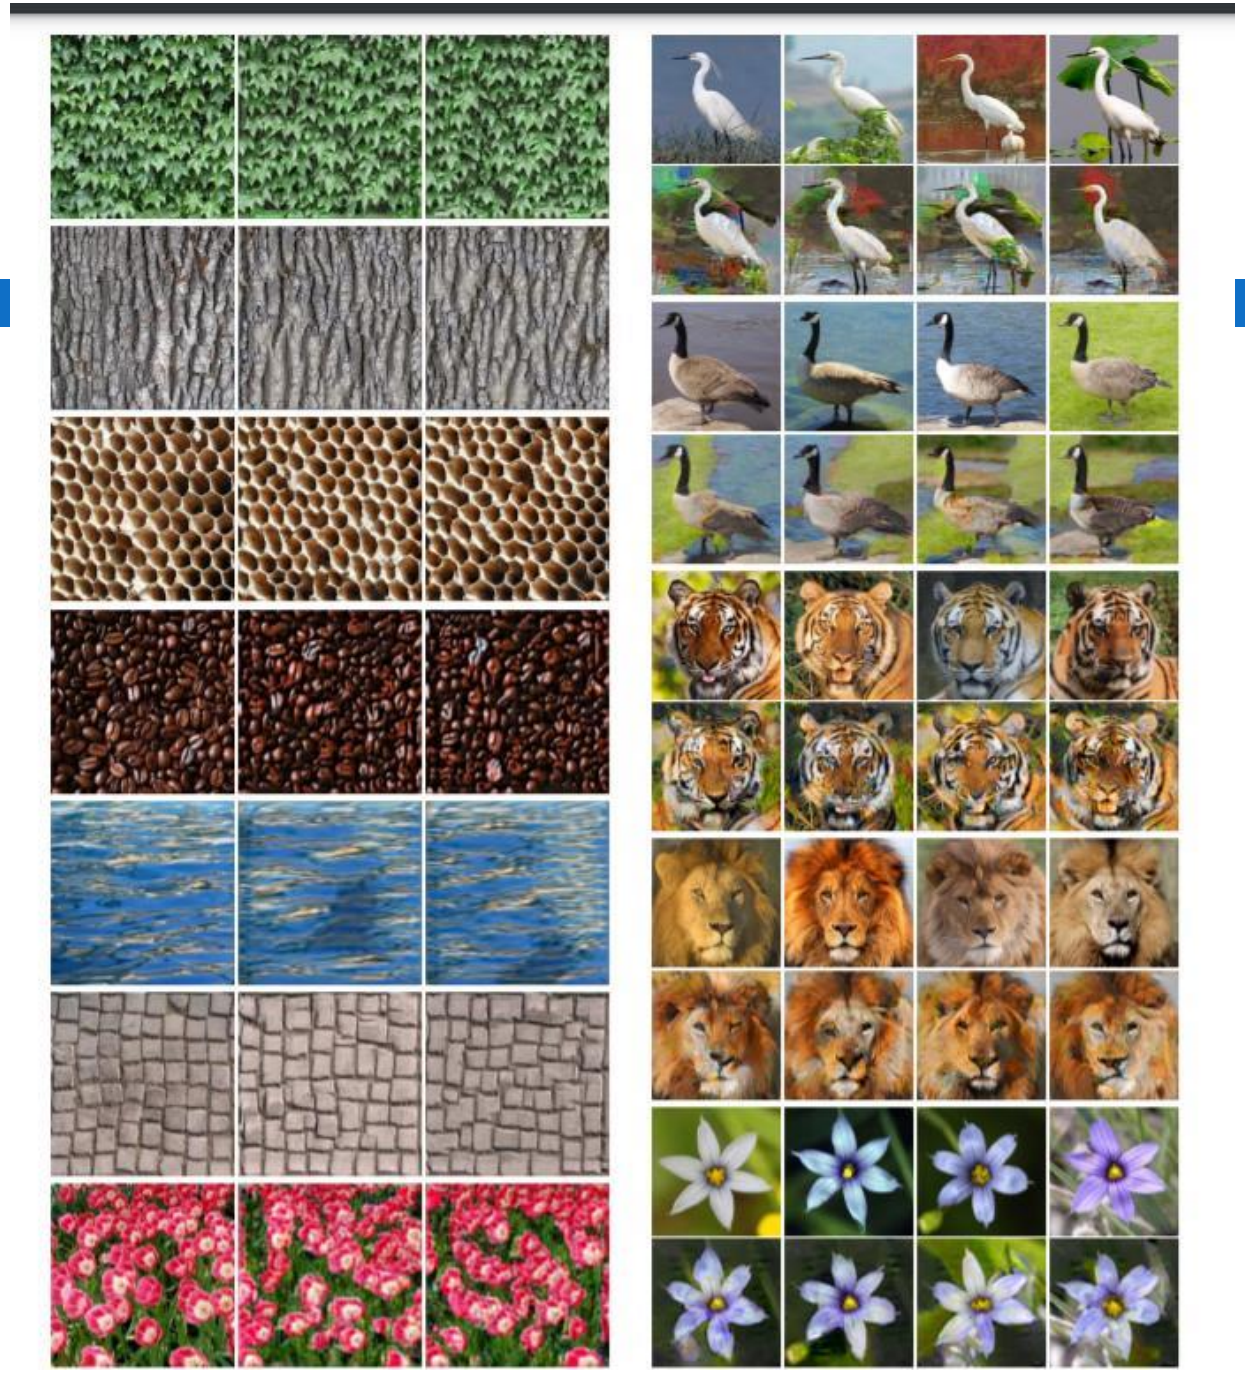
(Step 2) Learning gradient **(MLE)**

$$L'(w) = \frac{1}{\tilde{n}} \sum_{i=1}^{\tilde{n}} \frac{\partial}{\partial w} U(\tilde{\mathrm{I}}_i; w) - \frac{1}{n} \sum_{i=1}^{n} \frac{\partial}{\partial w} U(\mathrm{I}_i; w)$$

synthesized observed

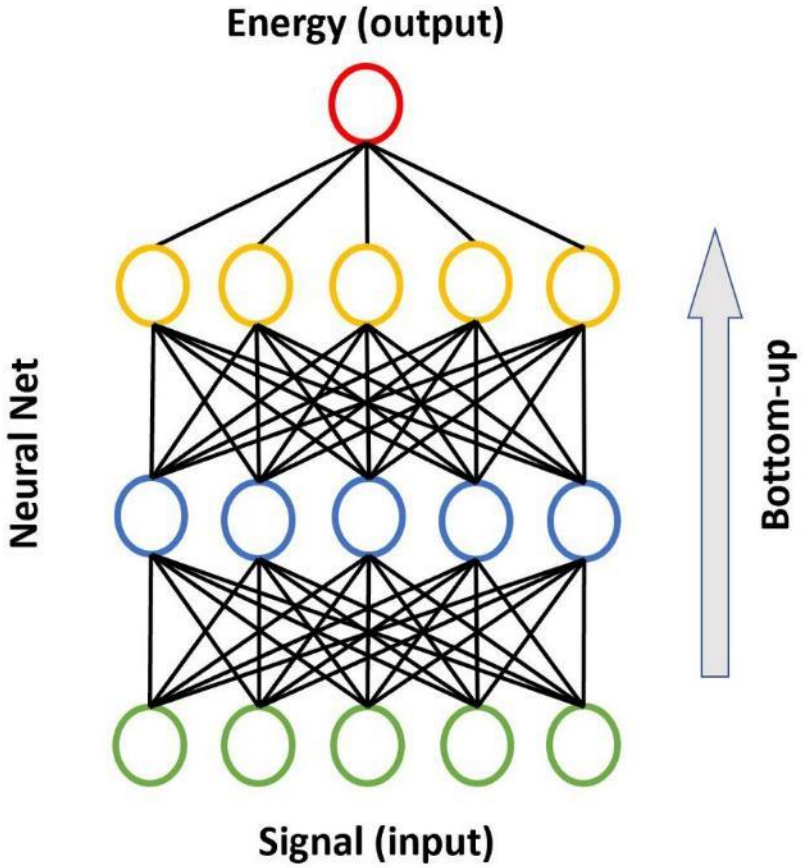
- Le modèle est formé par l'estimation du maximum de vraisemblance basée sur la dynamique de Langevin, qui itère (1) **Étape d'échantillonnage** : synthétiser de nouveaux exemples via la dynamique de Langevin à partir de le modèle actuel, et (2) **l'étape d'apprentissage**: mise à jour des paramètres du modèle par apprentissage par maximum de vraisemblance, où le gradient prend la forme de la différence entre les exemples observés et les exemples synthétisés.

Résultats



Réseau neuronal génératif basé sur l'énergie

- un nouveau cadre de modèle génératif,
- Il s'agit d'une nouvelle façon de former des réseaux de neurones profonds de manière non supervisée.



La fonction énergétique est paramétrée par un réseau neuronal profond

Generative PointNet: Deep Energy-Based Learning on Unordered Point Sets for 3D Generation, Reconstruction and Classification (2021)

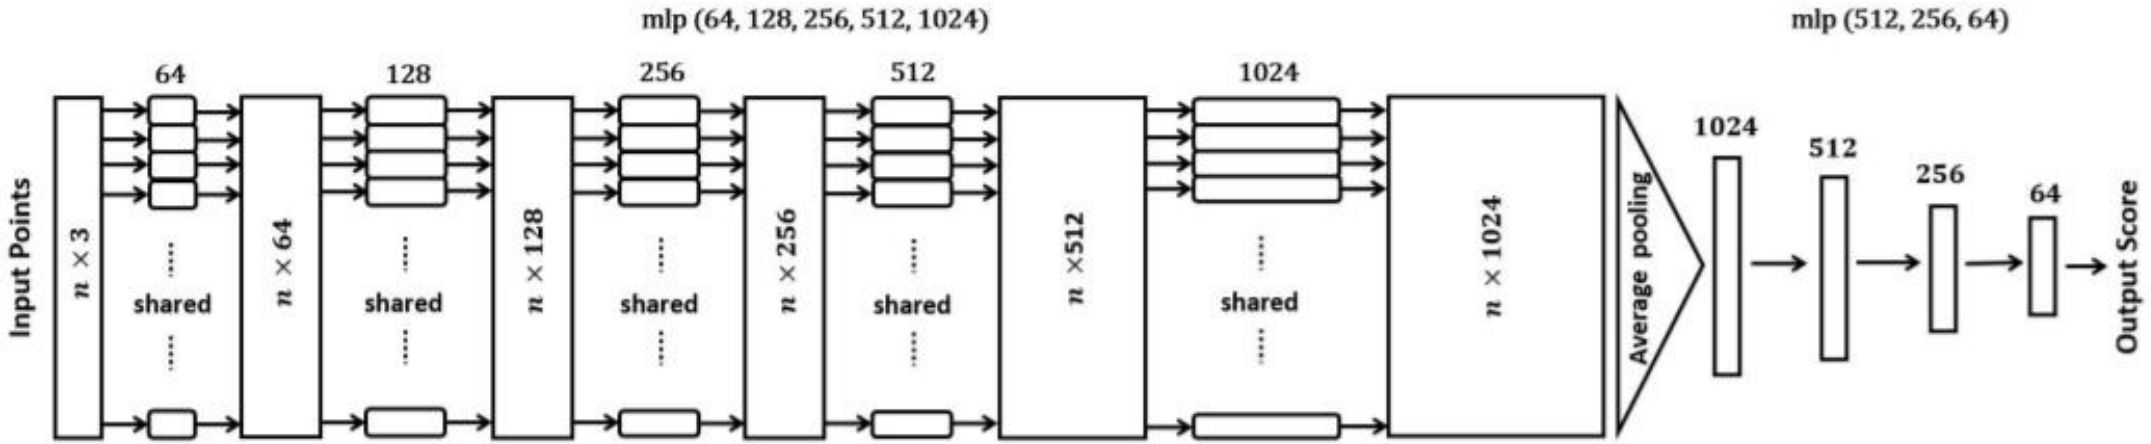


Figure 1: Architecture of the scoring function of the Generative PointNet. The scoring function $f_\theta(X)$ is an input-permutation-invariant bottom-up deep network, which takes n unordered points as input, encodes each point into features by multilayer perceptron (MLP) with numbers of channels 64, 128, 256, 512 and 1,024 at each layer respectively, and then aggregates all point features to a global feature by average pooling, and eventually outputs scalar energy by multilayer perceptron with numbers of channels 512, 256, 64 and 1 at each layer respectively. Layer Normalization [2] is used with ReLU for layers before average pooling, while only ReLU is used for layers after average pooling.

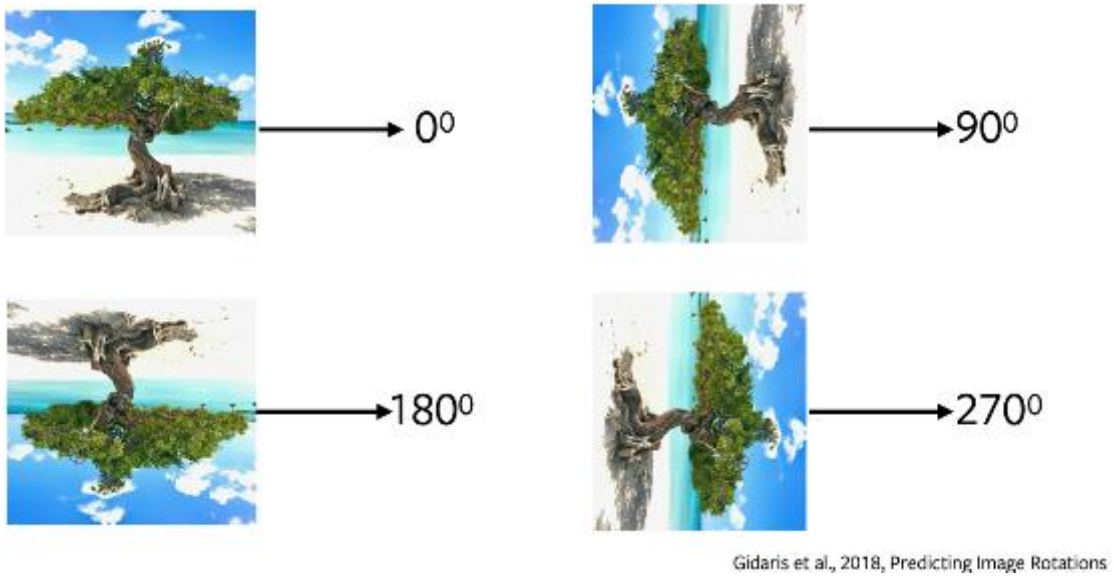
Réseau coopératif génératif

Exemples



Prévoir la rotation des images

- Au lieu d'étiqueter les images, nous pourrions plutôt les faire pivoter de 0/90/180/270 degrés et entraîner un modèle à prédire la rotation.



Gidaris et al., 2018, Predicting Image Rotations

Exemple

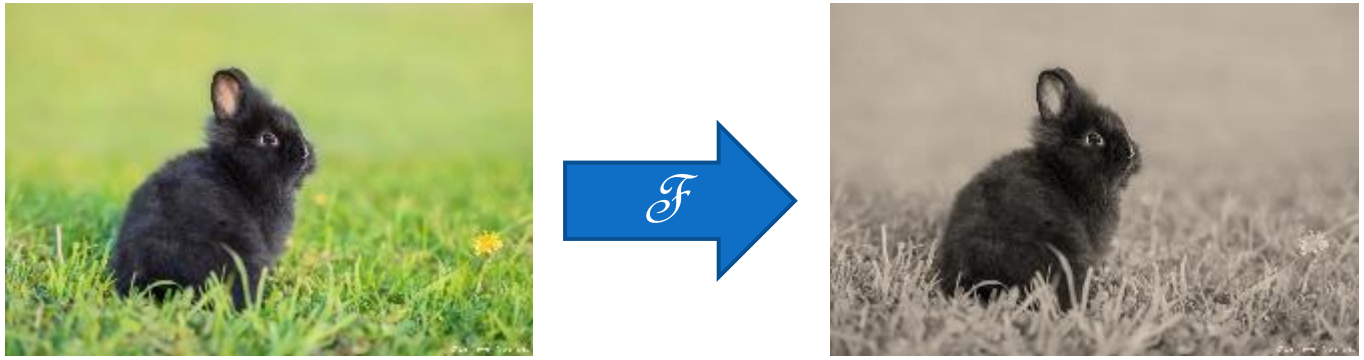




- Pour la reconnaissance d'image, le modèle prend deux images, x et y, comme entrées.
- Si x et y sont des versions légèrement déformées de la même image, le modèle est entraîné pour produire une faible énergie sur sa sortie.
- Par exemple, x pourrait être une photo d'un lapin et une photo du même lapin qui a été prise à un endroit légèrement différent à une heure différente de la journée, de sorte que la photo soit décalée, tournée, plus grande, plus petite et affichant des couleurs et des ombres légèrement différentes de celles du lapin en x.

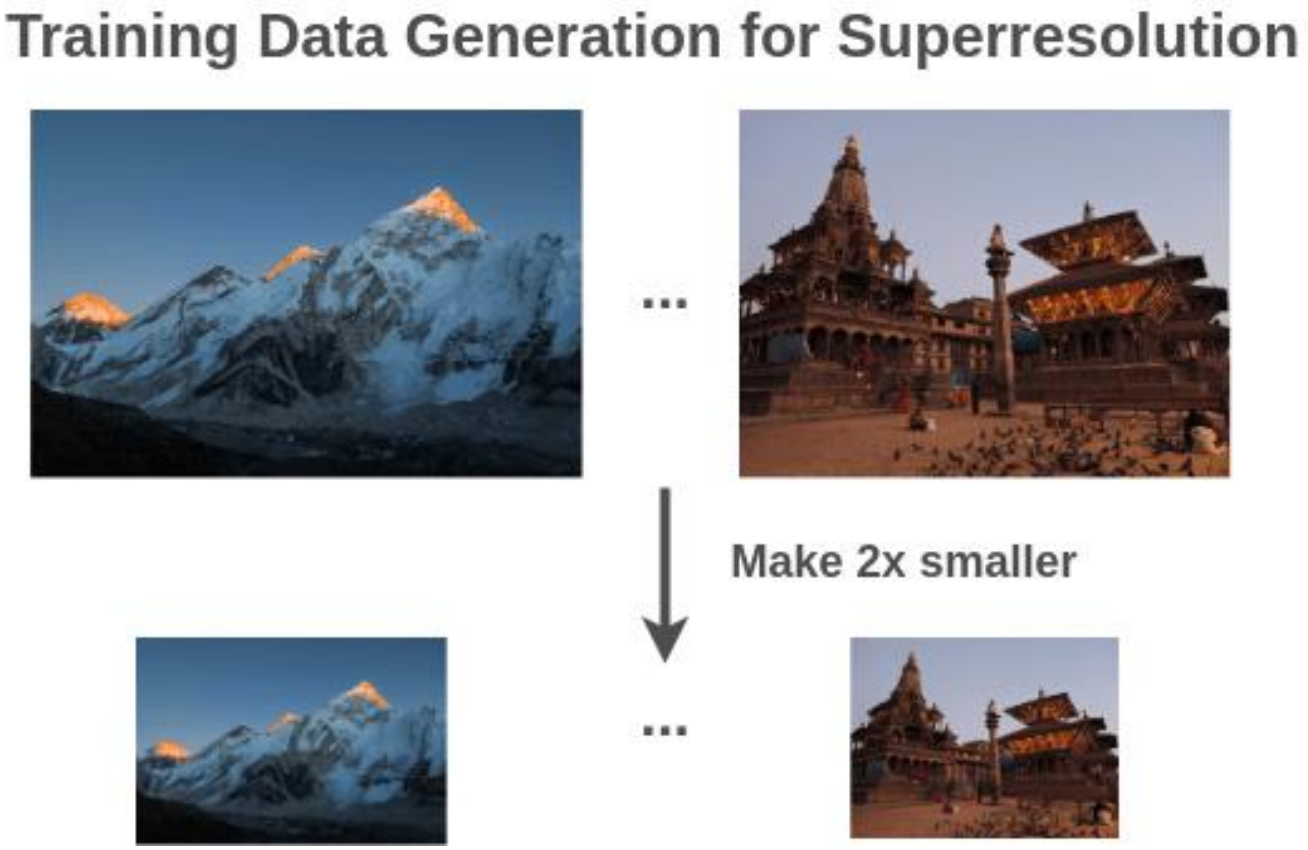
Colorisation

- Dans cette tâche de prétexte, on prédit les couleurs d'une image grise.
- Elle peut être formulée pour n'importe quelle image, il suffit d'enlever la couleur et d'alimenter le réseau avec cette image en niveaux de gris pour prédire sa couleur.



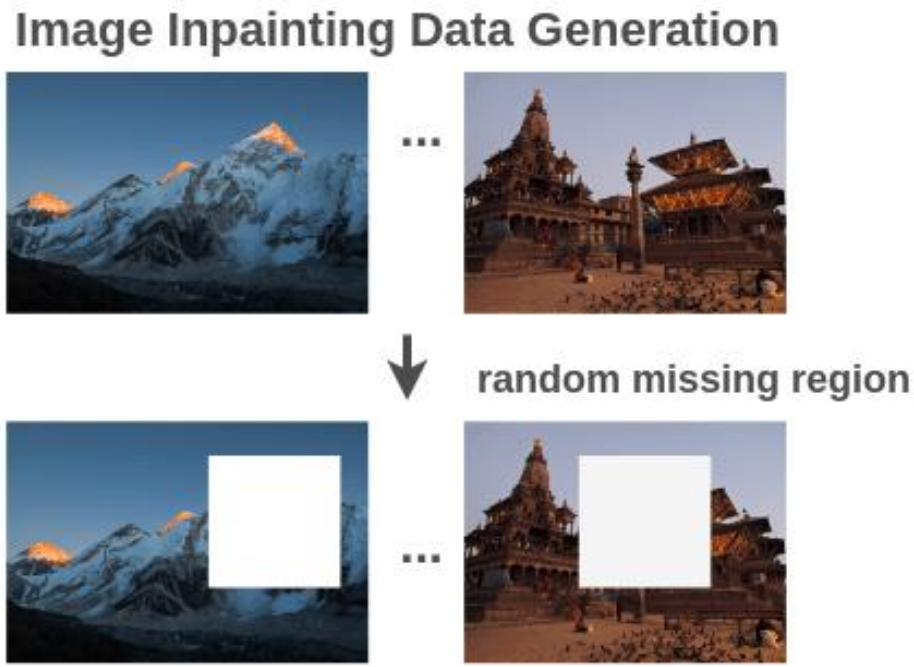
Super-résolution d'image

- *des paires de formation d'images (petites, à grande échelle)*



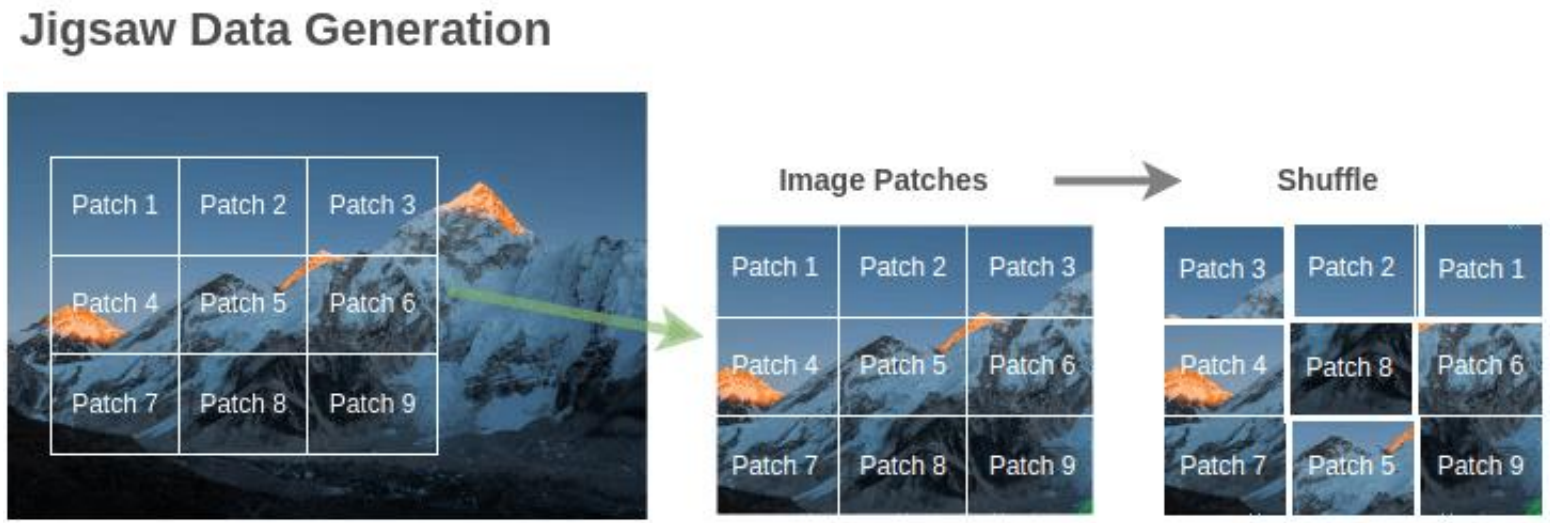
Inpainting d'imag

- *Des paires de formation d'images (corrompues, corrigées) en supprimant aléatoirement une partie des images*



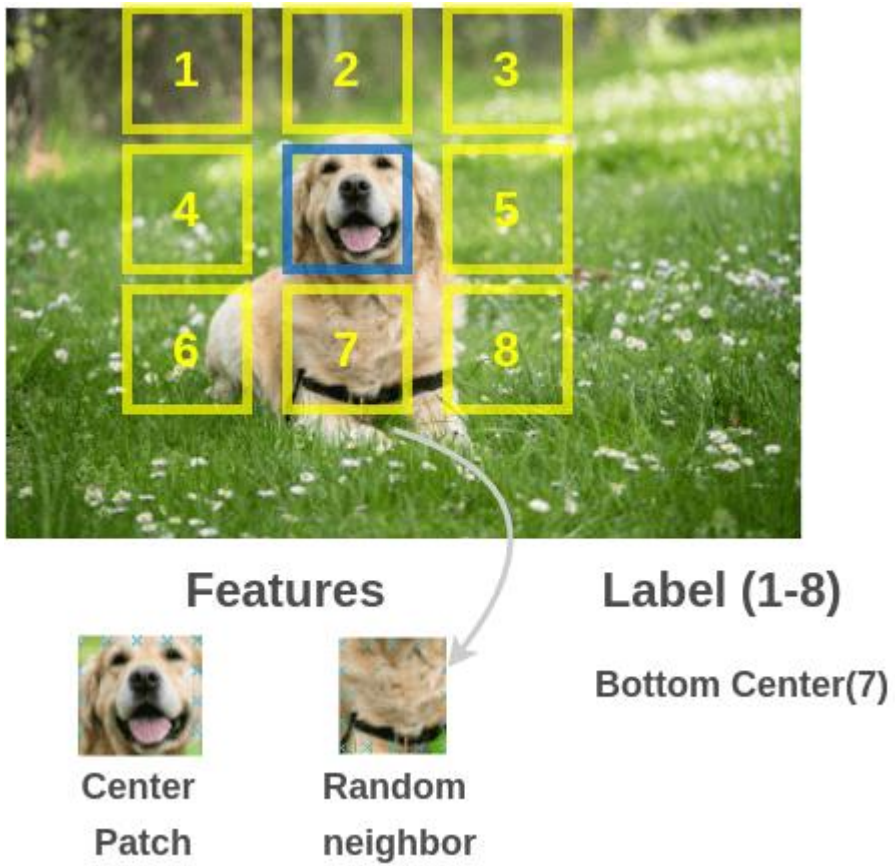
Puzzle d'image

- *Des paires d'entraînement de puzzles (mélangés, ordonnés) en mélangeant aléatoirement des patchs d'images*



Prédiction du contexte

- *paires d'entraînement de (image-patch, voisin) en prenant au hasard un patch d'image et l'un de ses voisins autour de lui à partir d'une grande collection d'images non étiquetées*



Cette Illustration est basé sur The Ilustrated SimCLR Framework,Amit Chaudhary
https://amitness.com/2020/03/illustrated-simclr/

SimCLR Framework : une illustration

9v3 [cs.LG] 1 Jul 2020

A Simple Framework for Contrastive Learning of Visual Representations

Ting Chen [1] Simon Kornblith [1] Mohammad Norouzi [1] Geoffrey Hinton [1]

Abstract

This paper presents *SimCLR*: a simple framework for contrastive learning of visual representations. We simplify recently proposed contrastive self-supervised learning algorithms without requiring specialized architectures or a memory bank. In order to understand what enables the contrastive prediction tasks to learn useful representations, we systematically study the major components of our framework. We show that (1) composition of data augmentations plays a critical role in defining effective predictive tasks, (2) introducing a learnable nonlinear transformation between the representation and the contrastive loss substantially improves the quality of the learned representations, and (3) contrastive learning benefits from larger batch sizes and more training steps compared to supervised learning. By combining these findings, we are able to considerably outperform previous

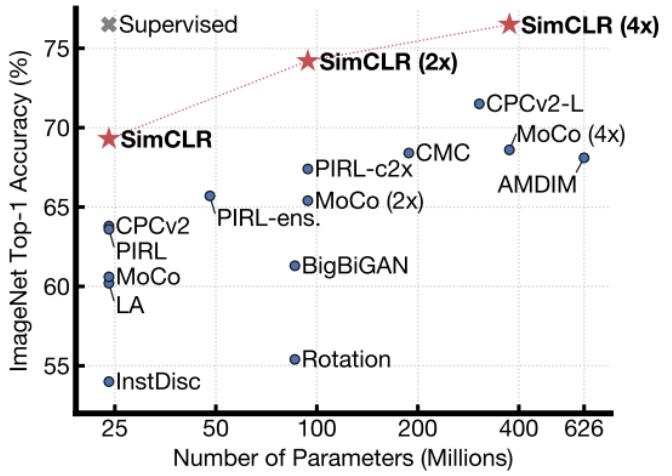
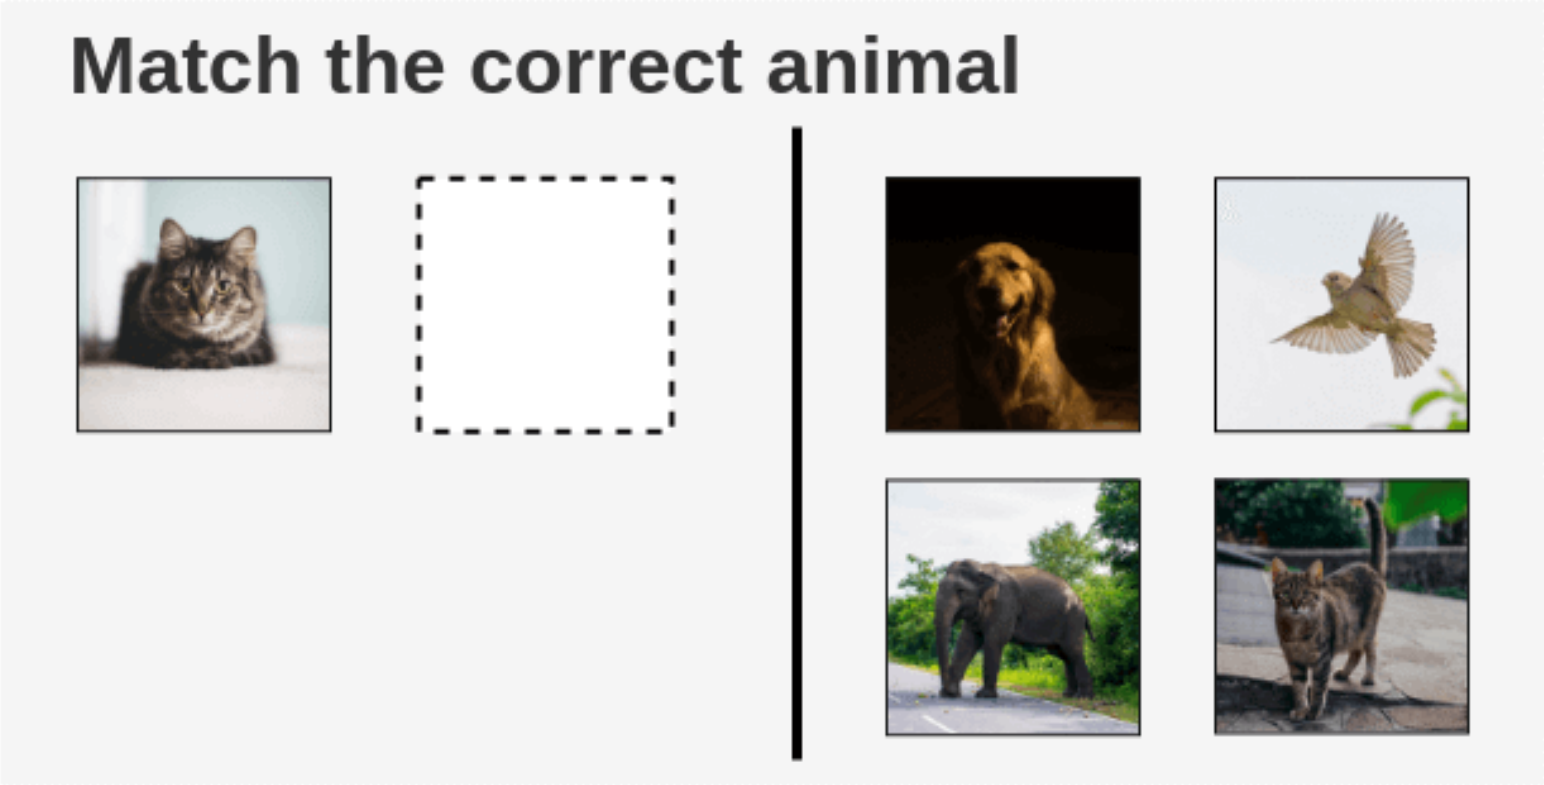


Figure 1. ImageNet Top-1 accuracy of linear classifiers trained on representations learned with different self-supervised methods (pretrained on ImageNet). Gray cross indicates supervised ResNet-50. Our method, SimCLR, is shown in bold.

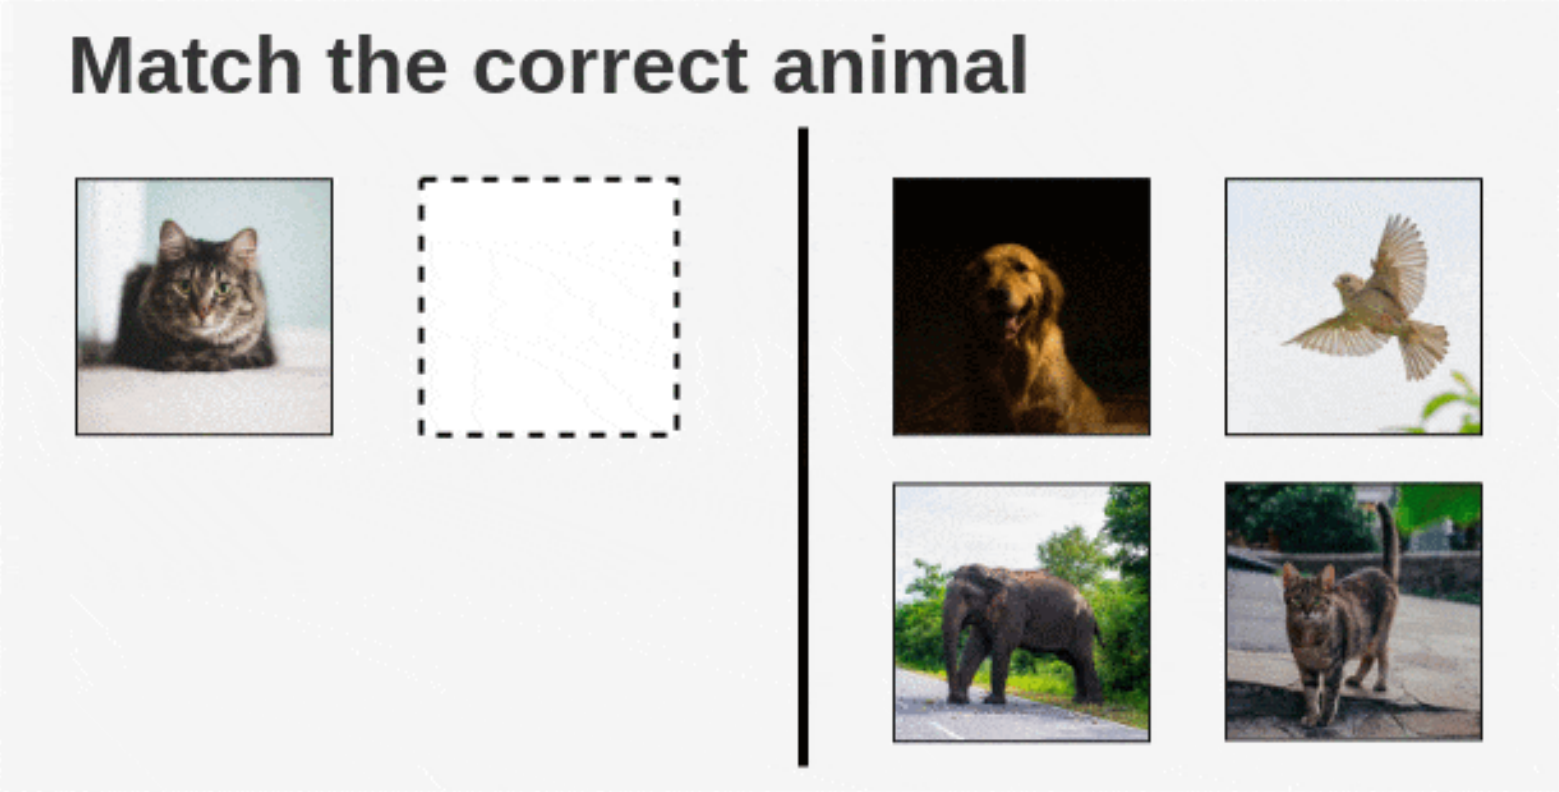
However, pixel-level generation is computationally expen

Exercice



De tels exercices ont été préparés pour que l'enfant puisse reconnaître un objet et le mettre en contraste avec d'autres objets. Pouvons-nous enseigner de la même manière les machines?

Exercice



De tels exercices ont été préparés pour que l'enfant puisse reconnaître un objet et le mettre en contraste avec d'autres objets. Pouvons-nous enseigner de la même manière les machines?

SimCLR

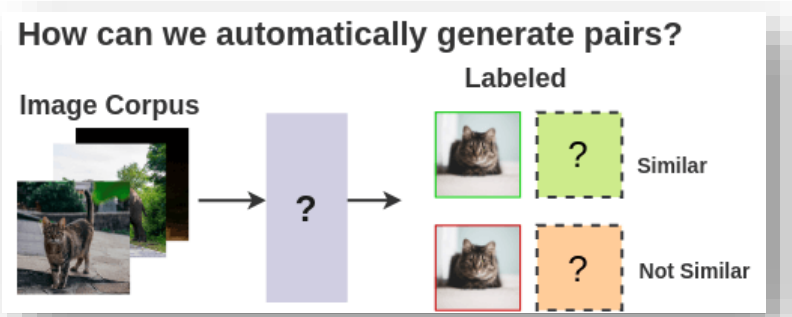
SimCLR tente d'apprendre aux machines à faire la distinction entre des choses similaires et différentes.



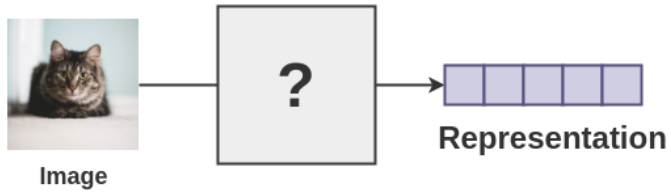
Besoins

- Pour modéliser l'exercice ci-dessus pour une machine au lieu d'un enfant, nous voyons que nous avons besoin de 3 choses:

1. **Exemples d'images similaires et différents**



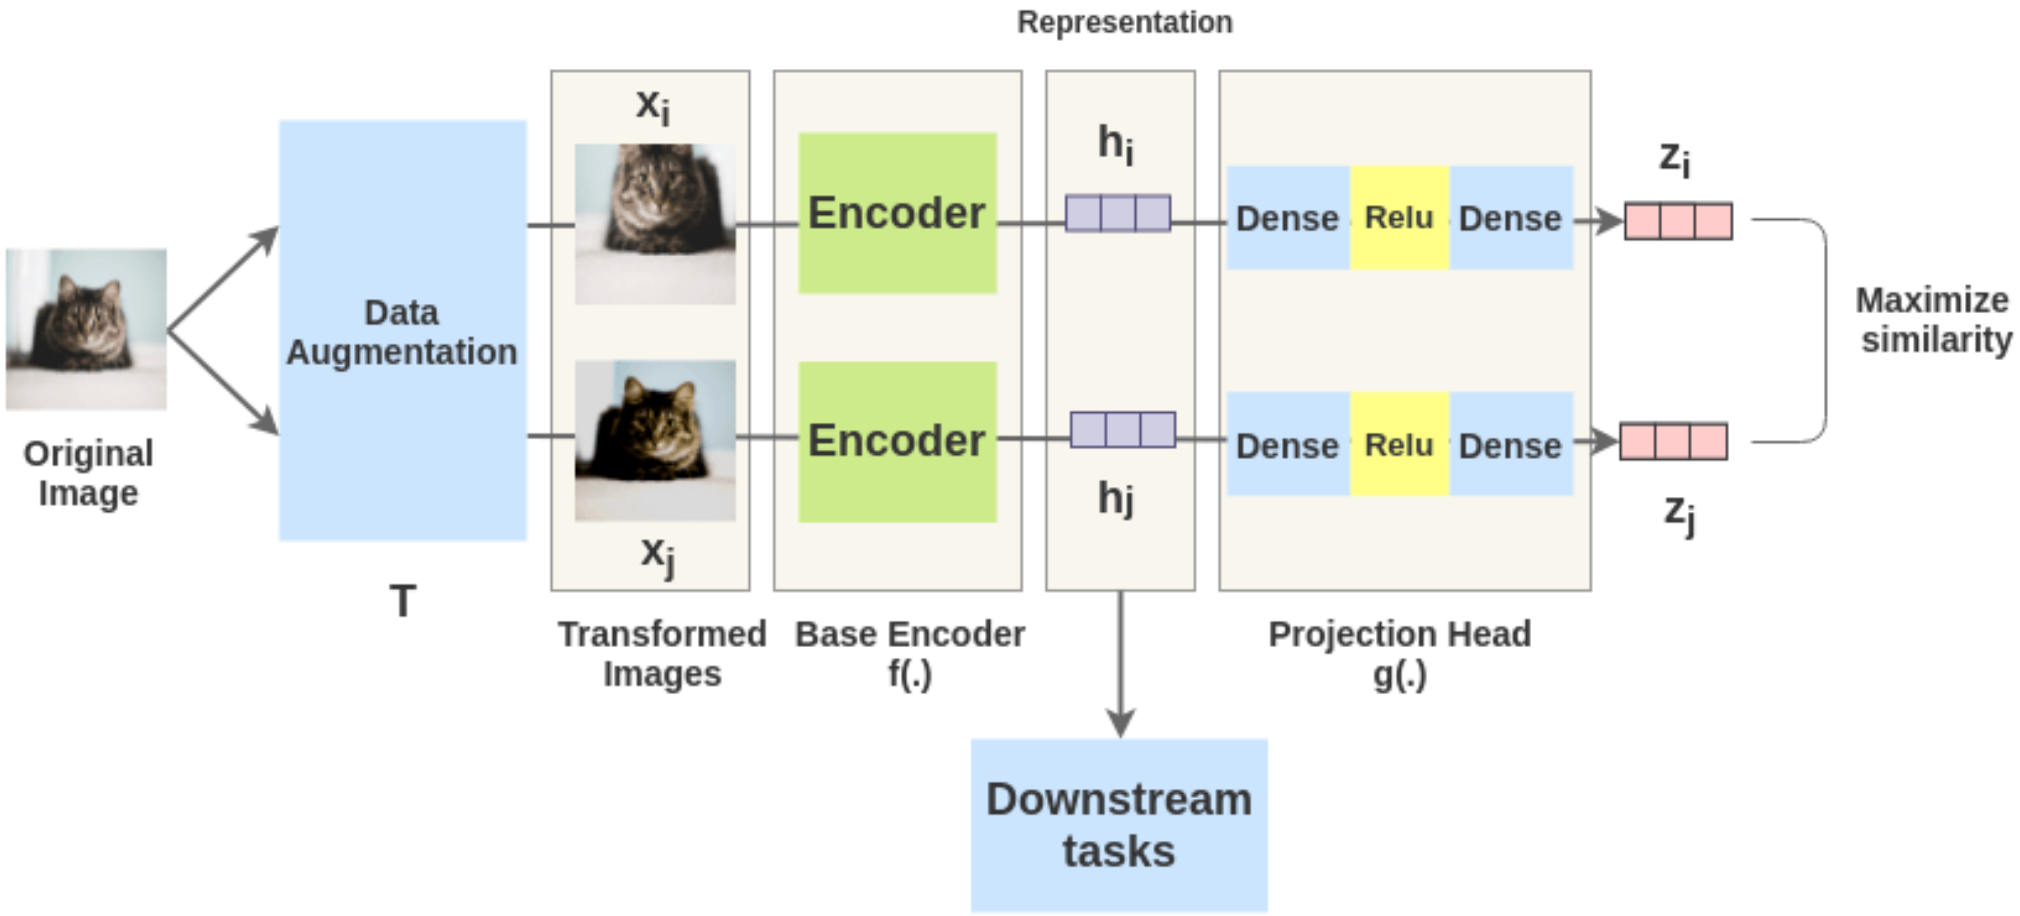
2. **Capacité de savoir ce que représente une image**



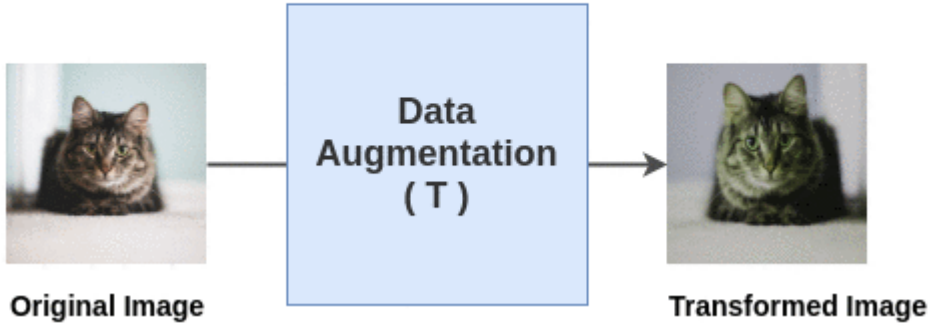
3. **Possibilité de quantifier si deux images sont similaires**



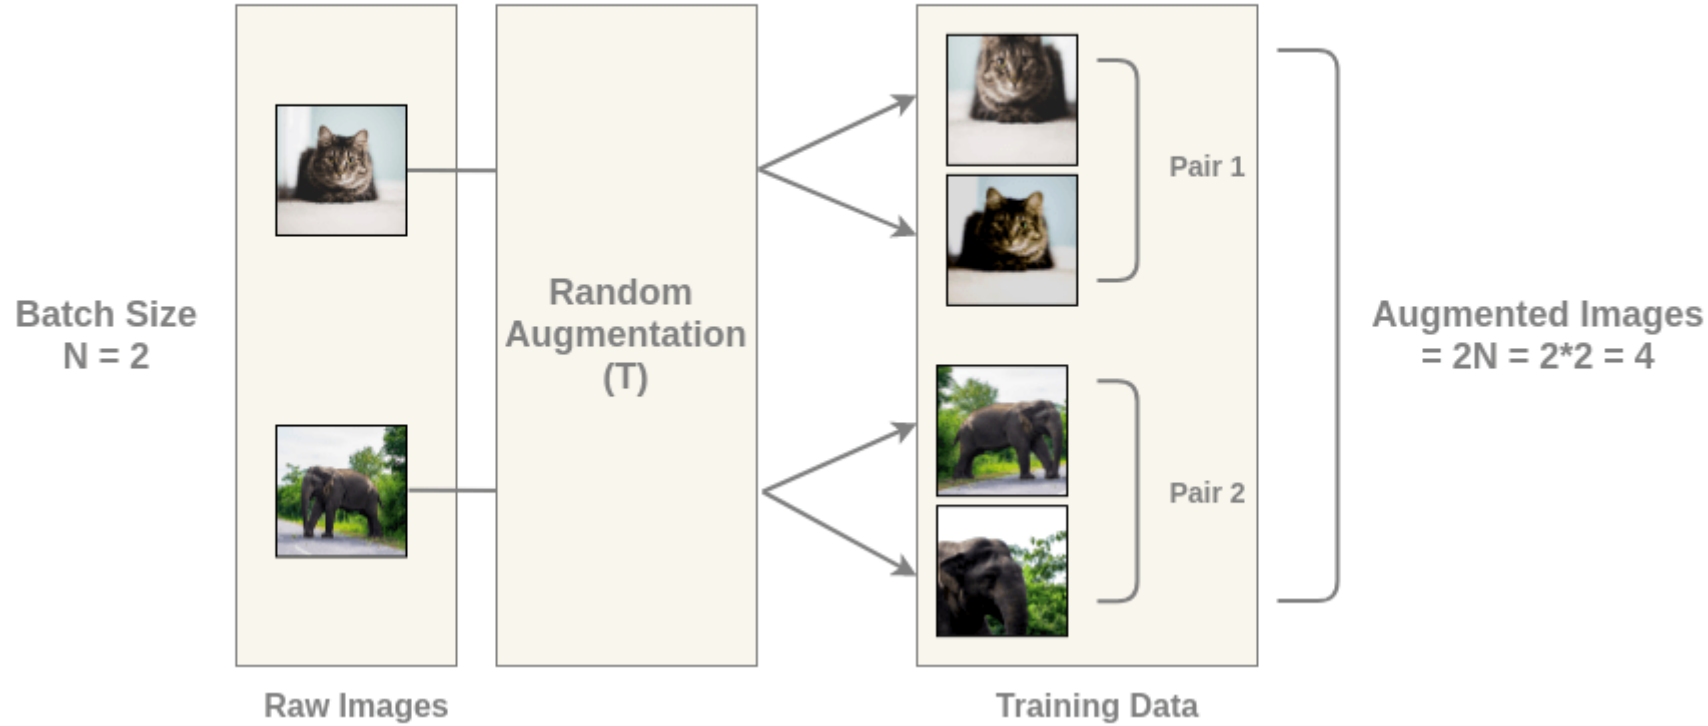
SimCLR Framework

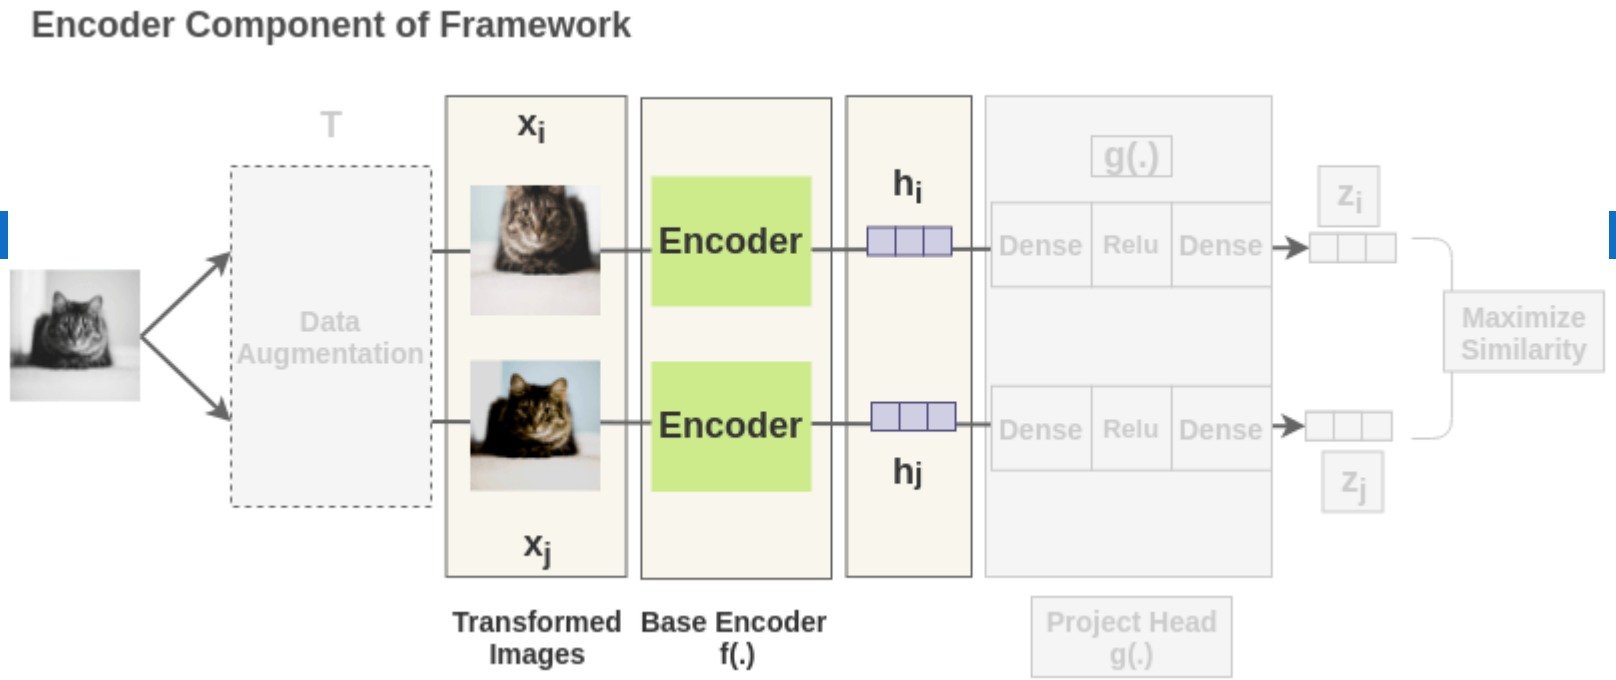


Random Transformation

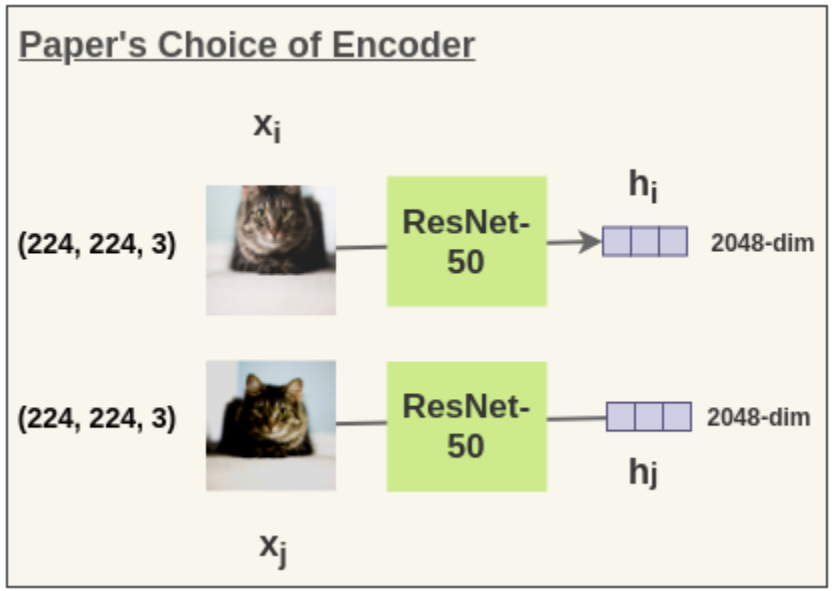


Preparing similar pairs in a batch

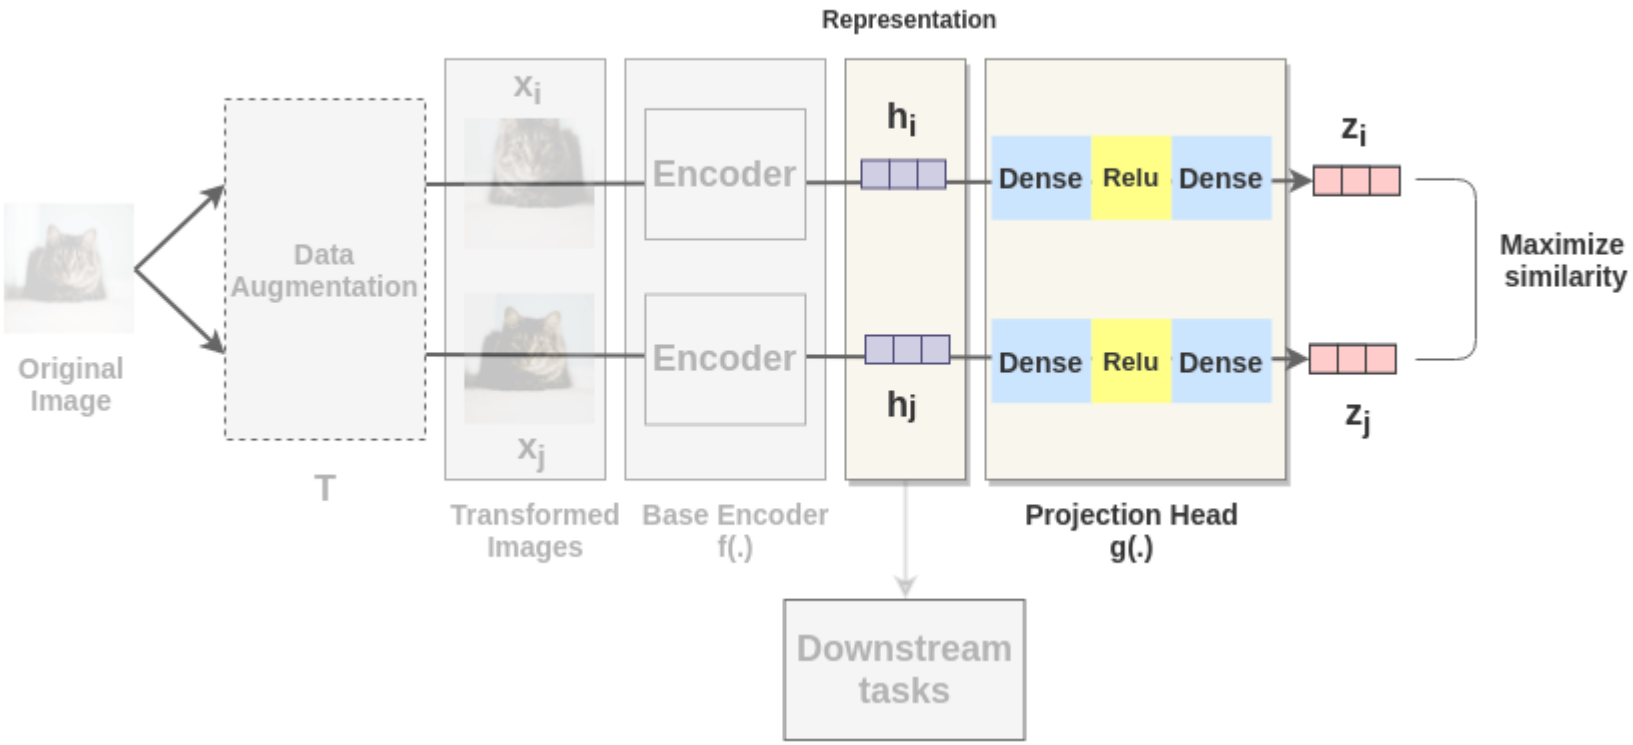




Dans l'article, les auteurs ont utilisé l' architecture ResNet-50 comme encodeur ConvNet. La sortie est un vecteur h de dimension 2048.



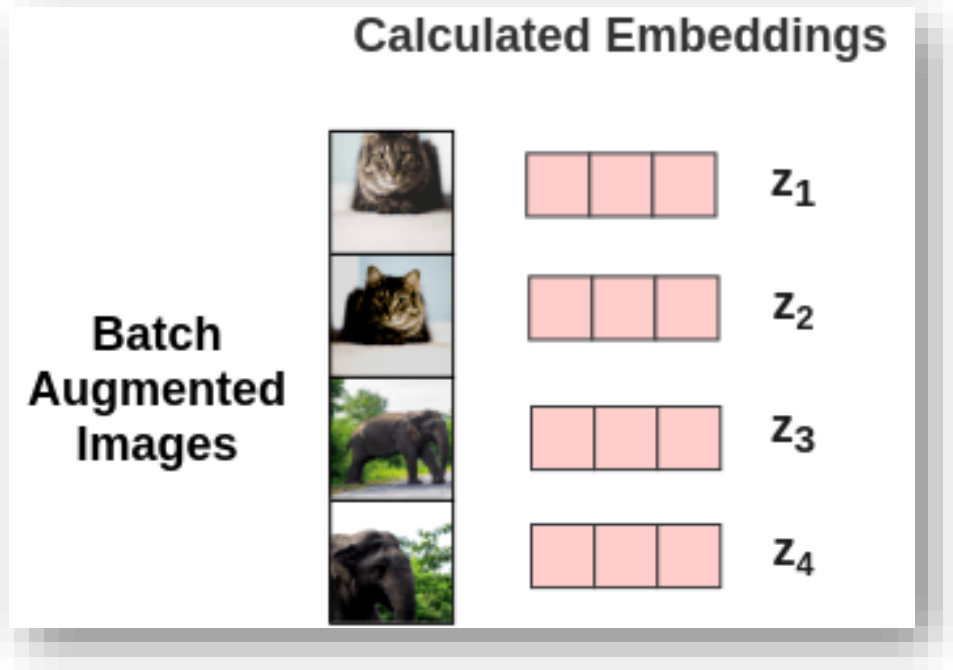
Projection Head Component



Les représentations hi et hj des deux images augmentées sont ensuite passées à travers une série de couches **Dense -> Relu -> Dense** pour appliquer une transformation non linéaire et la projeter dans une représentation zi et et zj.

Tuning Model

- Pour chaque image augmentée du lot, nous obtenons des vecteurs d'incorporation z.

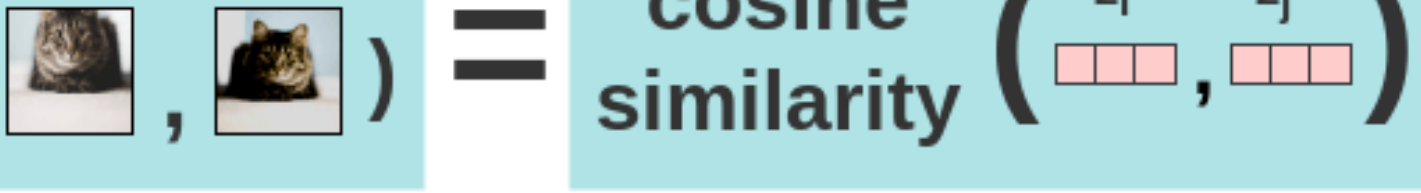


- À partir de ces incorporations, nous calculons la perte dans les étapes suivantes

Calcul de la similarité cosinus

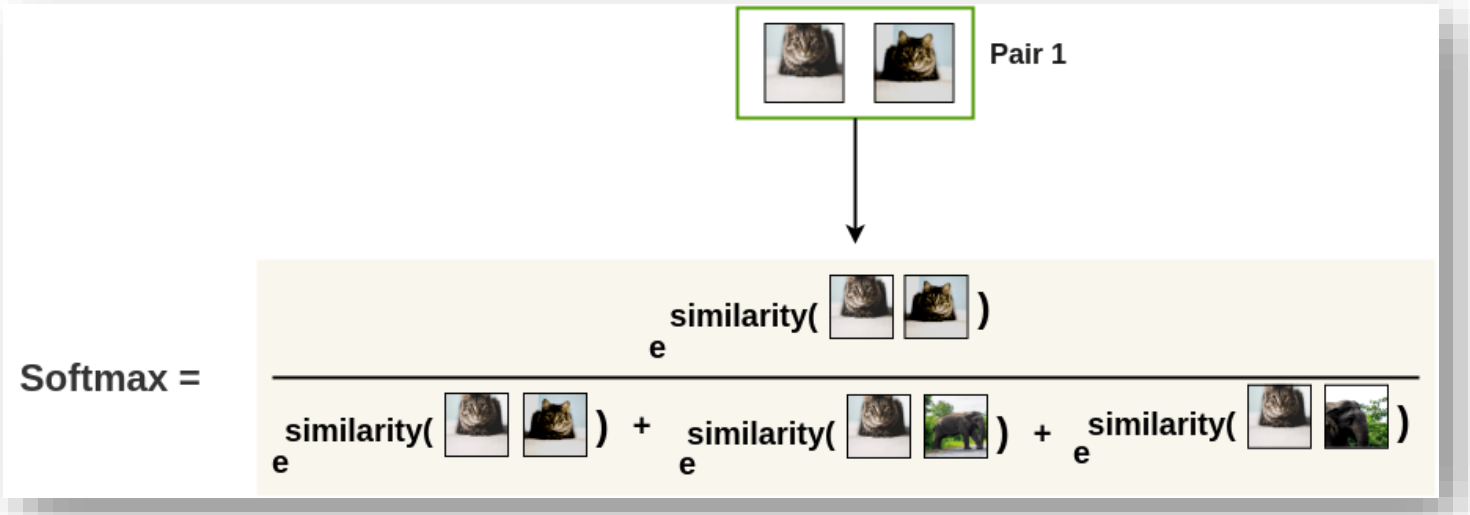
Similarity Calculation of Augmented Images

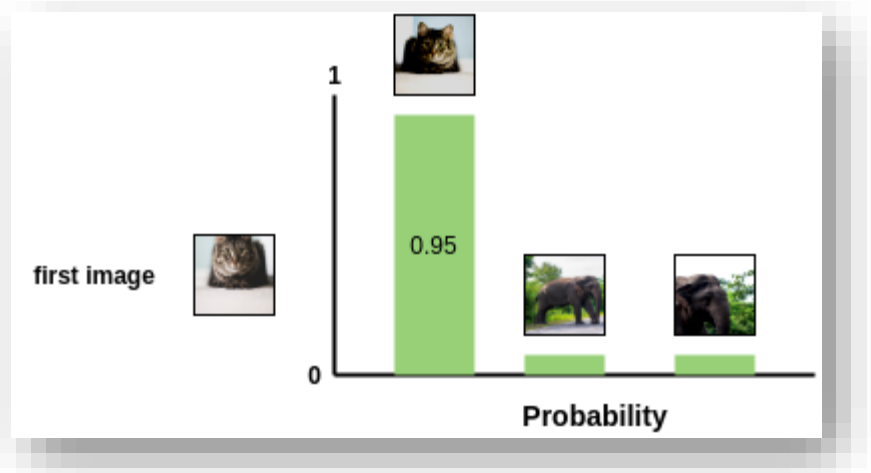
$$\text{similarity}(x_i, x_j) = \text{cosine similarity}(z_i, z_j)$$



Calcul des pertes

- SimCLR utilise une perte de contraste appelée « **NT-Xent loss** »
  (**Normalized Temperature-Scaled Cross-Entropy Loss**).
- Pour chaque paire du lot nous appliquons la fonction softmax pour obtenir la probabilité que ces deux images soient similaires.

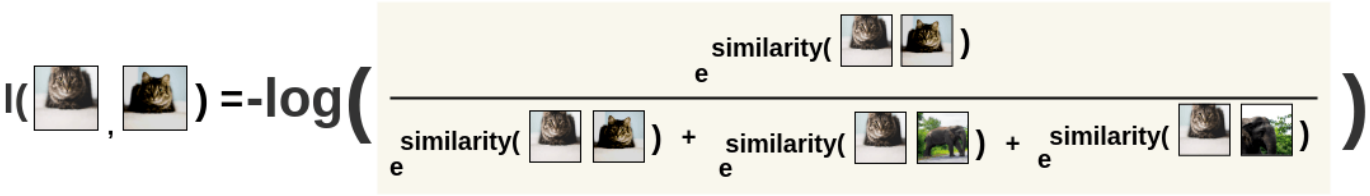




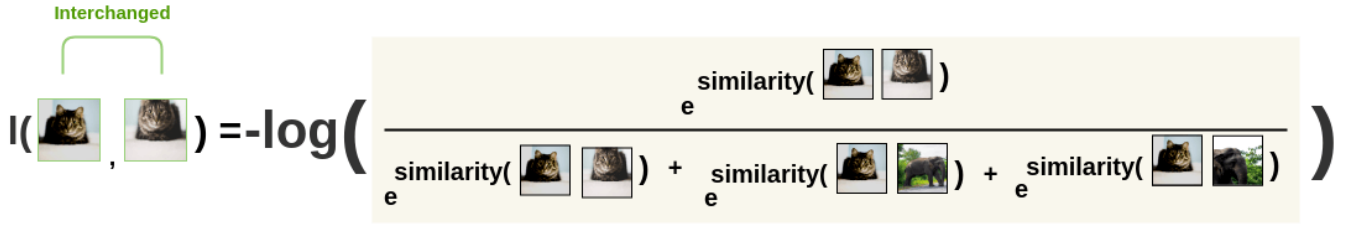
Calcul des pertes

- Ensuite, la perte est calculée pour une paire en prenant le négatif du log du calcul ci-dessus

$$l(je,j) = -log\frac{eXp(s_{je,j})}{\sum_{k=1}^{2N} l_{[k!=je]} eXp(s_{je,k})}$$

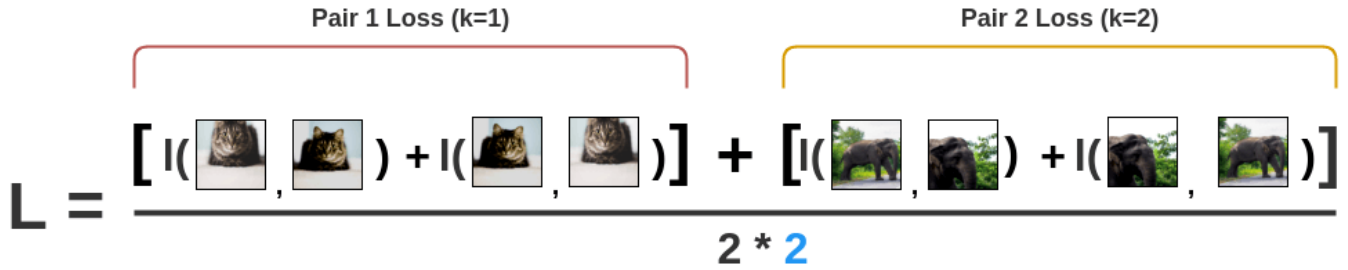


- Nous calculons également la perte pour la même paire une deuxième fois là où les positions des images sont interchangées.

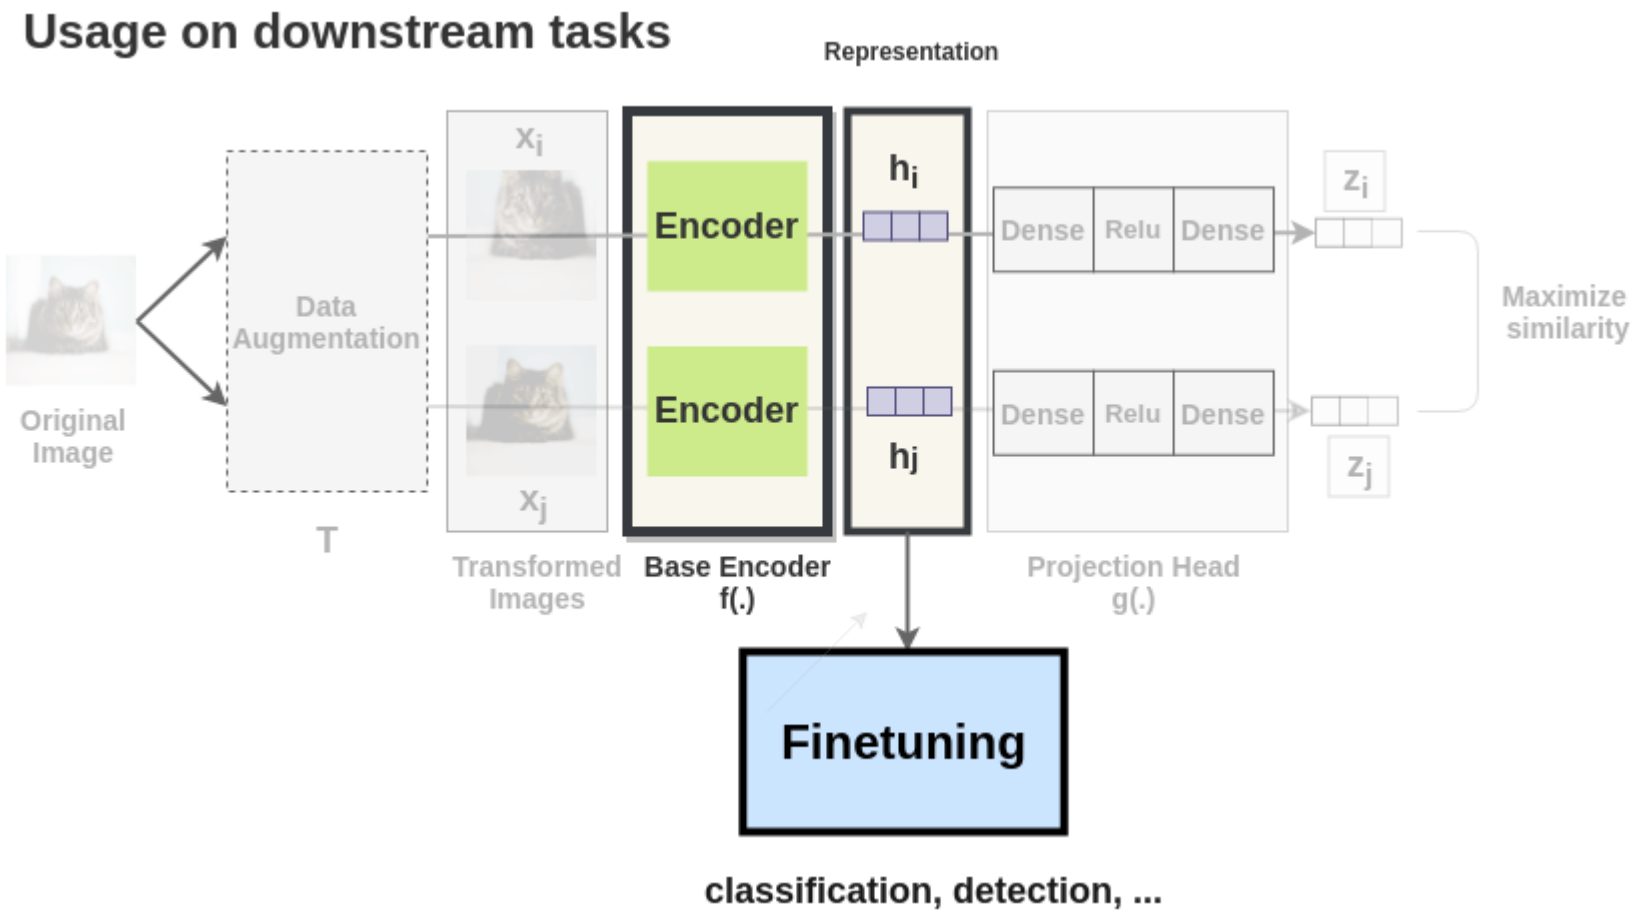


- Enfin, nous calculons la perte sur toutes les paires du lot de taille N = 2 et prenons une moyenne.

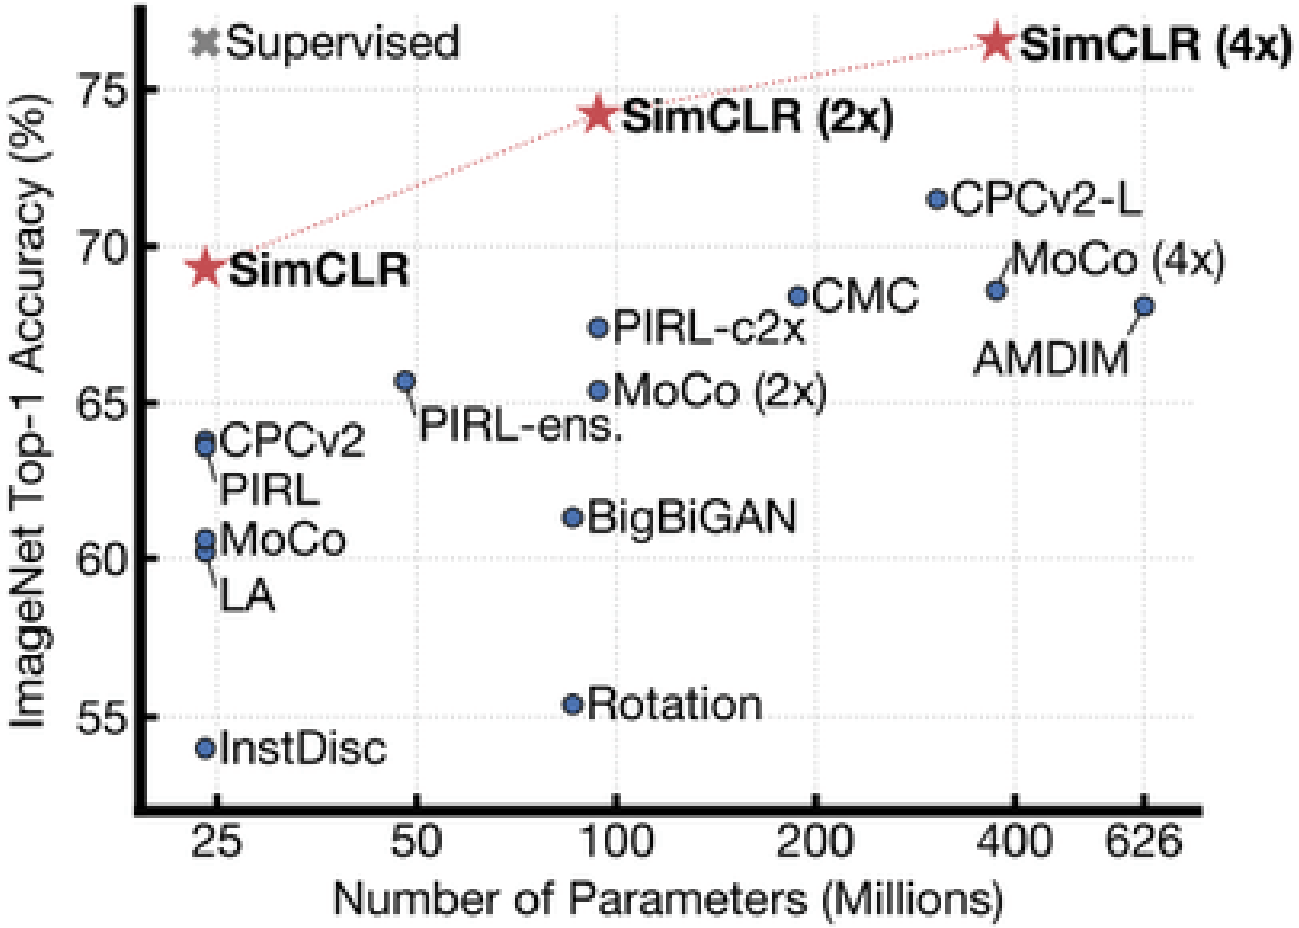
$$L = \frac{1}{2N}\sum_{k=1}^{N}[l(2k-1,2k) + l(2k,2k-1)]$$



Finetuning

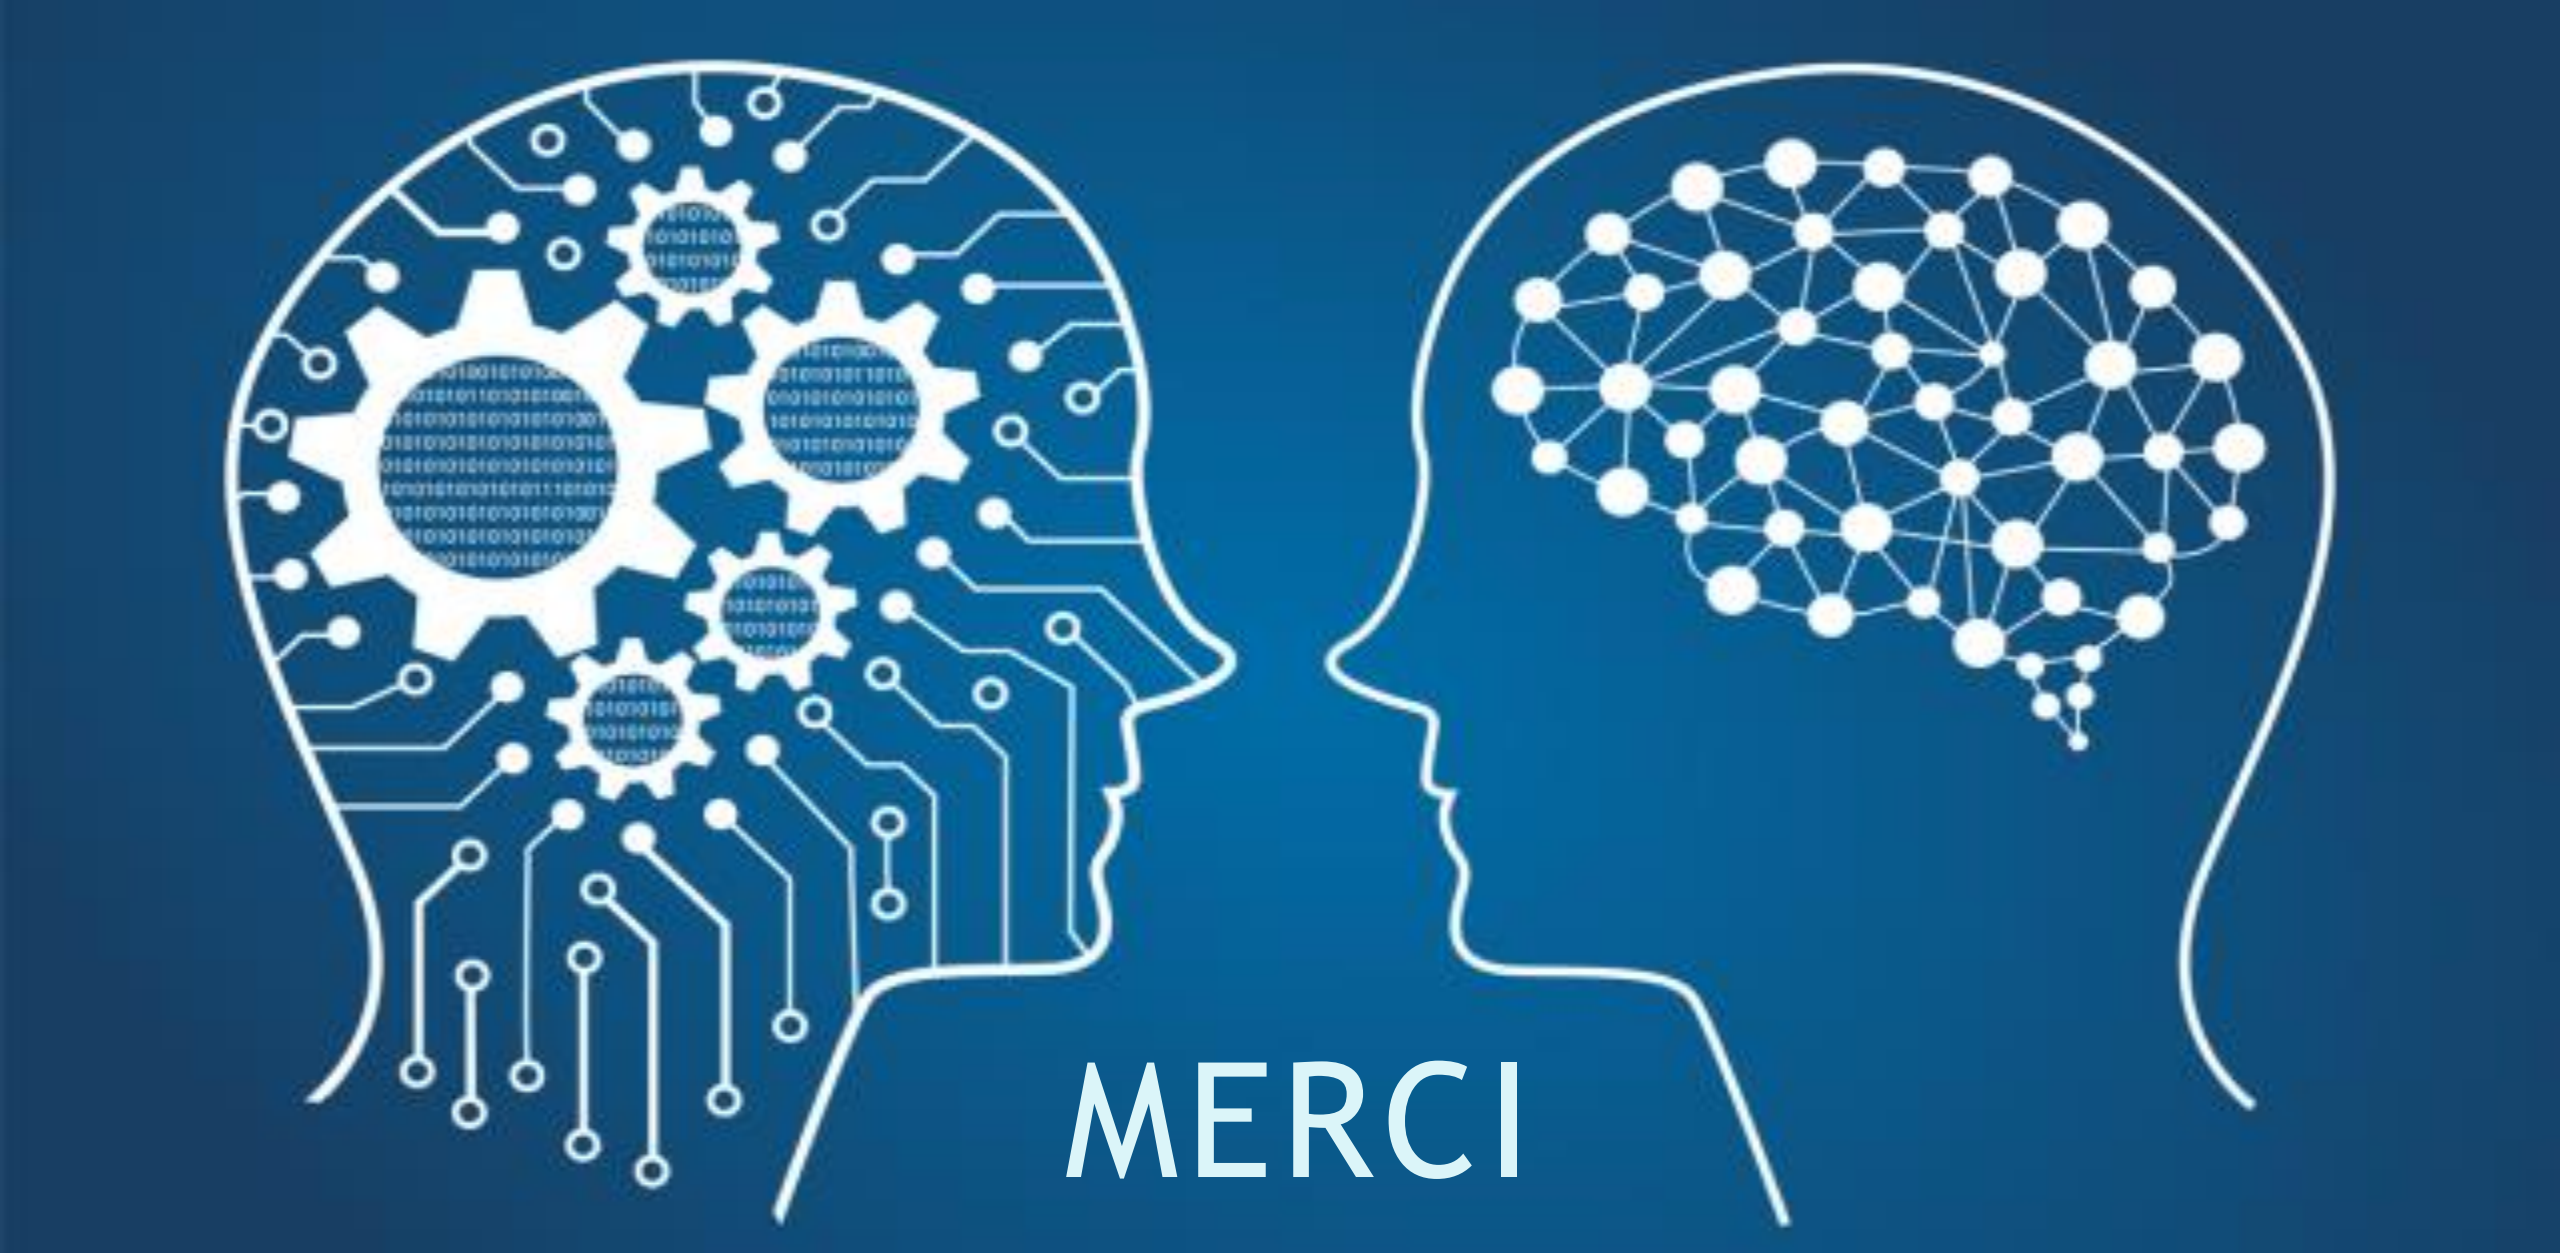

Usage on downstream tasks
Representation
Original Image
Data Augmentation
T
x_i
x_j
Transformed Images
Encoder
Encoder
Base Encoder f(.)
h_i
h_j
Dense
Relu
Dense
Dense
Relu
Dense
Projection Head g(.)
z_i
z_j
Maximize similarity
Finetuning
classification, detection, ...

Résultats (Source: papier SimCLR)



Conclusion

- SSL est en plein expansion (voir c'est l'avenir selon LeCan)
  - Apprentissage des features hiérarchiques en fonction de la tâche à accomplir
  - Beaucoup de données
  - Etat de l'art de l'apprentissage automatique
  - **Défi** : gérer l'incertitude dans la prédiction



Questions ?