Laboratoire de Technologie de l'Information et modélisation

LTIM

جامعة الحسن الثاني بالدار البيضاء
كلية العلوم بن مسيك

FSBM

FACULTE DES SCIENCES BEN M'SICK
UNIVERSITÉ HASSAN II DE CASABLANCA

THINKING AHEAD: JOINT-EMBEDDING PREDICTIVE ARCHITECTURE FOR LONG-RANGE COHERENCE IN SMALL LANGUAGE MODELS

Pr. El Habib BEN LAHMAR
https://orcid.org/0000-0001-7098-4621

International Summer School on Artificial Intelligence of the Franco-Moroccan Research Center 2026 Rabat, Morocco · ENSIAS · UIR · FLSHR

07/07/2026

AGENDA

- ❑ Introduction
- ❑ Modèles autorégressifs
- ❑ Les Limittes
- ❑ JEPA
- ❑ JEPA et NLP
- ❑ Une Architecture à Espaces Latents Découplés (AELD)
- ❑ Conclusion

« RECETTE DE CUISINE » : UN MICRO-RÉCIT À STRUCTURE CAUSALE

La Cohérence de Surface (Tokens t+1)

1. Casser deux œufs dans un bol.

2. Les battre avec une fourchette jusqu'à ce que le mélange soit homogène.

3. Ajouter une pincée de sel et de poivre.

4. Faire fondre une noix de beurre dans une poêle à feu moyen.

5. Verser les œufs battus dans la poêle.

6. Laisser cuire 2 minutes sans remuer.

7. Ajouter le fromage râpé sur la moitié de l'omelette.

8. Replier l'omelette en deux à l'aide d'une spatule.

Le Glissement Sémantique (Amnésie)

9. Servir avec une salade verte.

10. Pour la salade, émincer un oignon rouge et le faire revenir dans l'huile d'olive.

11. Incorporer les tomates cerises coupées en deux.

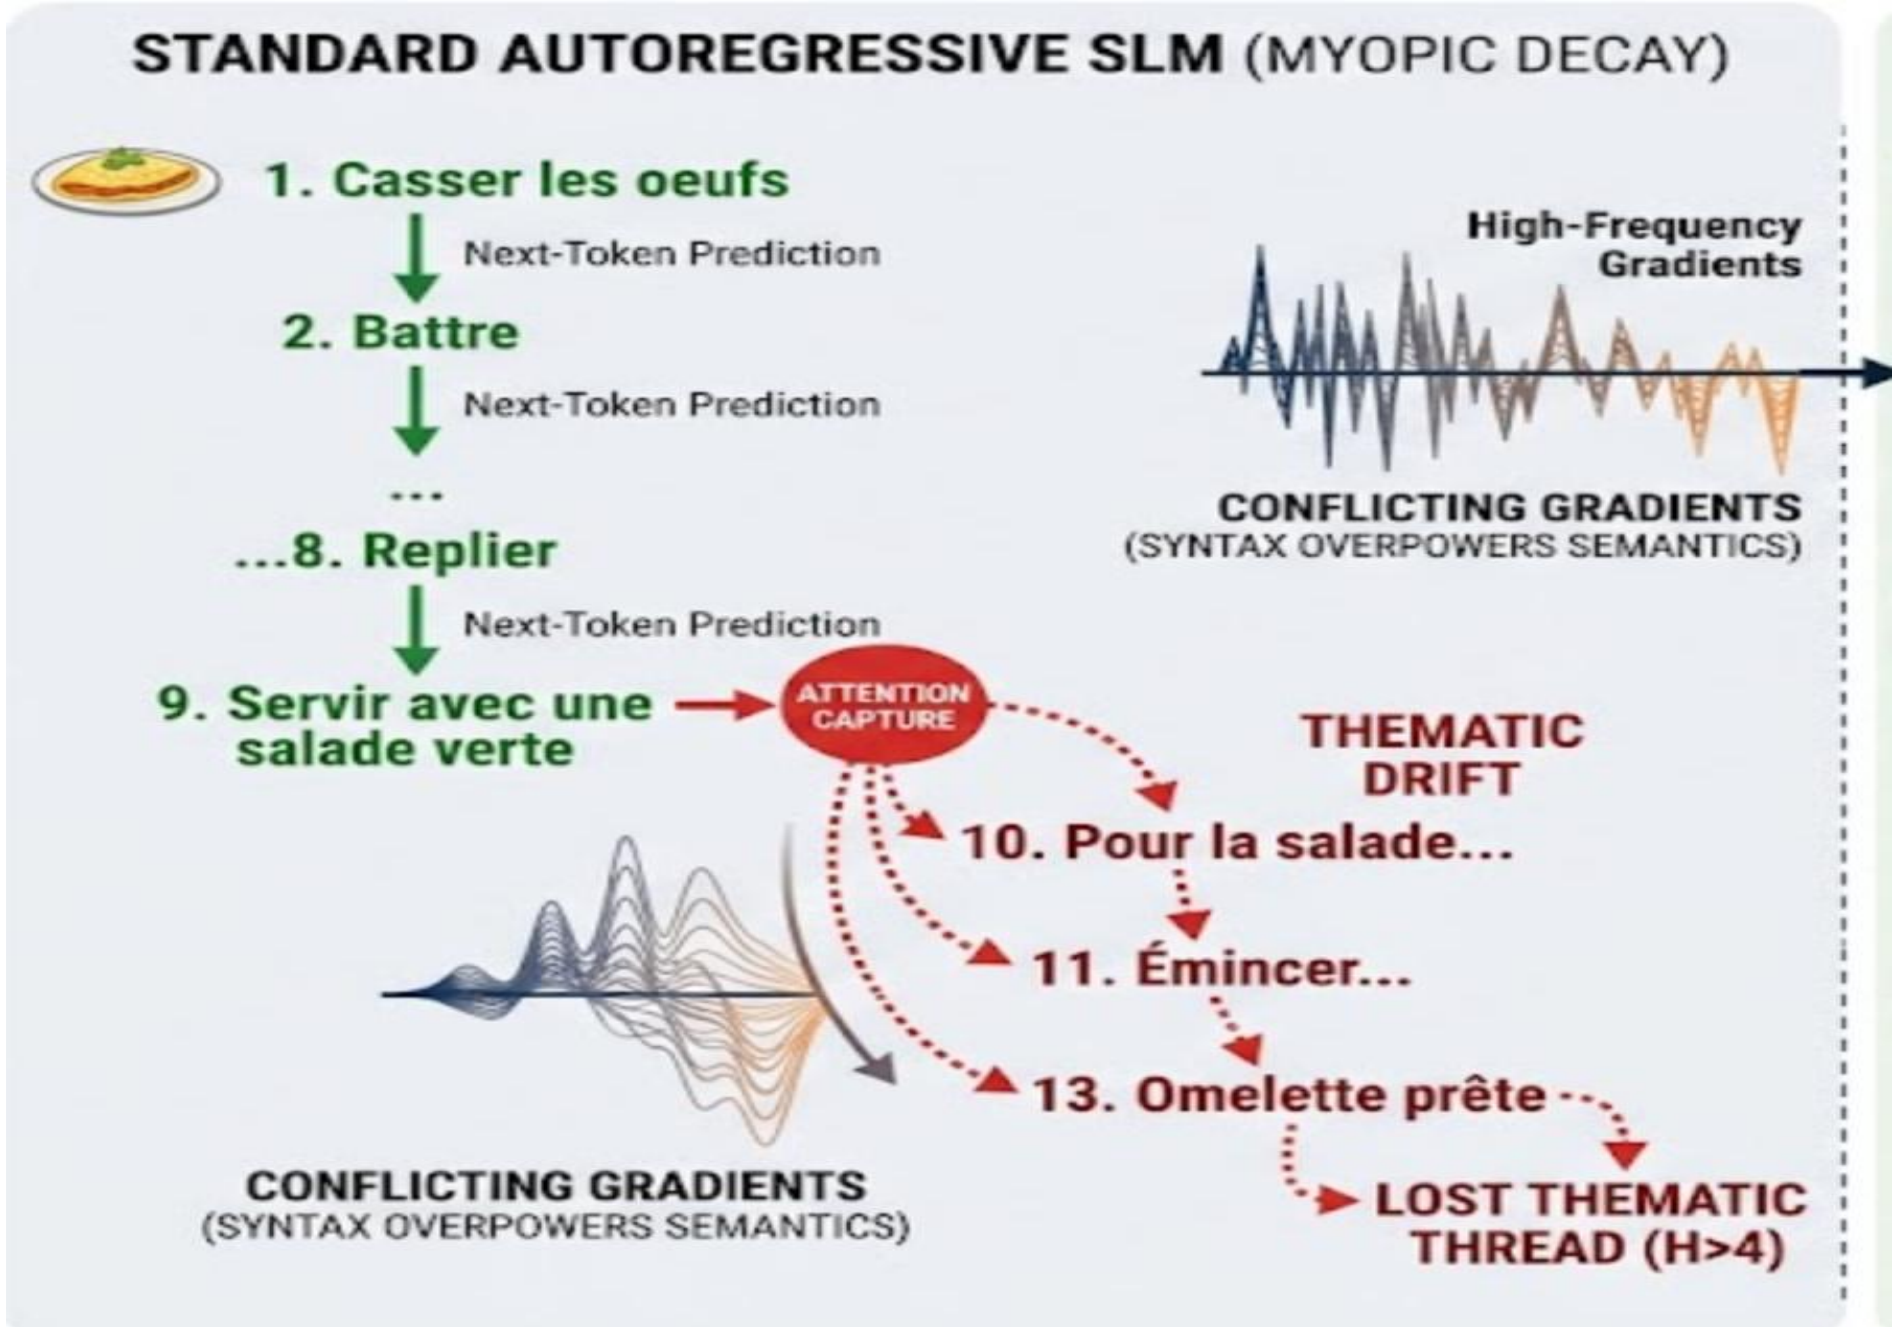
12. Assaisonner de vinaigre balsamique.

13. L'omelette est maintenant prête. Bon appétit !

POURQUOI ?

Ce comportement illustre à la perfection :

- **La myopie générative** : le modèle alloue toute sa capacité à la syntaxe locale et à la continuité de surface (mots outils, style de recette) mais ne maintient pas de représentation stable du but principal (l'omelette est l'objet central).
- **L'absence de planification abstraite** : il n'a pas de « plan latent » de la recette. Dès que le contexte immédiat glisse vers « salade », il suit cette nouvelle branche sans se rappeler qu'il s'agissait juste d'un accompagnement.
- **Le besoin d'un horizon de planification** : pour rester cohérent, le modèle aurait dû se souvenir, à l'étape 10, qu'il parlait encore de l'omelette et que la salade n'est qu'une suggestion, pas une sous-recette à développer.


STANDARD AUTOREGRESSIVE SLM (MYOPIC DECAY)
1. Casser les oeufs
Next-Token Prediction
2. Battre
Next-Token Prediction
...
...8. Replier
Next-Token Prediction
9. Servir avec une salade verte
ATTENTION CAPTURE
High-Frequency Gradients
CONFLICTING GRADIENTS
(SYNTAX OVERPOWERS SEMANTICS)
THEMATIC DRIFT
10. Pour la salade...
11. Émincer...
13. Omelette prête
LOST THEMATIC THREAD (H>4)
CONFLICTING GRADIENTS
(SYNTAX OVERPOWERS SEMANTICS)

L'OBJECTIF AUTORÉGRESSIF USUEL

Le modèle apprend à maximiser la vraisemblance d'une séquence $x_{1:T}$ en factorisant la distribution jointe par la règle de la chaîne :

$$p_\theta(x_{1:T}) = \prod_{t=1}^{T} p_\theta(x_t \mid x_{<t})$$

La fonction de perte minimisée est la **log-vraisemblance negative** (ou entropie croisée) :

$$\mathcal{L}_{\mathrm{AR}}(\theta) = -\frac{1}{T} \sum_{t=1}^{T} \log p_\theta(x_t \mid x_{<t})$$

Défaut structurel : chaque terme ne dépend que de la prédiction locale x_t et de l'historique immédiat. Il n'y a **aucune contrainte explicite** sur la cohérence entre des tokens éloignés x_t et x_{t+K} pour K grand. L'espace latent n'est jamais contraint de coder une intention à long terme.

LA DÉRIVE SÉMANTIQUE COMME DIVERGENCE CROISSANTE

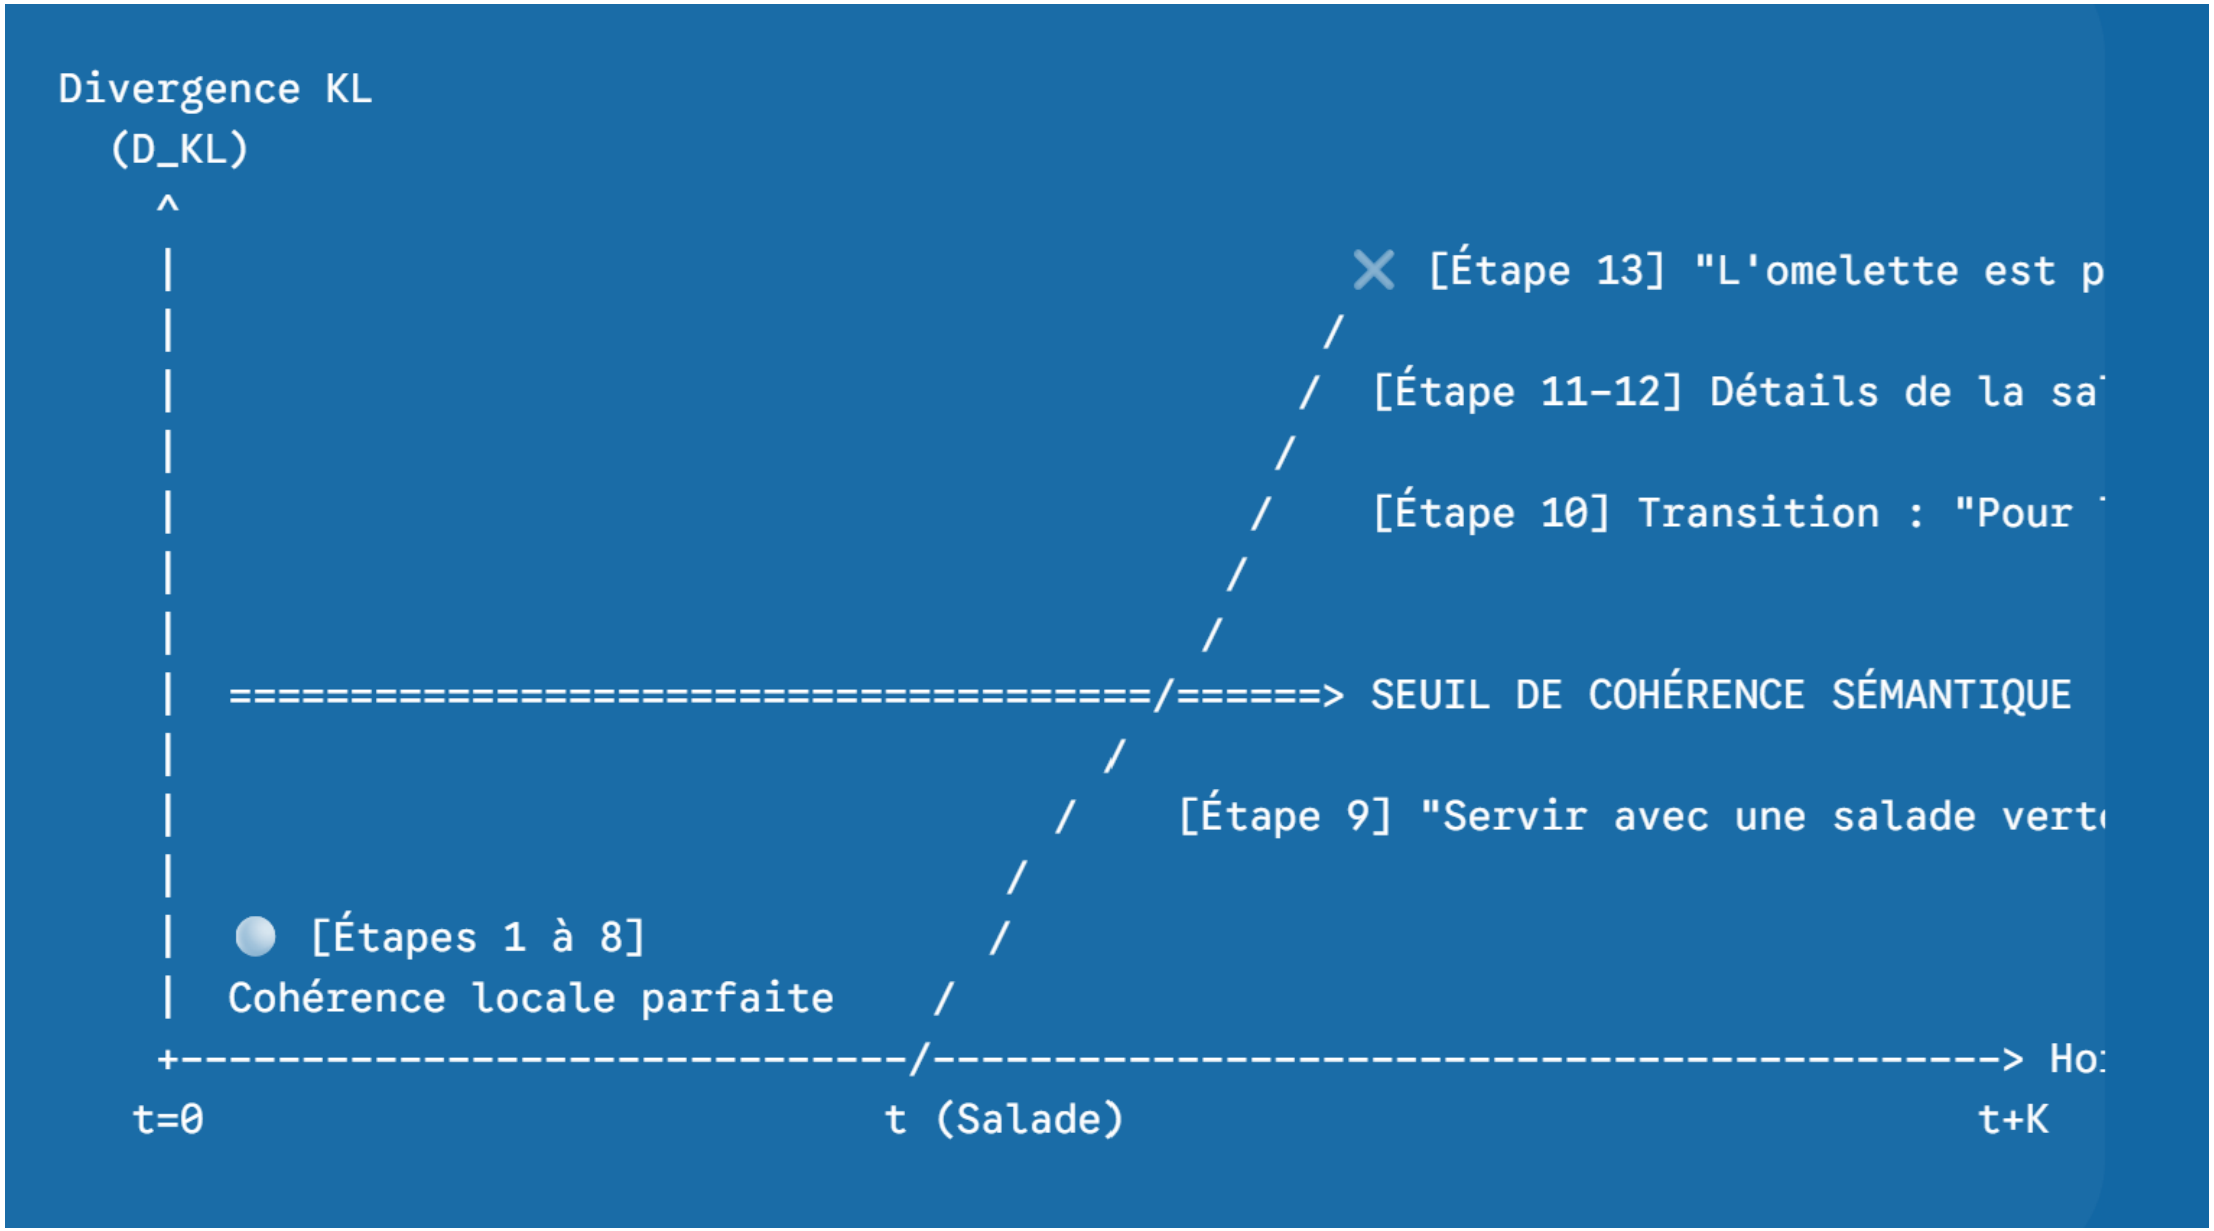
La distribution conditionnelle prédite pour une position future $t + K$ dérive de la véritable distribution conditionnelle qui, elle, dépend de toute l'histoire $x_{<t+K}$.

La différence peut se mesurer par une divergence de Kullback-Leibler.

Pour un petit modèle sous-contraint, cette divergence croît avec K :

$$D_{\mathrm{KL}}\left(p_{\mathrm{data}}(x_{t+K} \mid x_{<t+K}) \,\middle\|\, p_\theta(x_{t+K} \mid x_{<t+K})\right) \approx \alpha K$$

Cela signifie que le modèle oublie exponentiellement le contexte lointain : c'est l'**amnésie sémantique**.


Divergence KL
(D_KL)
[Étape 13] "L'omelette est p
[Étape 11-12] Détails de la sa
[Étape 10] Transition : "Pour
SEUIL DE COHÉRENCE SÉMANTIQUE
[Étape 9] "Servir avec une salade vert
[Étapes 1 à 8]
Cohérence locale parfaite
t=0
t (Salade)
t+K

LA « TYRANNIE » DES HAUTES FRÉQUENCES

Dans un modèle à capacité fixe (15M paramètres), le gradient de la perte autorégressive est dominé par les corrélations locales (syntaxiques) à haute fréquence. Pour le voir, on peut décomposer le signal d'apprentissage :

$$\nabla_\theta \mathcal{L}_{\text{AR}} \approx \underbrace{\nabla_\theta \mathcal{L}_{\text{local}}}_{\text{syntaxe, forte amplitude}} + \underbrace{\nabla_\theta \mathcal{L}_{\text{long-range}}}_{\text{sémantique, faible amplitude}}$$

Le rapport signal/bruit est tel que le réseau alloue presque toute sa capacité aux dépendances de surface. La conséquence est formalisable : pour tout horizon $K >$ *seuil*, la corrélation mutuelle entre les représentations latentes h_t et h_{t+K} s'effondre vers zéro.

BESOIN D'UN NOUVEAU PARADIGME D'APPRENTISSAGE

Le problème n'est pas accidentel, il est **inscrit dans l'objectif autorégressif lui-même**. Aucun réglage d'hyperparamètres, aucune augmentation de données ne peut le résoudre sans modifier l'objectif d'apprentissage. D'où la nécessité d'une « autre manière de faire de l'IA », comme vous dites.

C'est précisément là qu'intervient l'idée d'un **objectif de planification latente** : au lieu de prédire x_{t+K} directement, on prédit un état latent s_{t+K} qui résume l'information sémantique future, en opérant dans un espace où l'on peut échapper à la domination du signal syntaxique discret.

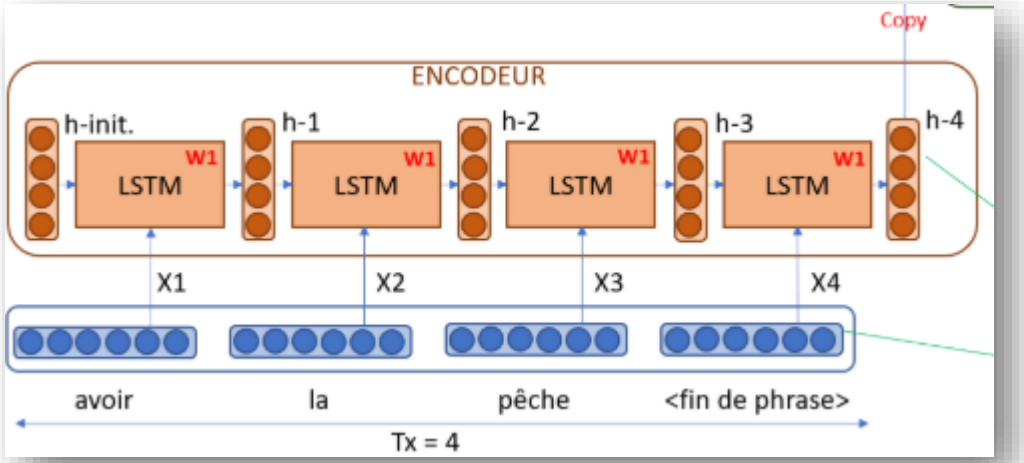
JEPA

Puisque la myopie est une propriété structurelle de $\mathcal{L}_{AR}$, nous avons besoin d'un signal d'apprentissage qui force la cohérence à long terme.

Besoin d'un nouveau signal d'apprentissage qui force le modèle à anticiper le sens global, pas seulement le token suivant

C'est ce que propose le JEPA : au lieu de générer le futur token par token, le modèle apprend à anticiper son propre état latent à $t + K$

AR VS JEPA



- **JEPA: Joint Embedding Predictive Architecture.**
  - x: observed past and present
  - y: future
  - a: action
  - z: latent variable (unknown)
  - D( ): prediction cost
  - C( ): surrogate cost
  - JEPA predicts a representation of the future S_y from a representation of the past and present S_x

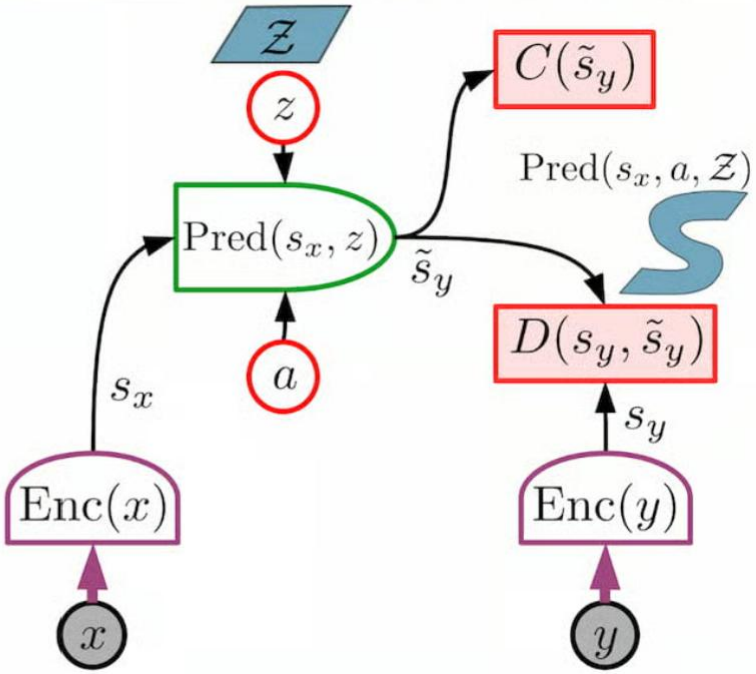
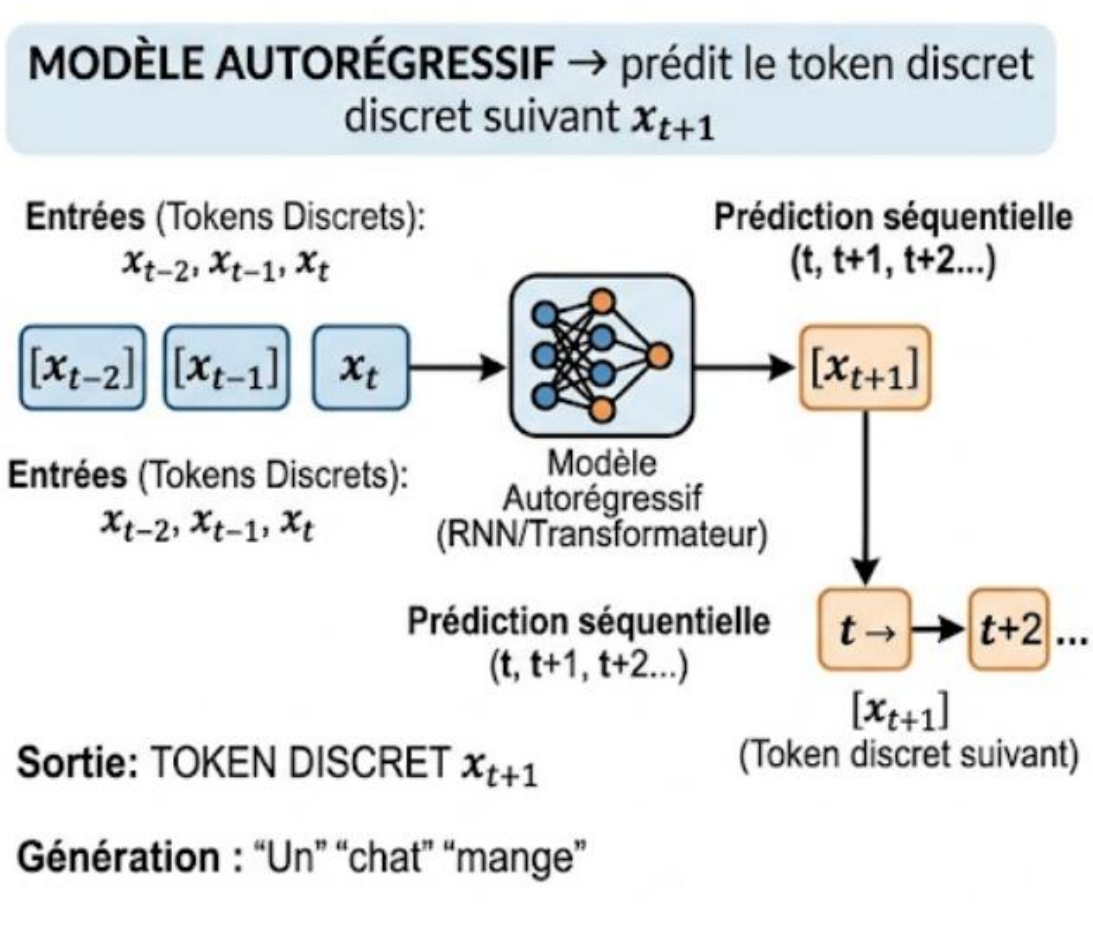
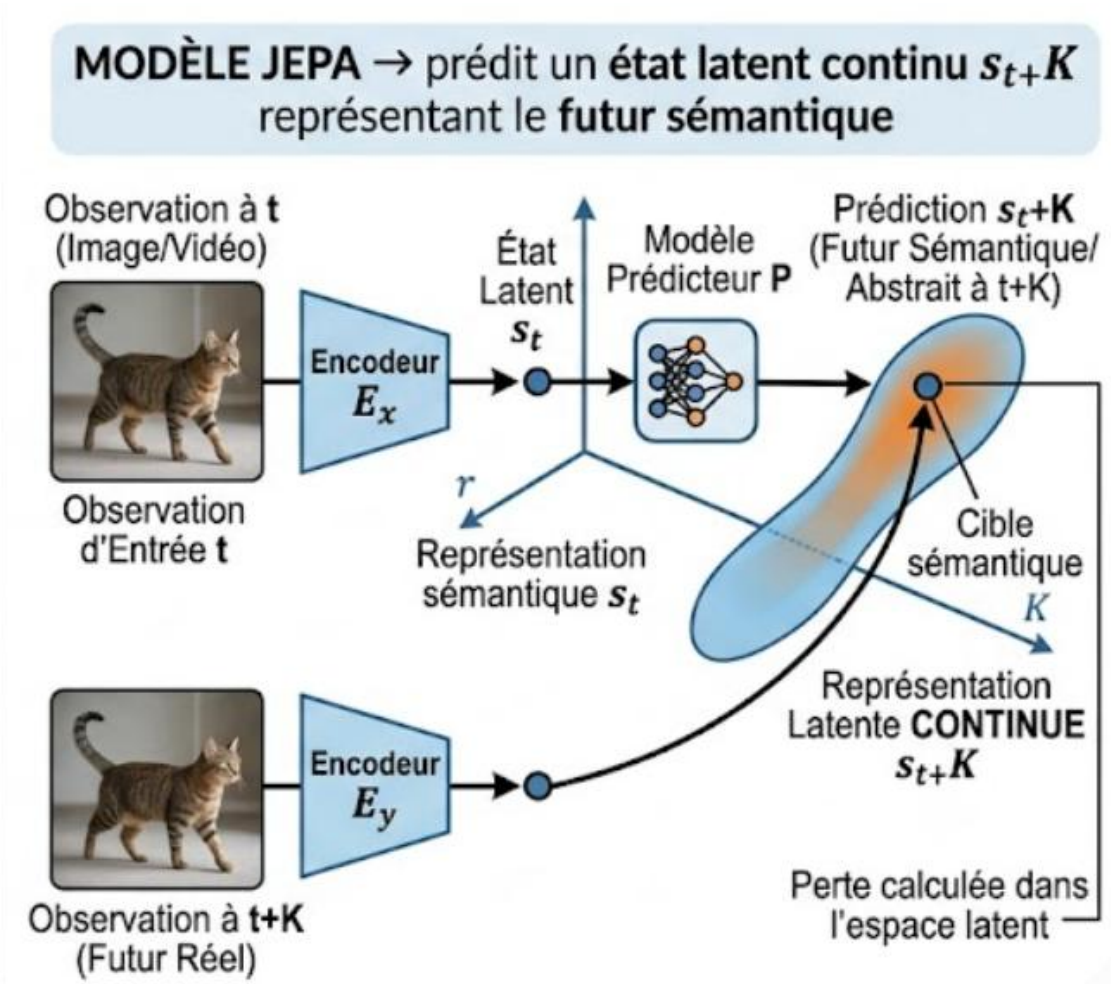


Image Credit: Yann LeCun's Harvard presentation (March 28, 2024)

AR VS JEPA


MODÈLE AUTORÉGRESSIF → prédit le token discret discret suivant x_{t+1}
Entrées (Tokens Discrets):
x_{t-2}, x_{t-1}, x_t
$[x_{t-2}]$ $[x_{t-1}]$ x_t
Modèle Autorégressif (RNN/Transformateur)
Prédiction séquentielle (t, t+1, t+2...)
$[x_{t+1}]$
Entrées (Tokens Discrets):
x_{t-2}, x_{t-1}, x_t
Prédiction séquentielle (t, t+1, t+2...)
$t \rightarrow$ $t+2$ ...
$[x_{t+1}]$
(Token discret suivant)
Sortie: TOKEN DISCRET x_{t+1}
Génération : "Un" "chat" "mange"


MODÈLE JEPA → prédit un état latent continu s_{t+K} représentant le futur sémantique
Observation à t (Image/Vidéo)
Observation d'Entrée t
Encodeur E_x
État Latent s_t
Modèle Prédicteur P
Prédiction s_t+K (Futur Sémantique/ Abstrait à t+K)
r
Représentation sémantique s_t
Cible sémantique
K
Représentation Latente CONTINUE s_{t+K}
Encodeur E_y
Observation à t+K (Futur Réel)
Perte calculée dans l'espace latent

JEPA

JEPA repose sur un principe simple :

- Au lieu de reconstruire le détail pixel par pixel (ou token par token), il apprend à prédire l'état abstrait du futur dans un espace latent continu.
- Cela évite de gaspiller de la capacité sur le bruit de surface et force le modèle à capturer les dépendances globales.

- L'absence de décodeur vers l'espace d'entrée (pas de génération de pixels).
- L'utilisation du stop-gradient/EMA pour éviter l'effondrement (pertinent car vous réutiliserez ce mécanisme dans AELD).

- **JEPA: Joint Embedding Predictive Architecture.**
  - x: observed past and present
  - y: future
  - a: action
  - z: latent variable (unknown)
  - D( ): prediction cost
  - C( ): surrogate cost
  - JEPA predicts a representation of the future S_y from a representation of the past and present S_x

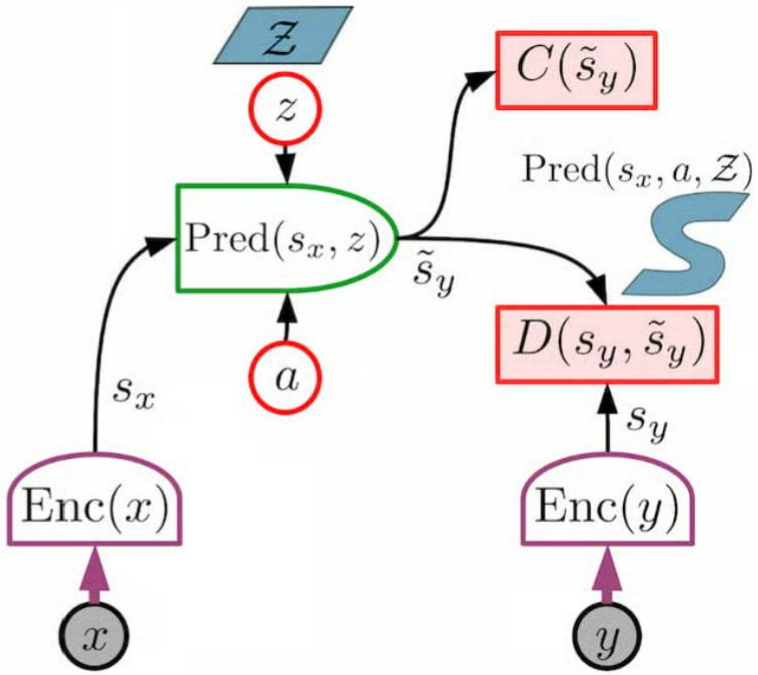
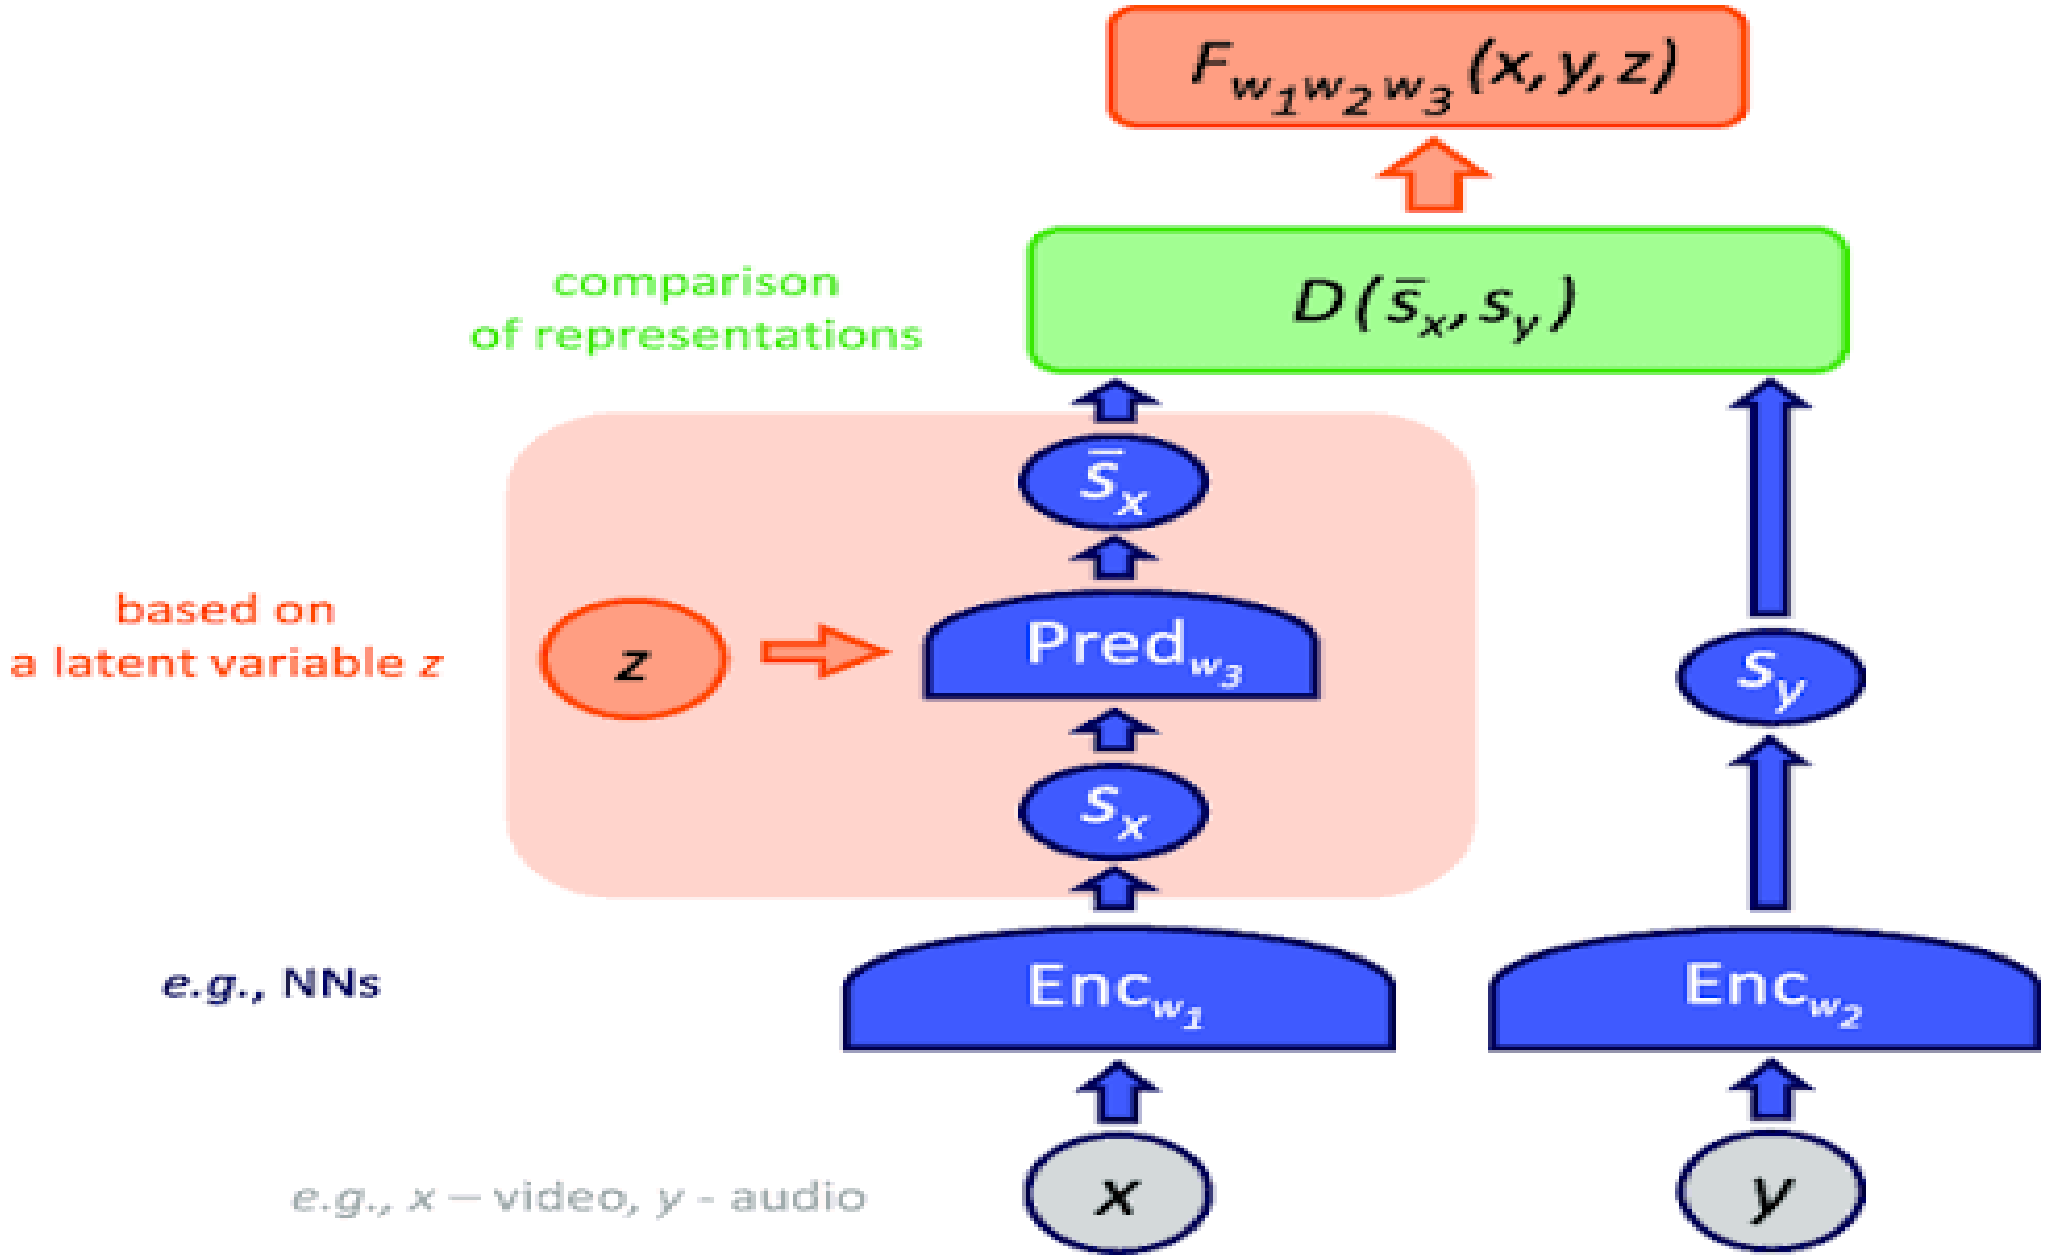
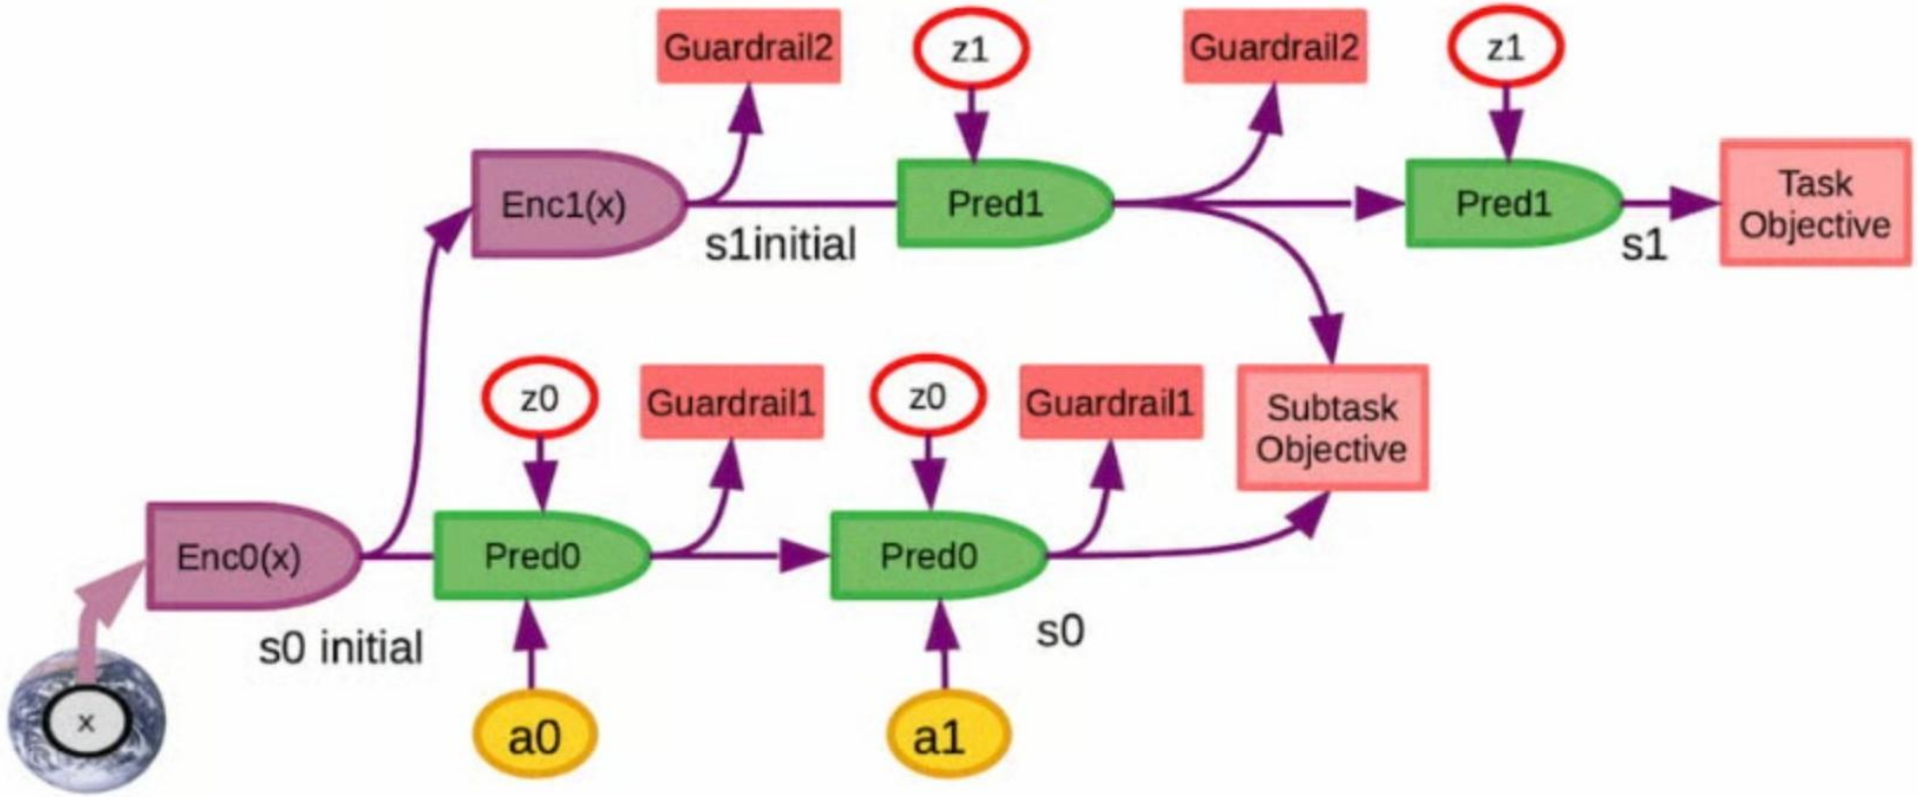


Image Credit: Yann LeCun's Harvard presentation (March 28, 2024)


$F_{w_1 w_2 w_3}(x, y, z)$
comparison
of representations
$D(\bar{s}_x, s_y)$
based on
a latent variable z
z
$\bar{s}_x$
Pred_{w_3}
s_x
s_y
e.g., NNs
Enc_{w_1}
Enc_{w_2}
x
y
e.g., x — video, y - audio

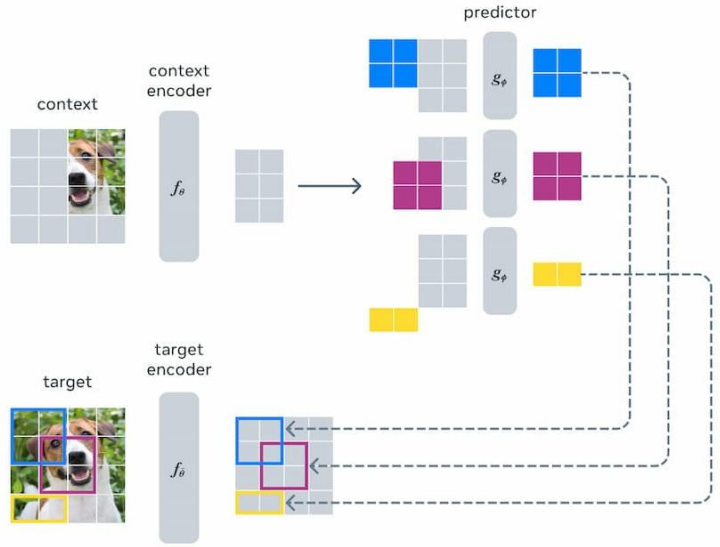
OBJECTIVE-DRIVEN AI: PLANIFICATION HIERARCHICALE

- **Hierarchical World Model and Planning**
  - Higher levels make longer-term predictions in more abstract representations
  - Predicted states at higher levels define subtask objectives for lower level
  - Guardrail objectives ensure safety at every level

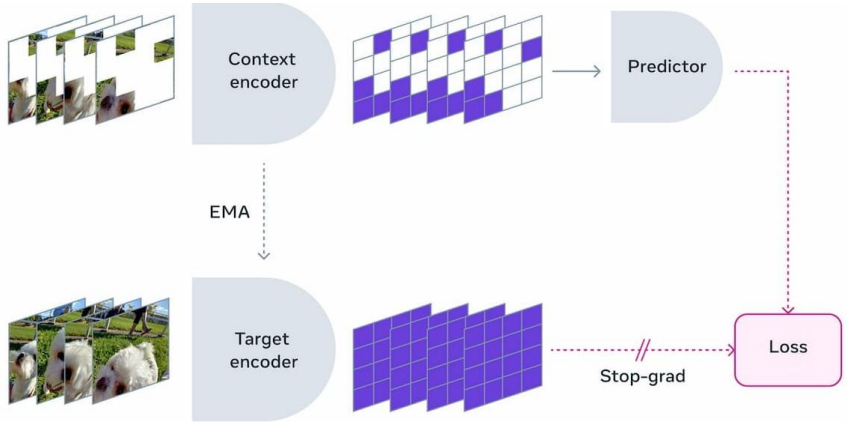


SUCCÈS EN IMAGE ET VIDÉO (CRÉDIBILITÉ)

I-JEPA (Image JEPA) : Apprentissage auto-supervisé sur ImageNet, atteint des performances élevées en classification avec des représentations riches sémantiquement, sans jamais reconstruire les pixels.



V-JEPA (Video JEPA) : Prédiction d'états latents futurs dans des vidéos, capture des dynamiques temporelles complexes, surpasse des méthodes génératives pour la reconnaissance d'actions.



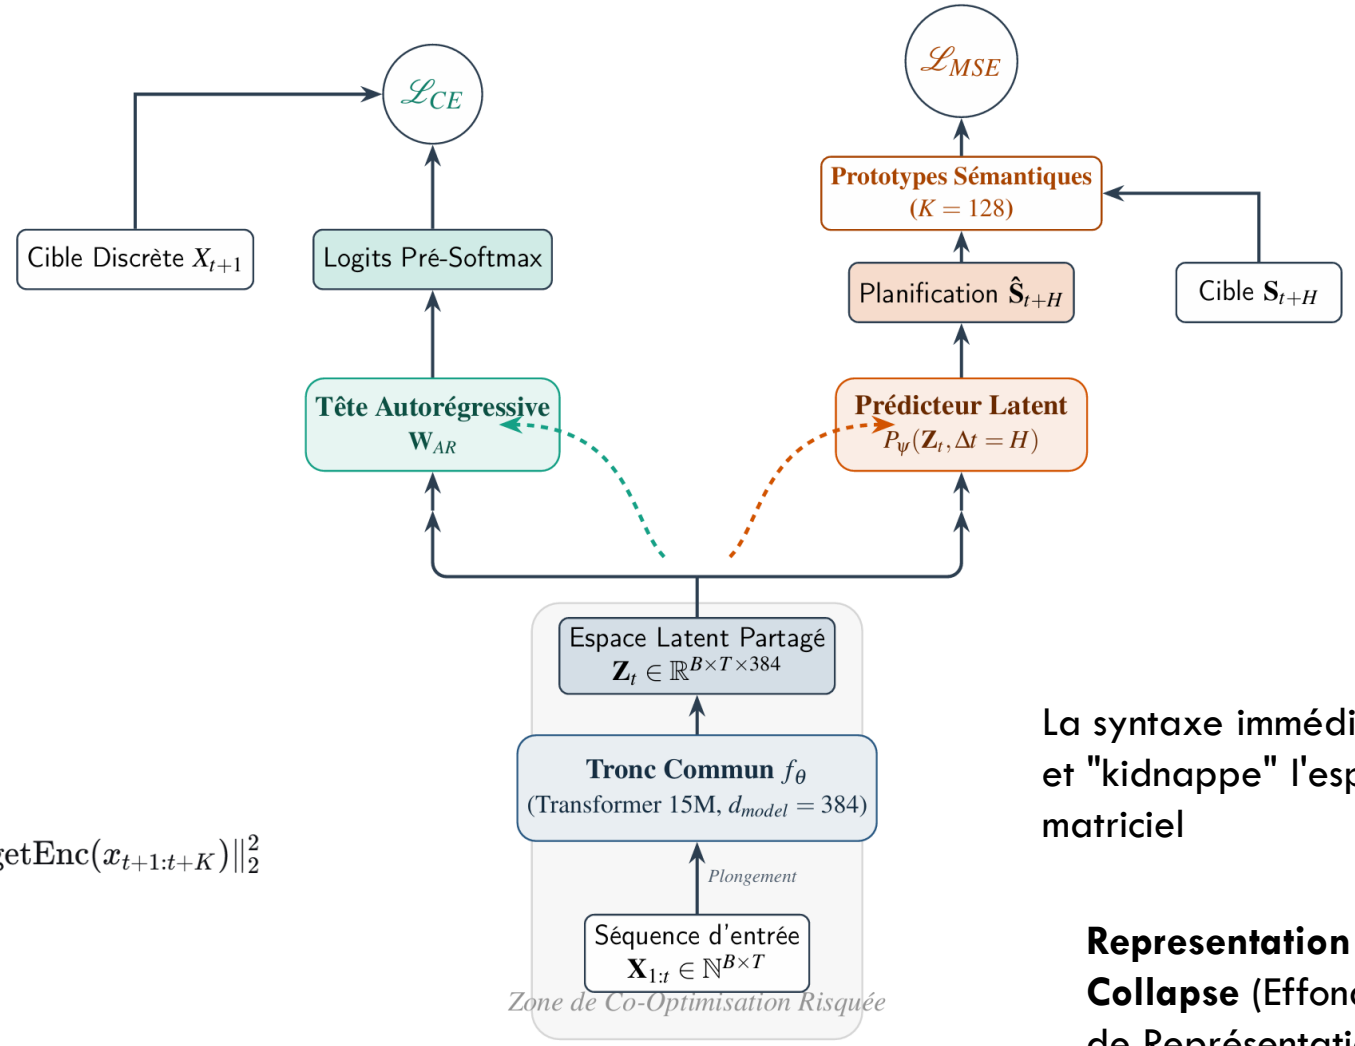
JEPA & NLP

Si JEPA parvient à saisir la structure sémantique d'une image ou la dynamique d'une vidéo sans jamais générer un pixel, pourquoi ne pourrait-il pas capturer le fil conducteur d'un texte sans avoir à prédire chaque mot ?

PREMIÈRE TENTATIVE: UN MODÈLE HYBRIDE UNIFIÉ.

Dans cette première tentative, l'objectif était de forcer un unique *backbone* Transformer (de 15M de paramètres) à projeter à la fois des informations discrètes à court terme et des concepts abstraits à long terme.

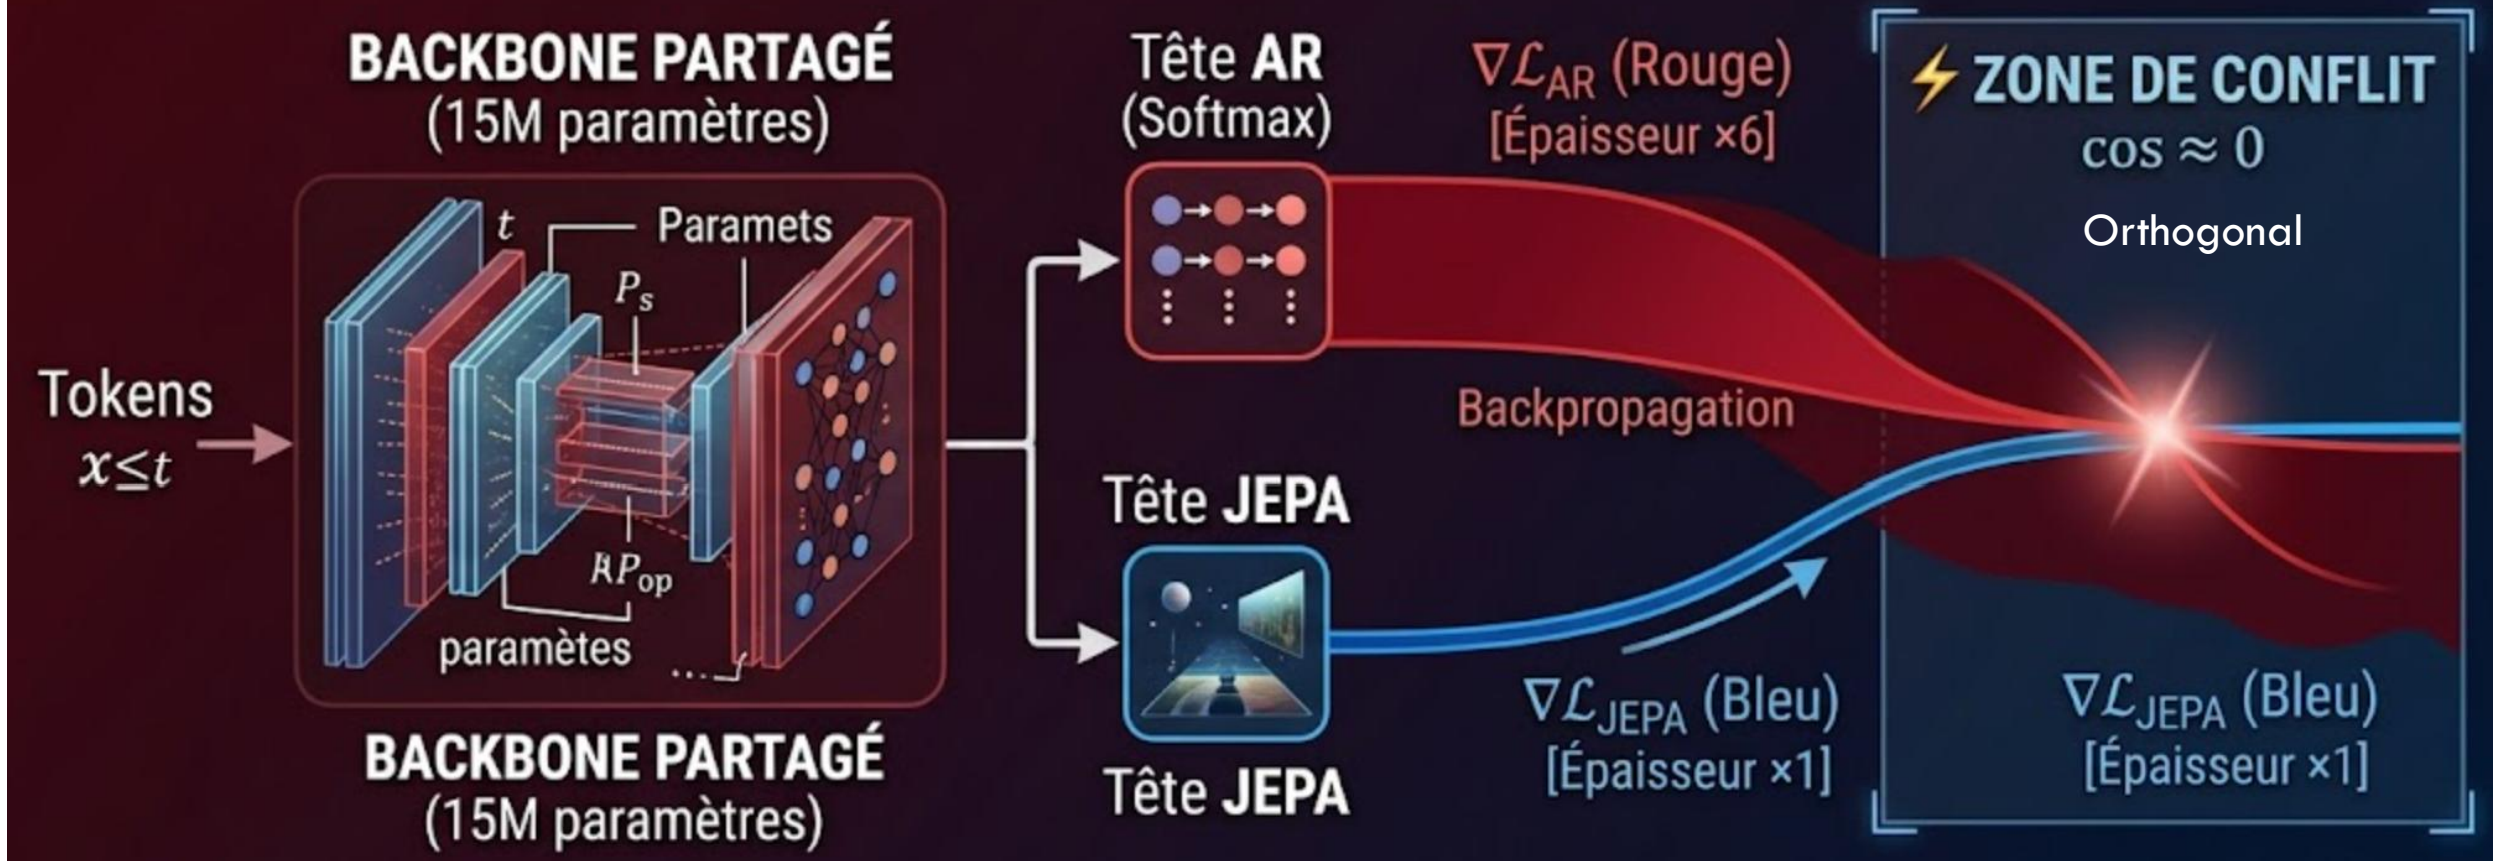
$$\mathcal{L}_{\text{Unifié}} = -\frac{1}{T}\sum_{t} \log p_\theta(x_{t+1}|x_{\leq t}) \; + \; \lambda \cdot \frac{1}{T}\sum_{t} \|\text{Pred}(h_t) - \text{TargetEnc}(x_{t+1:t+K})\|_2^2$$



La syntaxe immédiate sature et "kidnappe" l'espace matriciel

Representation Collapse (Effondrement de Représentation)

❌ MODÈLE HYBRIDE UNIFIÉ : CONFLIT DE GRADIENTS

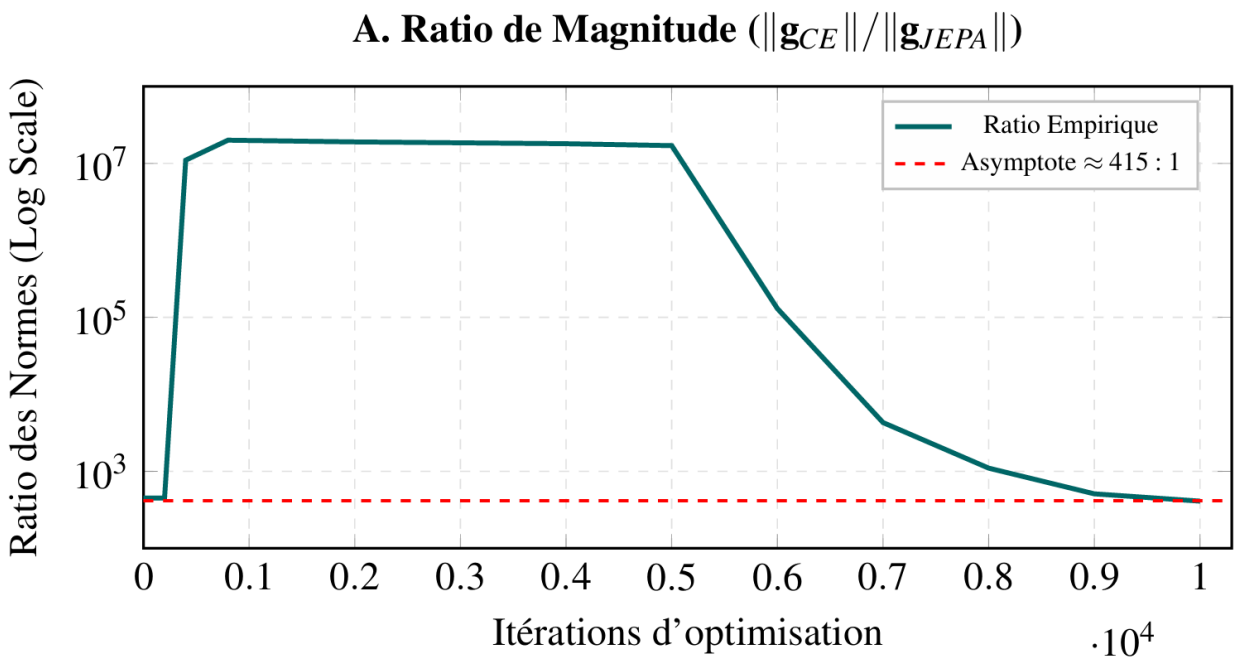


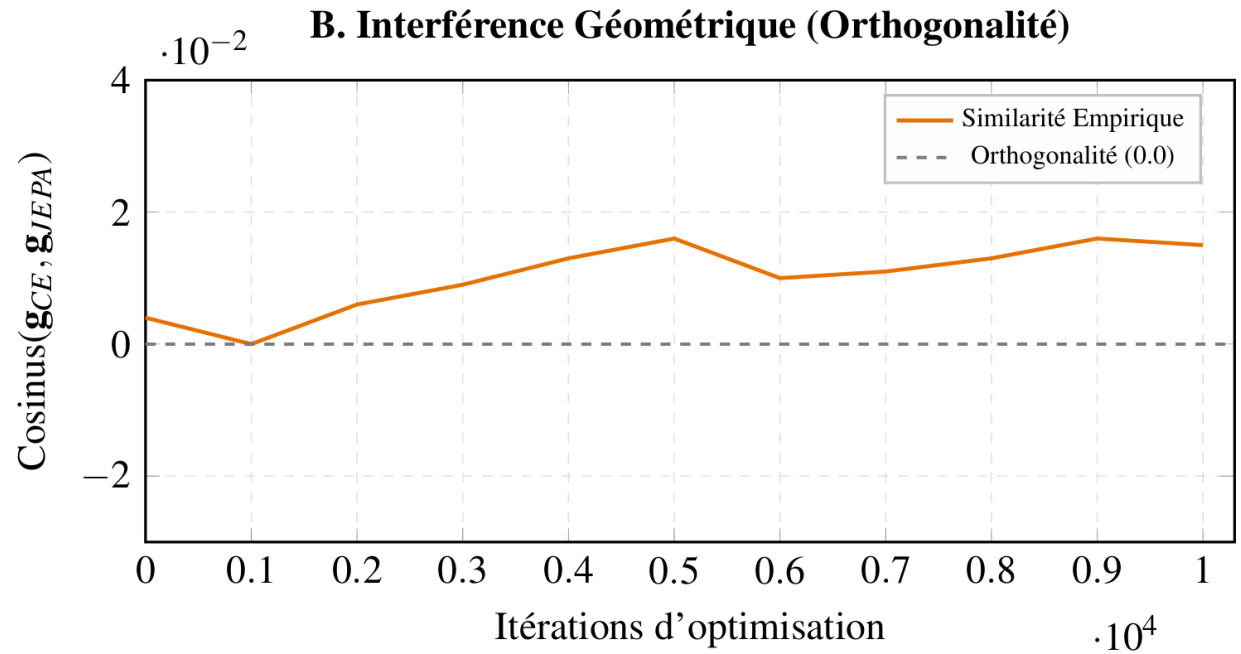
🔴 GRADIENT STARVATION

Le signal local écrase le signal sémantique lointain.

💥 REPRESENTATION COLLAPSE 🚨

L'espace latent perd sa structure prédictive → simple table de probas.

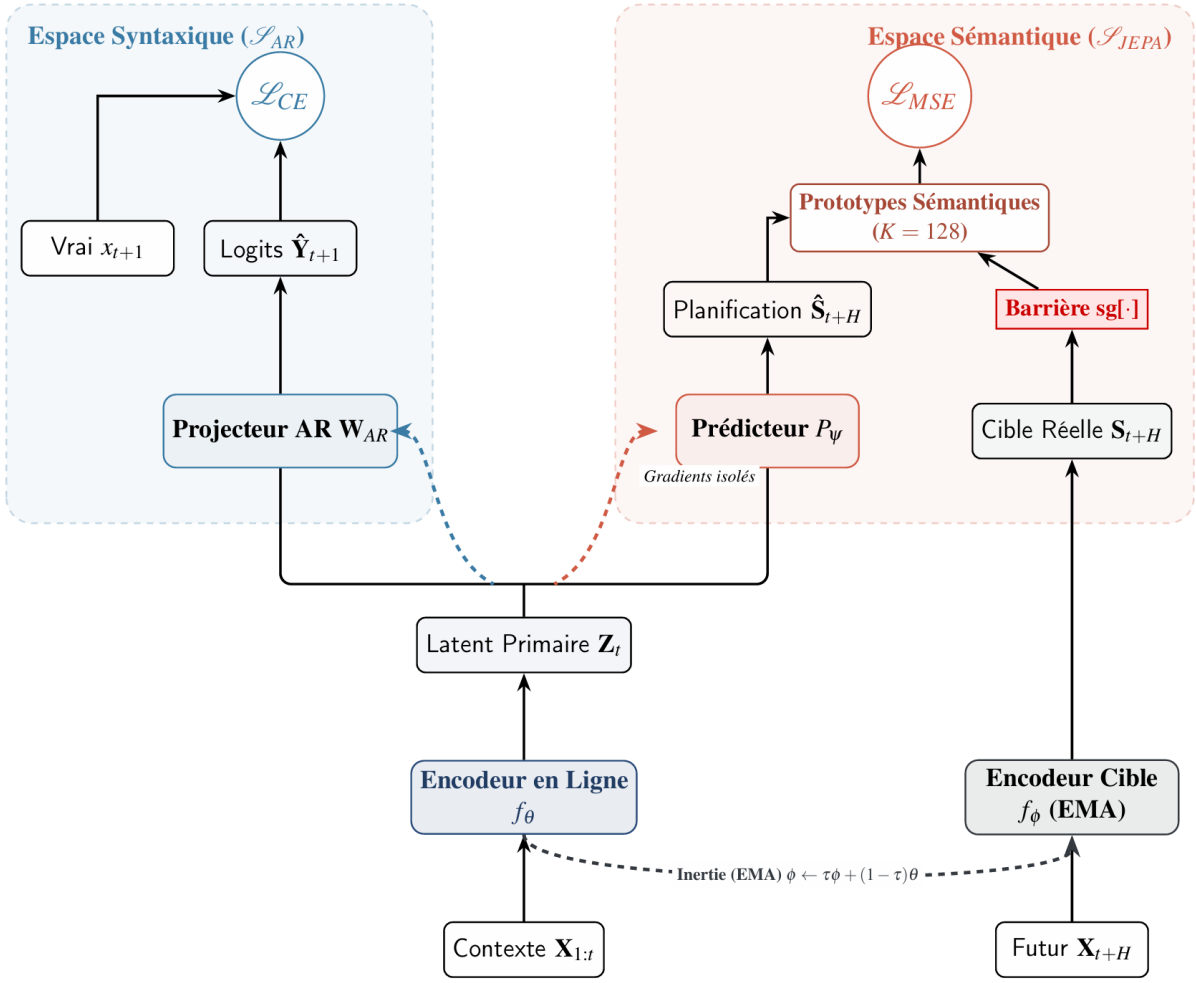

A. Ratio de Magnitude ($\|\mathbf{g}_{CE}\| / \|\mathbf{g}_{JEPA}\|$)
Ratio Empirique
Asymptote ≈ 415 : 1
Ratio des Normes (Log Scale)
10^7
10^5
10^3
0
0.1
0.2
0.3
0.4
0.5
0.6
0.7
0.8
0.9
1
Itérations d'optimisation
$\cdot 10^4$

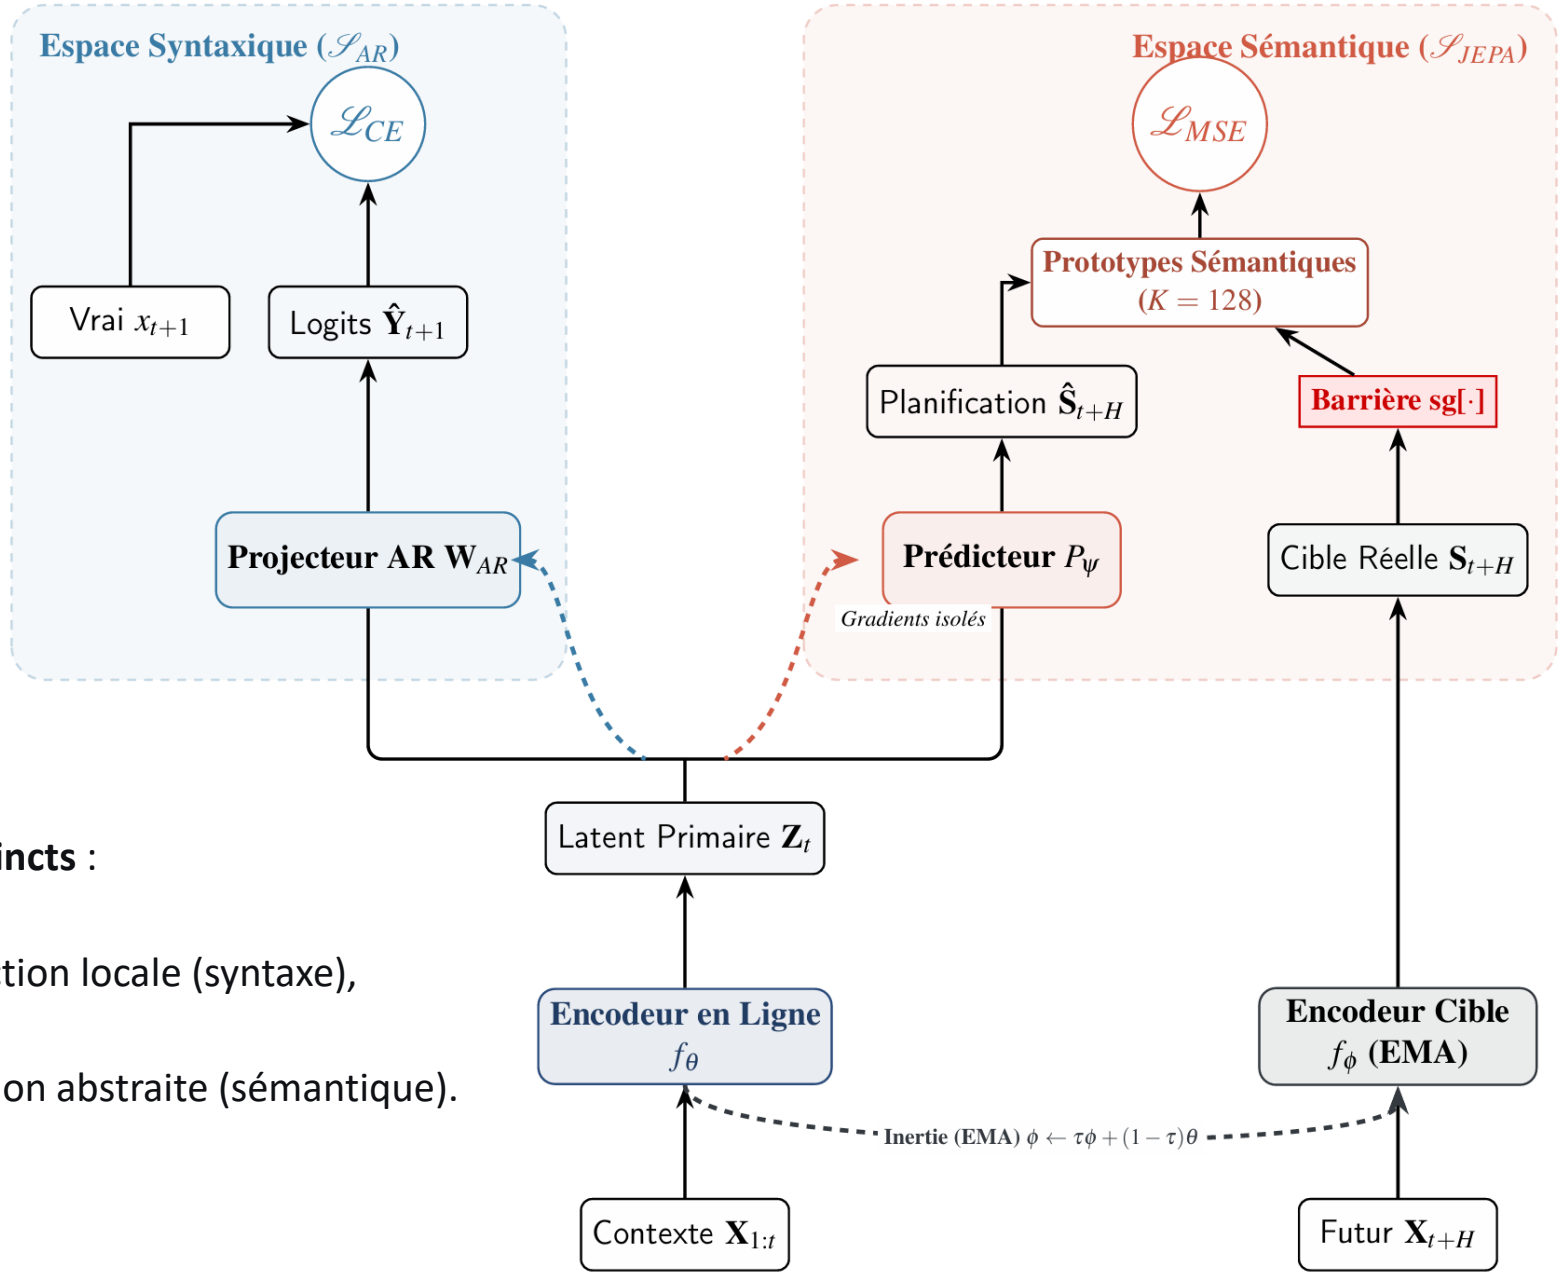

B. Interférence Géométrique (Orthogonalité)
$\cdot 10^{-2}$
Similarité Empirique
Orthogonalité (0.0)
Cosinus($\mathbf{g}_{CE}, \mathbf{g}_{JEPA}$)
4
2
0
−2
0
0.1
0.2
0.3
0.4
0.5
0.6
0.7
0.8
0.9
1
Itérations d'optimisation
$\cdot 10^4$

SOLUTION: UNE SÉPARATION PHYSIQUE
ARCHITECTURE À ESPACES LATENTS DÉCOUPLÉS (AELD)

Si le partage tue l'apprentissage, alors la solution est évidente : **ne plus partager.** Nous devons donner à chaque objectif son propre espace de représentation, et contrôler strictement les échanges entre eux.

En isolant physiquement les flux, nous supprimons le conflit de gradients. L'encodeur sémantique peut apprendre à planifier sans être écrasé par le signal syntaxique





Deux encodeurs distincts :

l'un dédié à la prédiction locale (syntaxe),

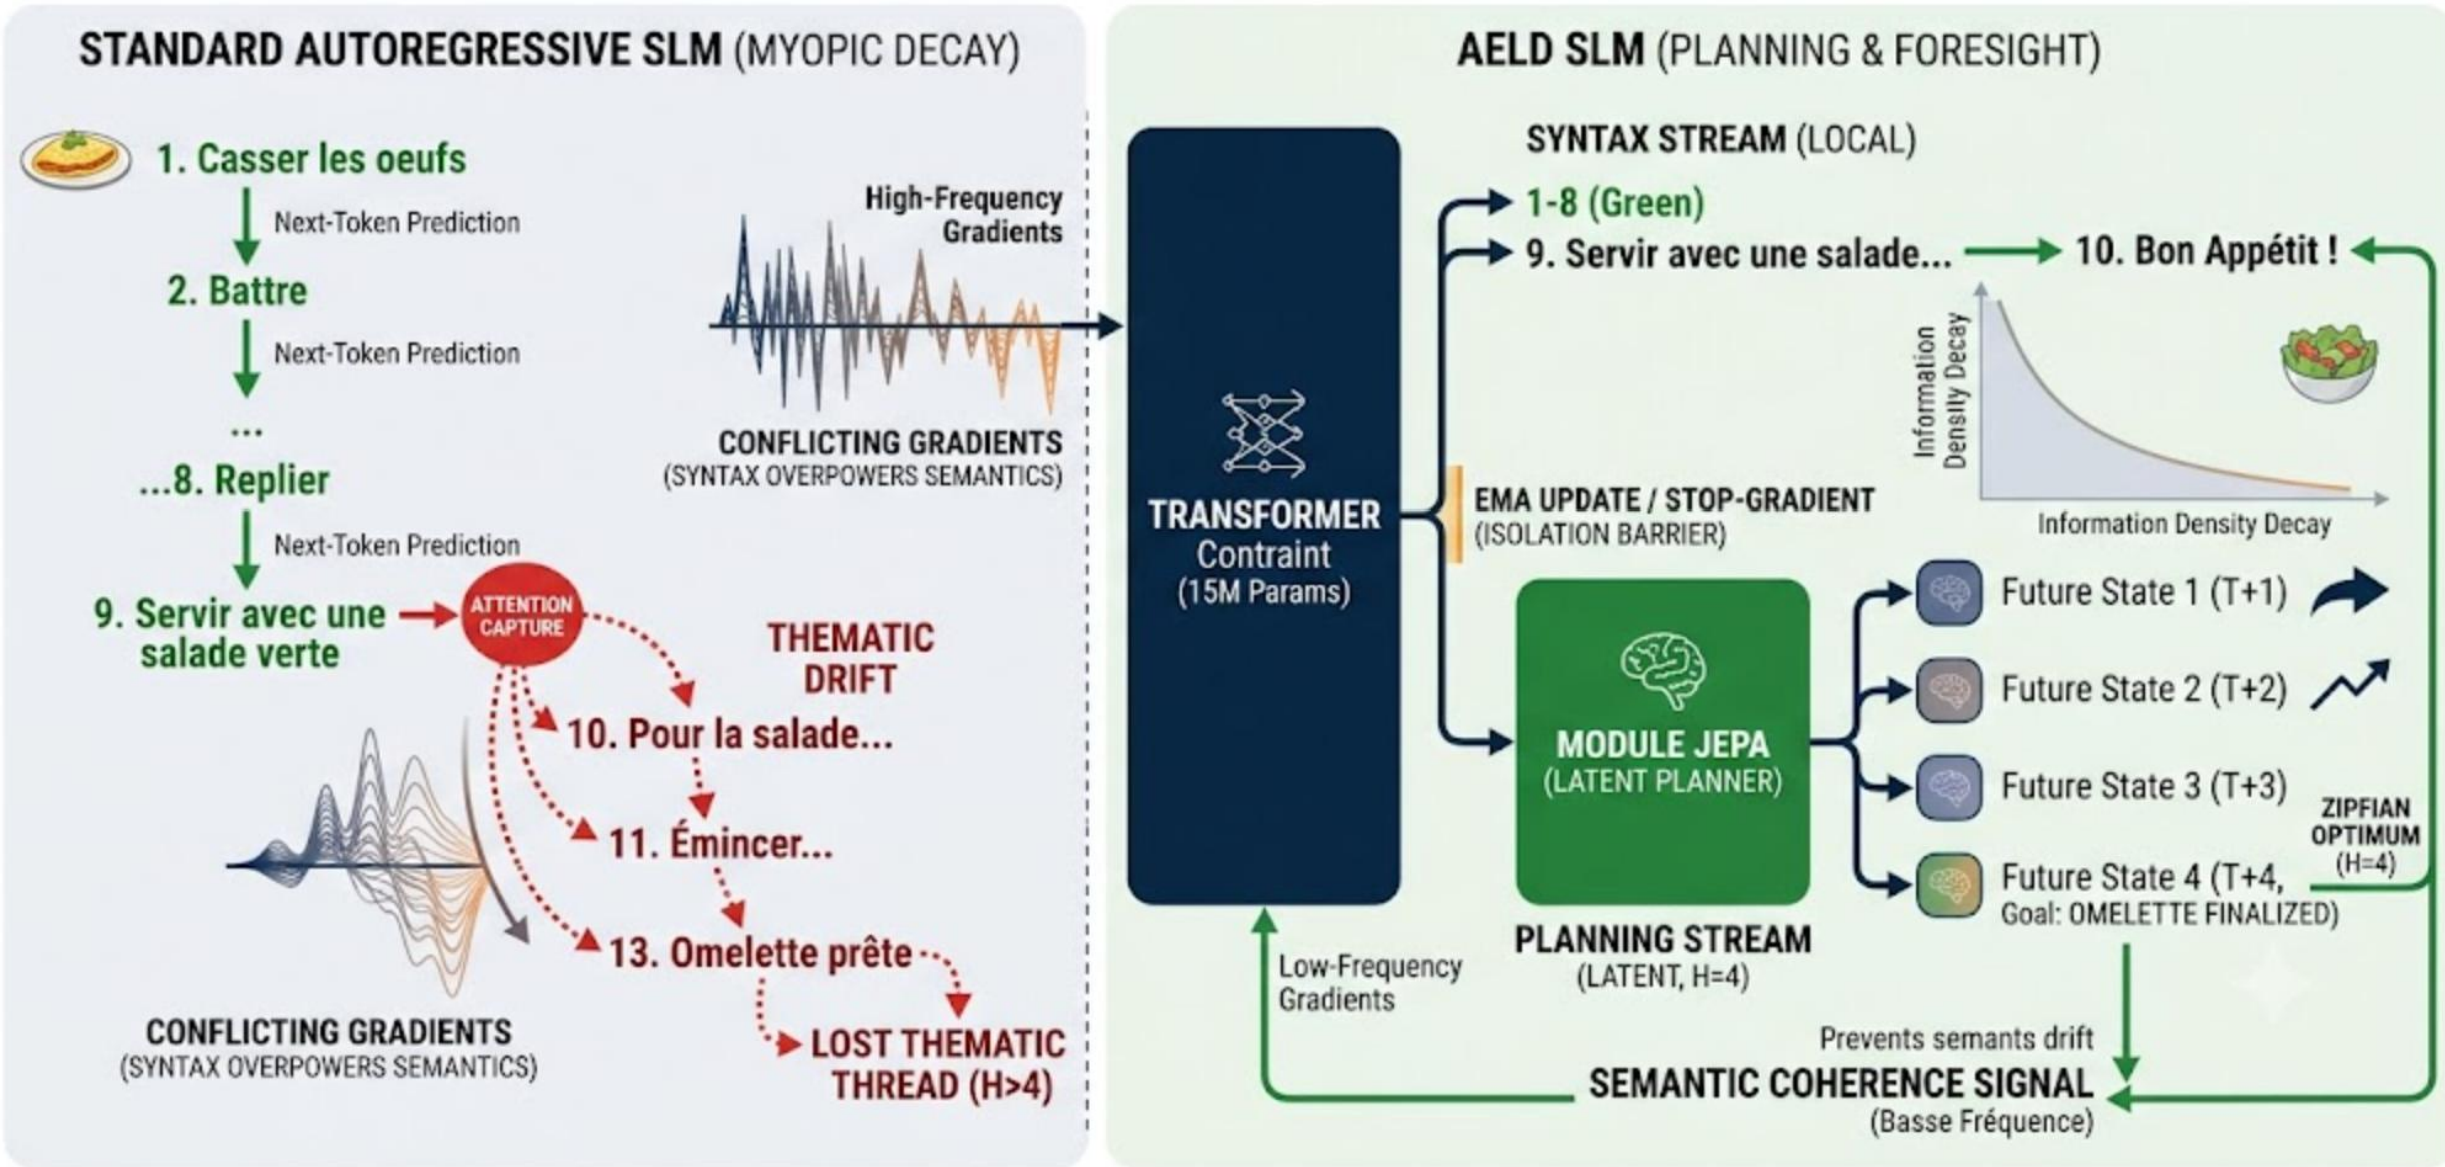
l'autre à la planification abstraite (sémantique).

Ils n'interfèrent plus.

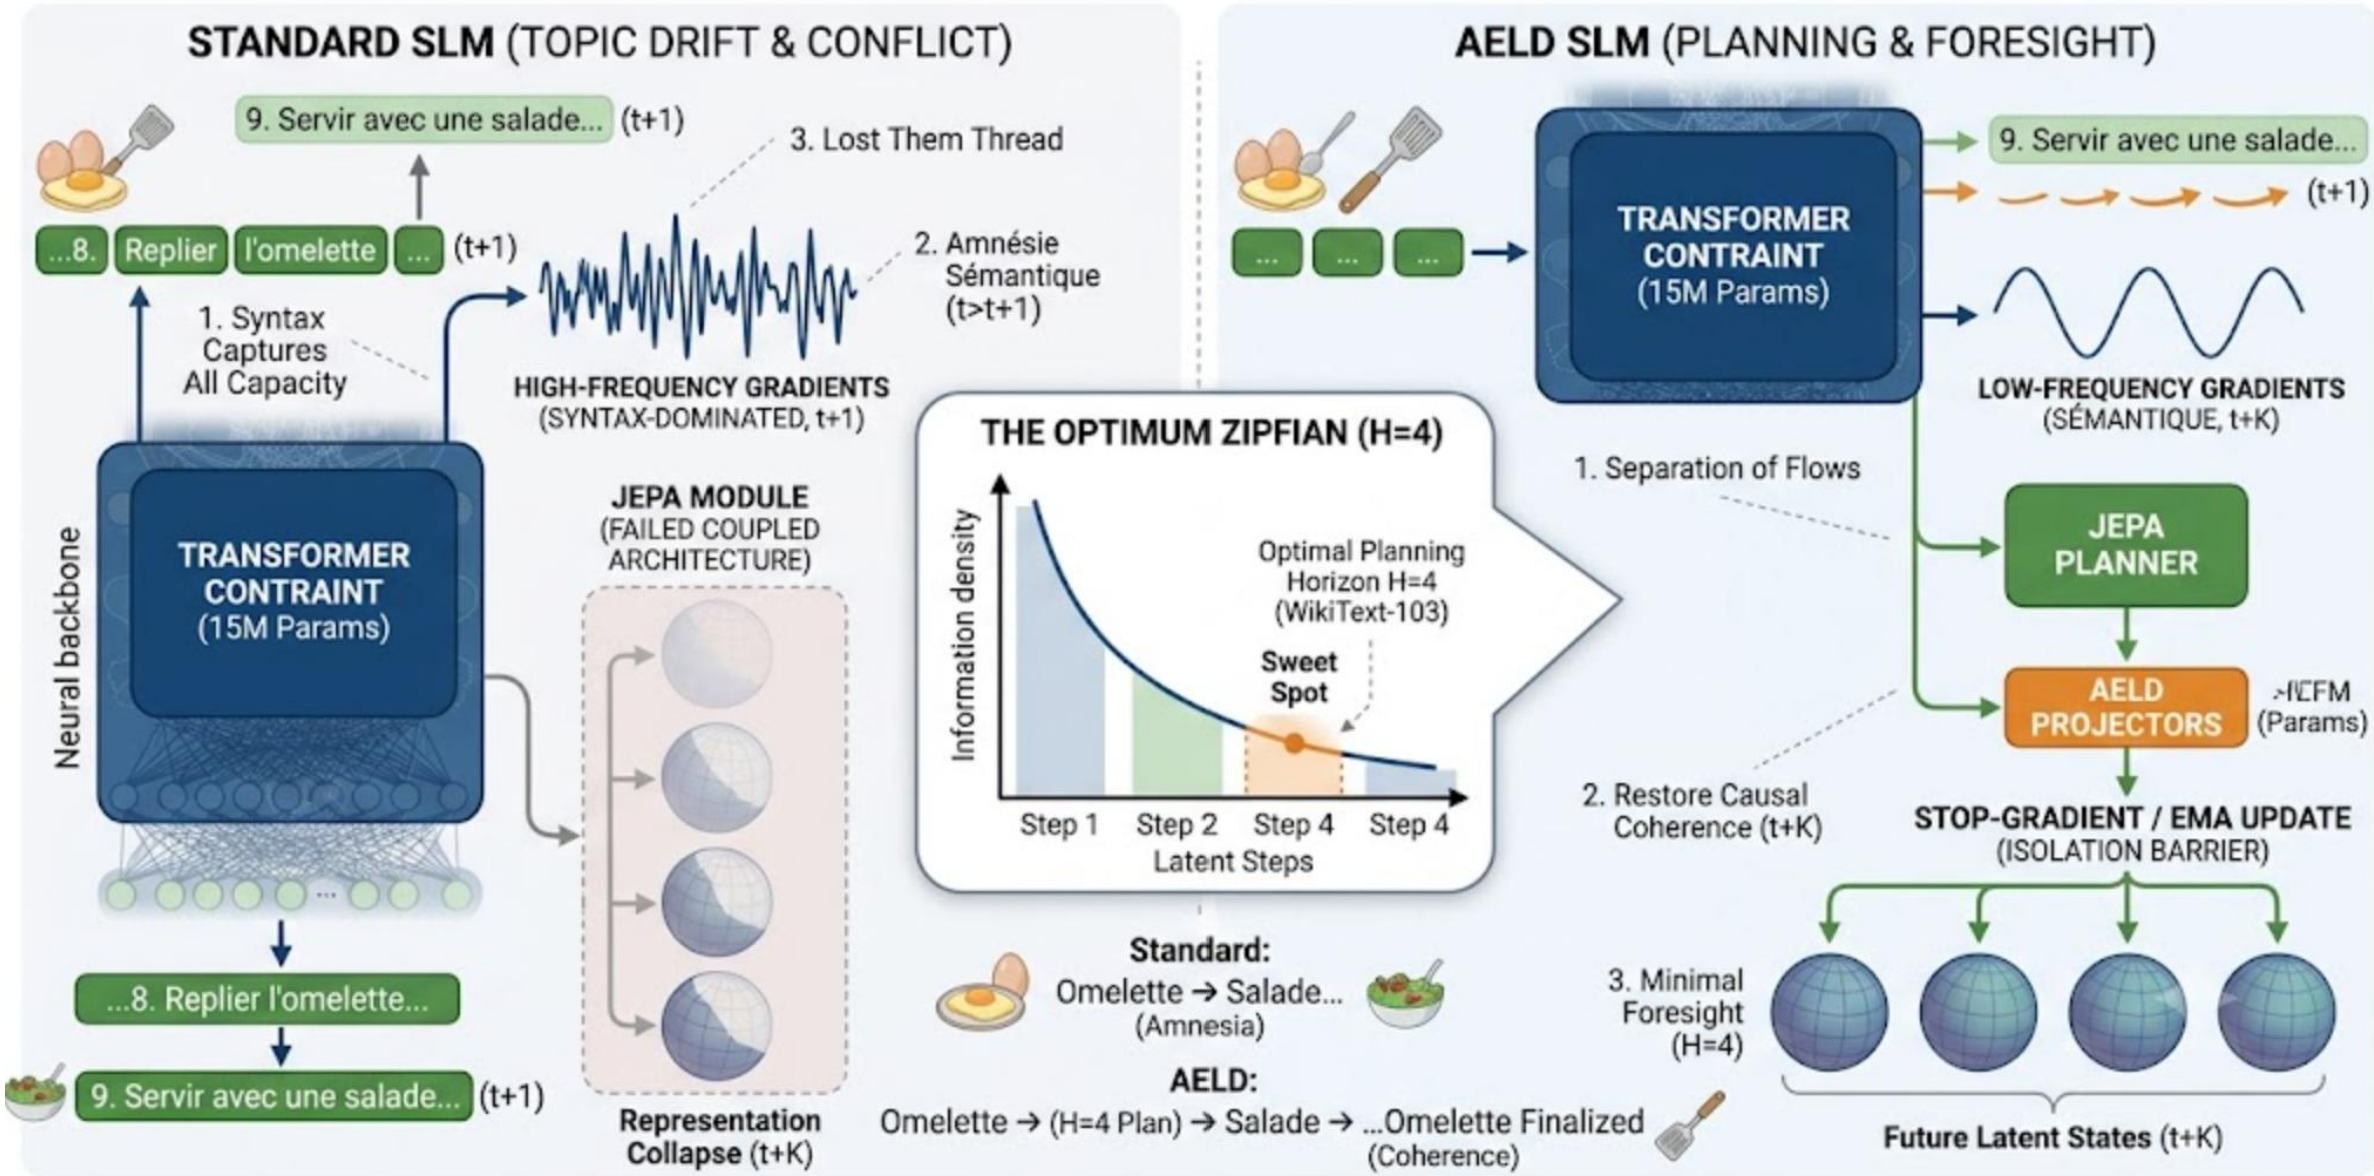
Les poids de l'encodeur cible sont une version lissée de l'encodeur sémantique, comme une moyenne glissante, pour stabiliser les cibles d'apprentissage

DECOUPLING SYNTAX AND PLANNING IN SMALL LANGUAGE MODELS (AELD ARCHITECTURE)

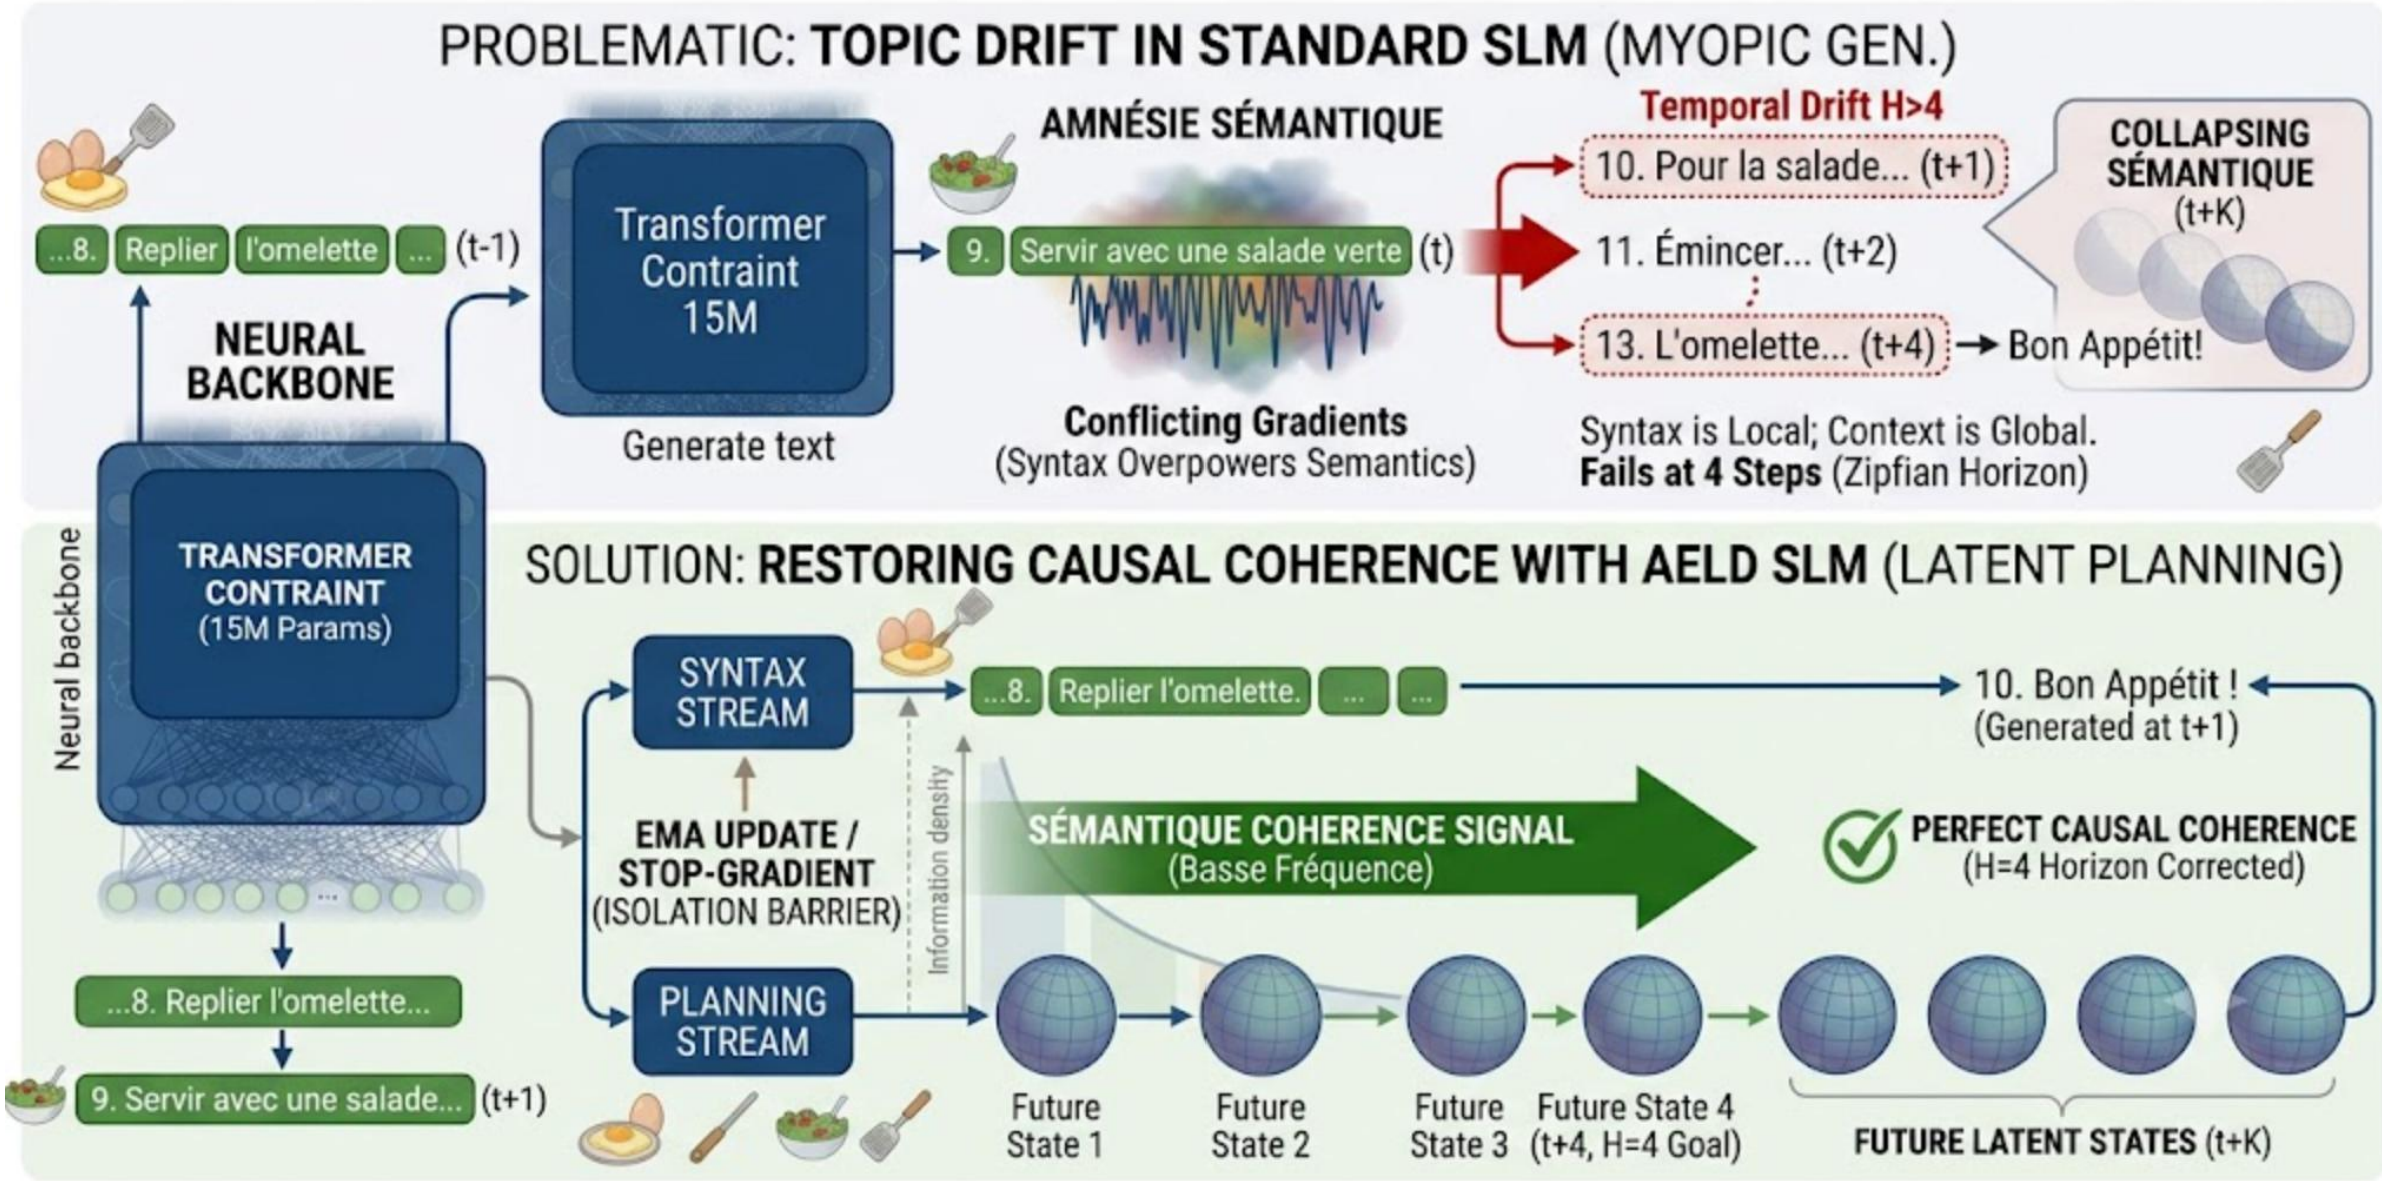
Concept to **prevent topic drift in a 15M parameter SLM**, using the recipe example from image_0.png, image_1.png, image_2.png



COGNITIVE ARCHITECTURES FOR SLM COHERENCE



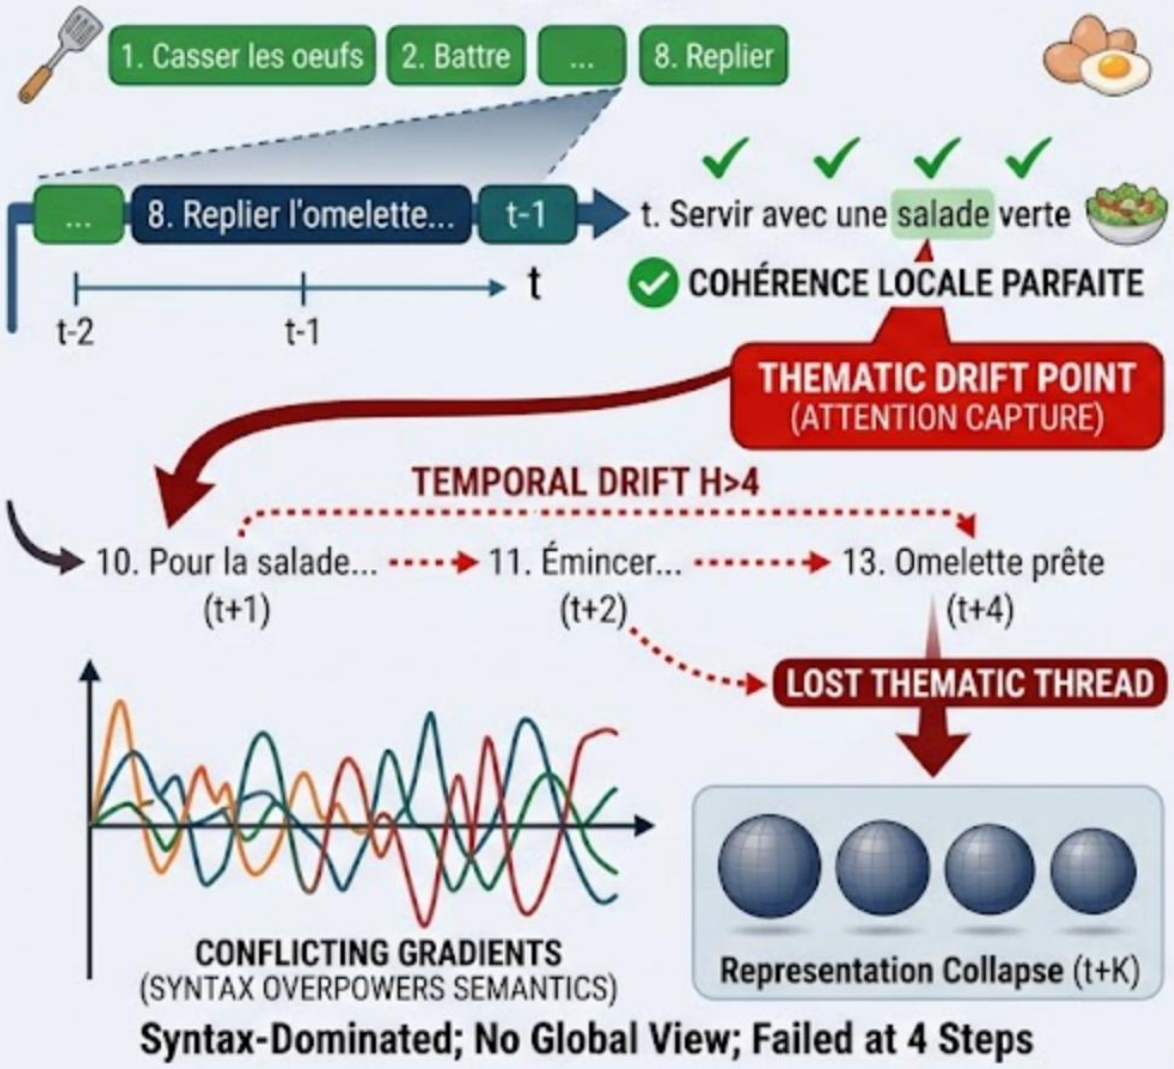
Recipe: Omelette Ratée/Coiffée



DECOUPLING SYNTAX AND PLANNING IN SLMs: THE AELD ARCHITECTURE

STANDARD AUTOREGRESSIVE SLM (MYOPIC GEN.)

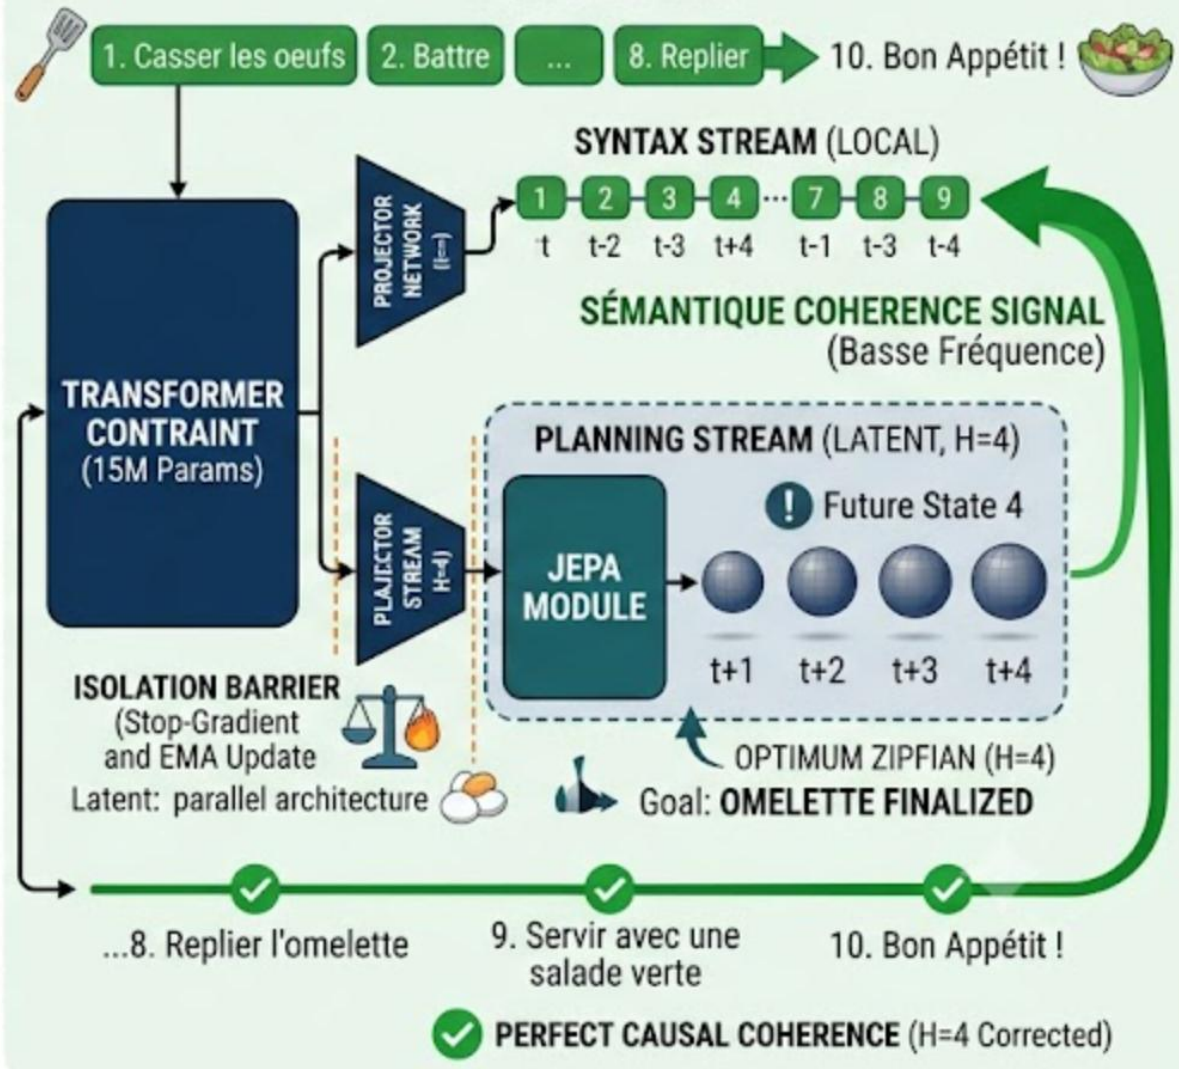
THE DRIFT



Syntax-Dominated; No Global View; Failed at 4 Steps

AELD SLM (PLANNING & FORESIGHT)

THE SOLUTION



AELD

Séparer la forme (la syntaxe) du fond (la planification). Elle coupe le modèle en deux "flux" distincts :

Le Flux Syntactique (En haut)

C'est un Transformer classique, mais très léger. Son unique rôle est de s'assurer que les phrases sont grammaticalement correctes et fluides au niveau local. Il ne réfléchit pas au futur, il aligne les mots.

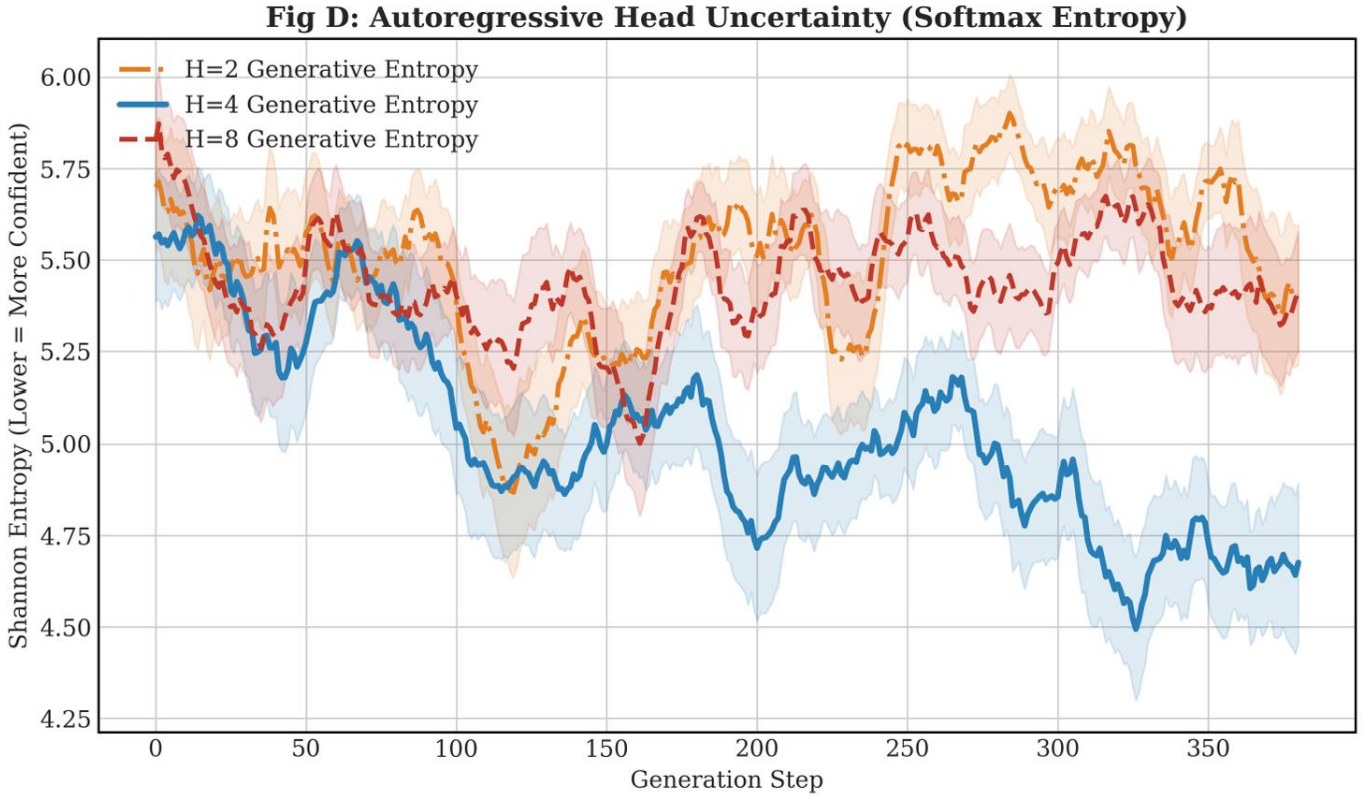
Le Flux de Planification (En bas - Le Module JEPA)

C'est la boussole du modèle. Il a un objectif clair gravé dans son espace latent : **"OMELETTE FINALISÉE"**.

Grâce à sa structure JEPA, il simule le futur dans l'espace latent avec un horizon de 4 étapes d'avance (H=4).

Il envoie ensuite un **"Signal de cohérence sémantique à basse fréquence"** au Transformer.

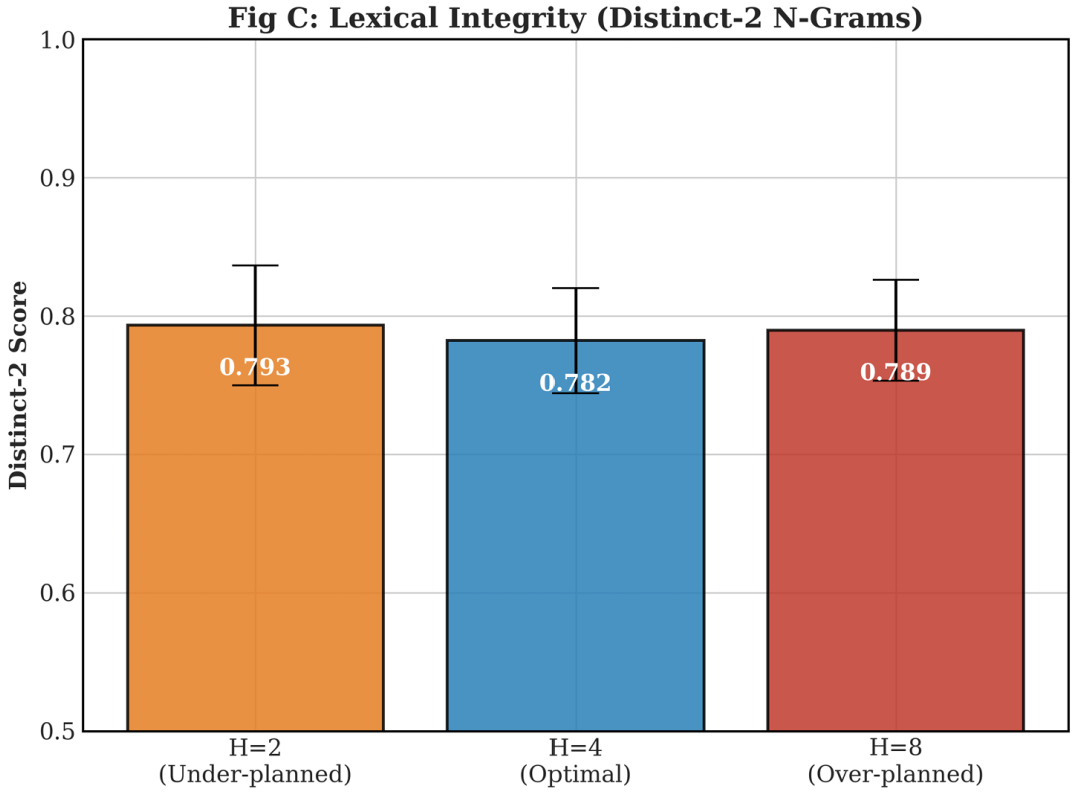
C'est comme un chef cuisinier qui crie à son assistant : *"Hé, n'oublie pas qu'on doit envoyer l'omelette, lâche cette salade !"*.



Entropie Softmax (Incertitude stochastique du décodeur).

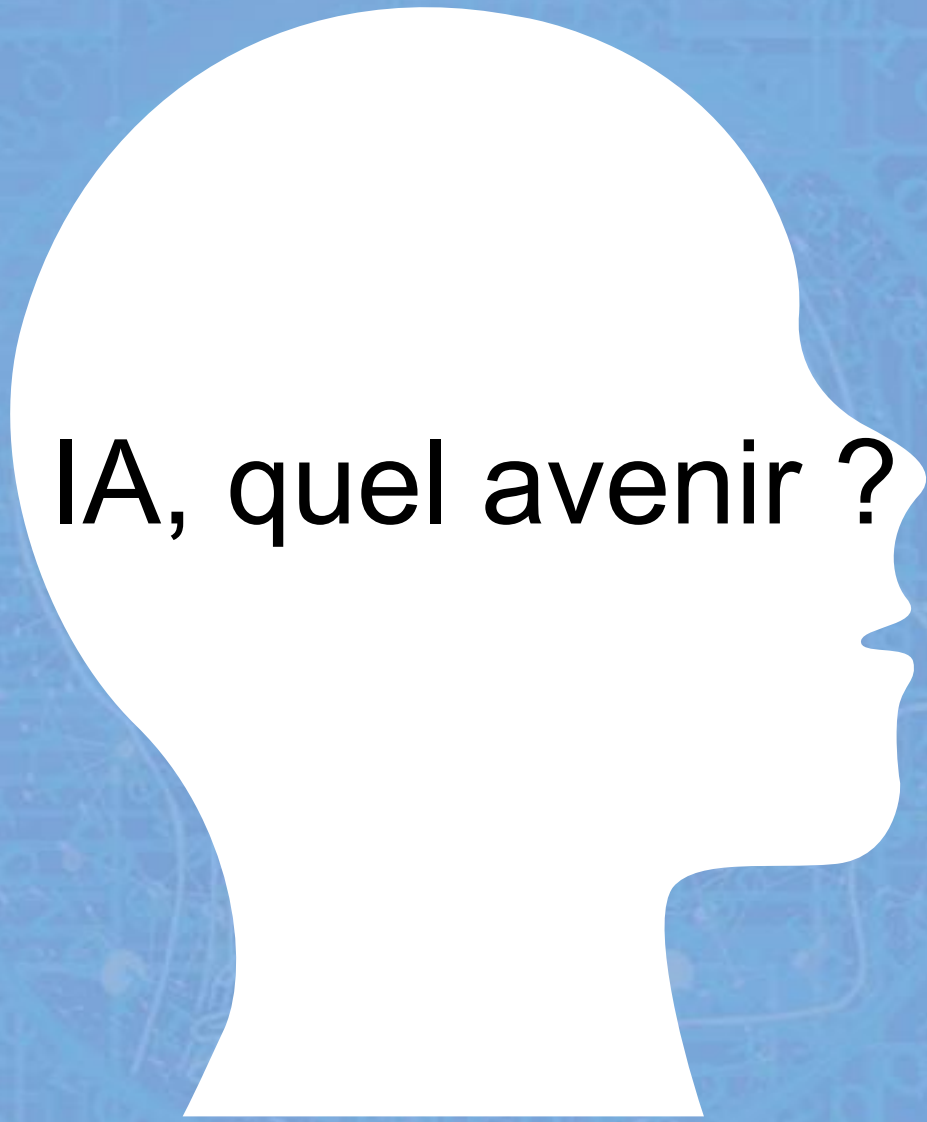
Dynamique de l'incertitude générative sous différentes contraintes tempo relles.

Diversité Lexicale (N-Grams Distincts)



RÉSULTATS

Modèle	Perplexité	Cohérence (H=4)	Drift mesuré
AR (15M)	32.4	0.21	78%
Hybride (15M)	31.8	0.35	65%
AELD (15M)	33.1	0.72	12%


IA, quel avenir ?